

Machine Learning Aplicado à Cartografia Geológica

Introdução a Inteligência Artificial



Iago Costa

IX SimBGF

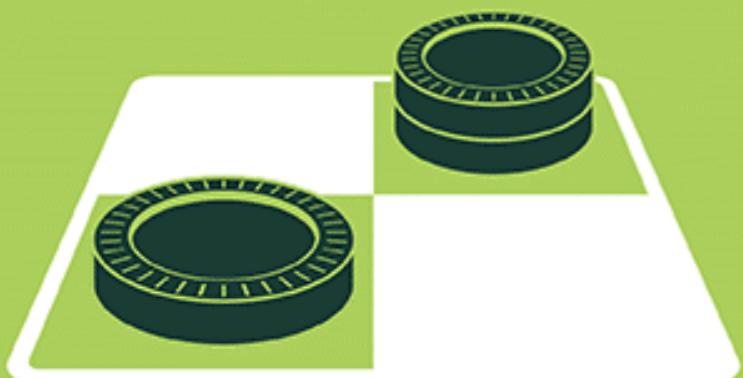
4 de outubro de 2022

Cronograma do Minicurso

1. Introdução ao Machine Learning
2. Introdução ao Orange Canvas e análise inicial dos dados
3. Prática de Geração dos mapas
4. Como a máquina aprende?

ARTIFICIAL INTELLIGENCE

Early artificial intelligence
stirs excitement.



MACHINE LEARNING

Machine learning begins
to flourish.



DEEP LEARNING

Deep learning breakthroughs
drive AI boom.

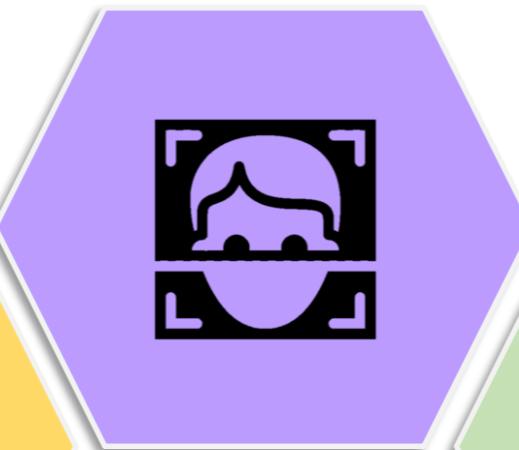


Aplicações do Machine Learning

Filtragem de Spam



Reconhecimento Facial



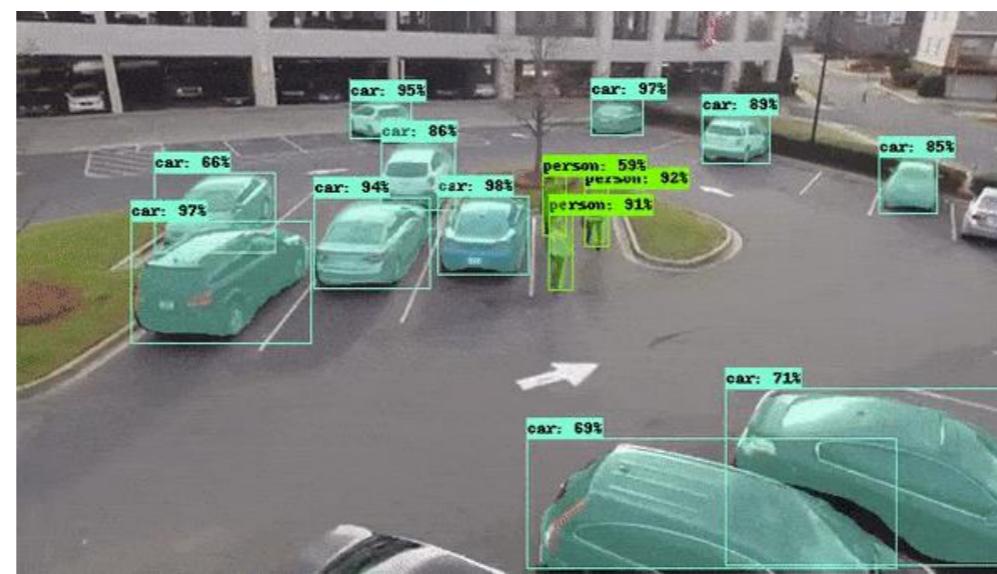
Carros Autônomos



Fraudes em Cartões de Crédito



Sistemas de Recomendação



Porque estudar e entender Machine Learning?



Ações Governamentais

CYCCLICAL CONSUMER GOODS DECEMBER 10, 2019 / 9:34 AM / UPDATED A YEAR AGO

Finland seeks to teach 1% of Europeans basics on artificial intelligence

By Reuters Staff

2 MIN READ



White House reportedly aims to double AI research budget to \$2B

Devin Coldewey @techcrunch / 7:51 PM GMT-3 • February 7, 2020

Comment



Medicina

News > Medscape Medical News > Neurology News

AI Blood Test Predicts Neurodegenerative Disease Progression, Severity

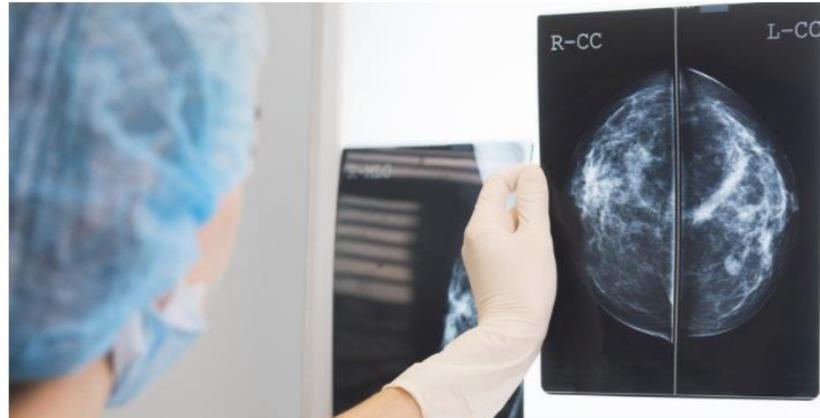
Michael Vlessides
February 07, 2020

Health | Coronavirus

AI 'outperforms' doctors diagnosing breast cancer

 **Fergus Walsh**
Medical correspondent
@BBCFergusWalsh

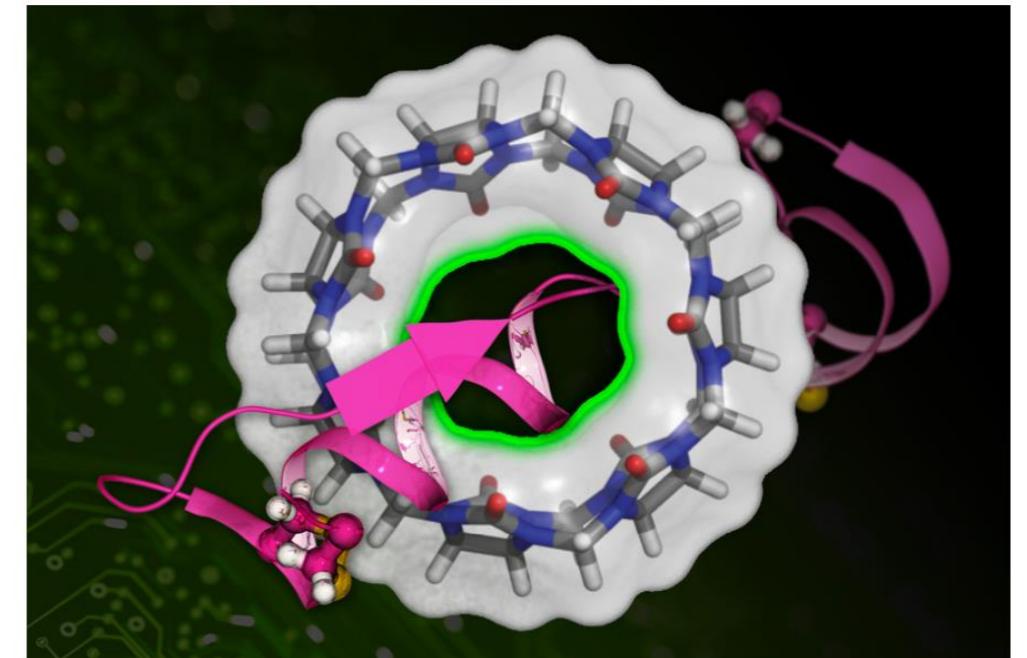
© 2 January 2020



Faster drug discovery through machine learning

New technique speeds up calculations of drug molecules' binding affinity to proteins.

Daniel Ackerman | MIT News Office
March 15, 2021



Games

TOM SIMONITE BUSINESS 01.25.2019 01:05 PM

DeepMind Beats Pros at StarCraft in Another Triumph for Bots

The group behind the software program that conquered the board game Go beat a world champion at real-time-strategy videogame StarCraft II.



A pro gamer and an AI bot duke it out in the strategy game StarCraft, which has become a test bed for research on artificial intelligence. [STARCRAFT](#)

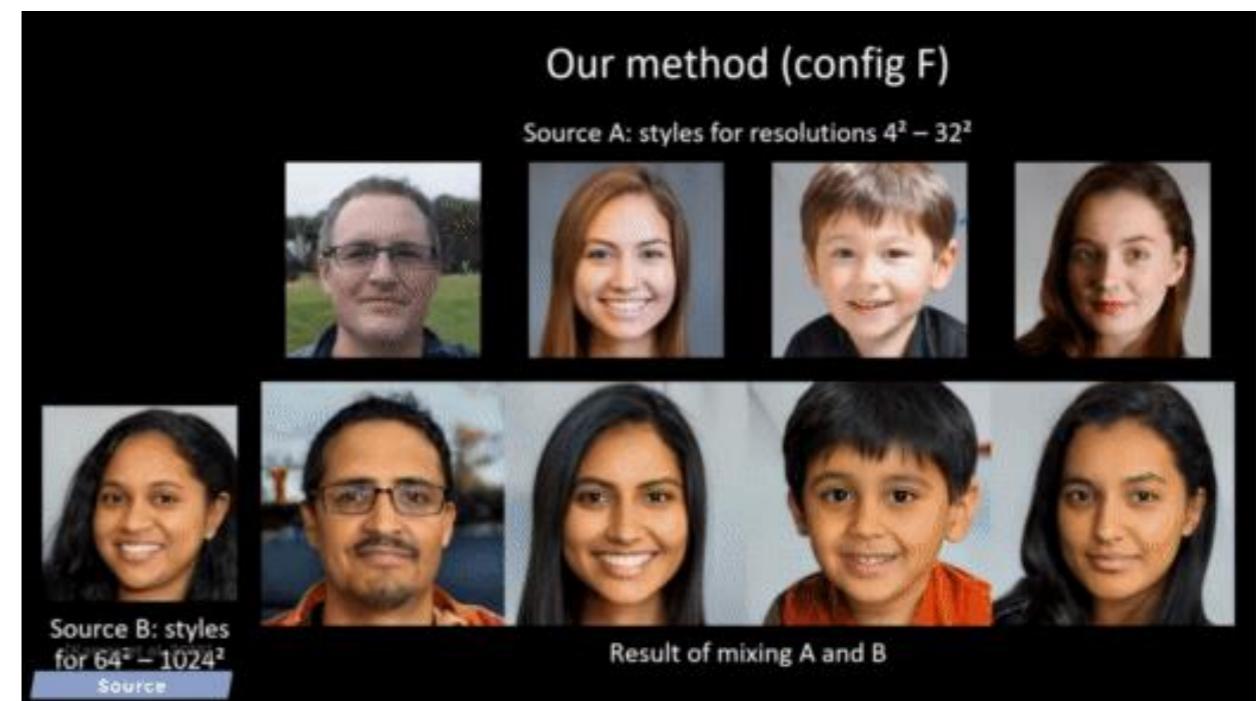
TECH

AlphaZero beat humans at Chess and StarCraft, now it's working with quantum computers

Fake Images

New machine learning algorithm produces "near-perfect" fake human faces

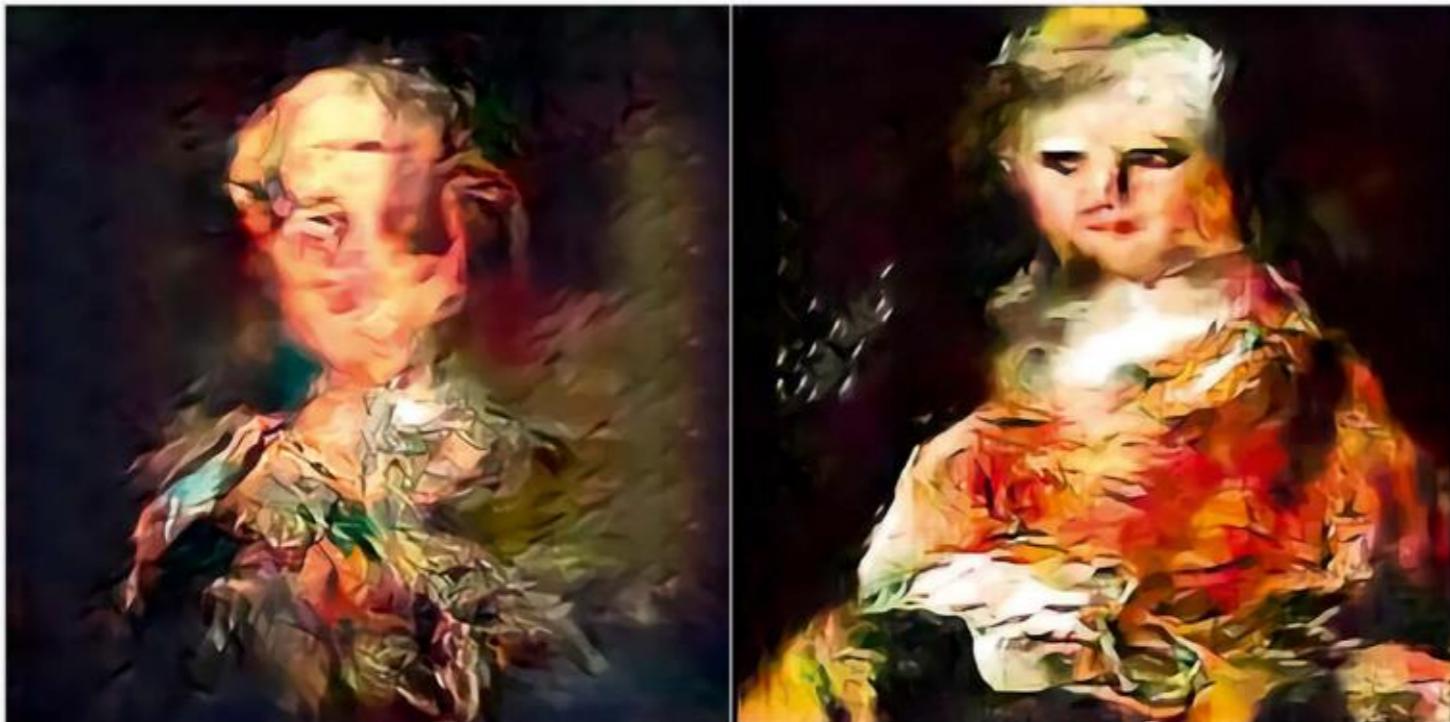
MARK FRAUENFELDER / 9:50 AM SAT FEB 1, 2020



Arte

The AI-Art Gold Rush Is Here

An artificial-intelligence “artist” got a solo show at a Chelsea gallery. Will it reinvent art, or destroy it?



AI-generated "faceless portraits" by Ahmed Elgammal and AICAN.

Portrait of Edmond Belamy



Preço de venda
USD 432,500

2018

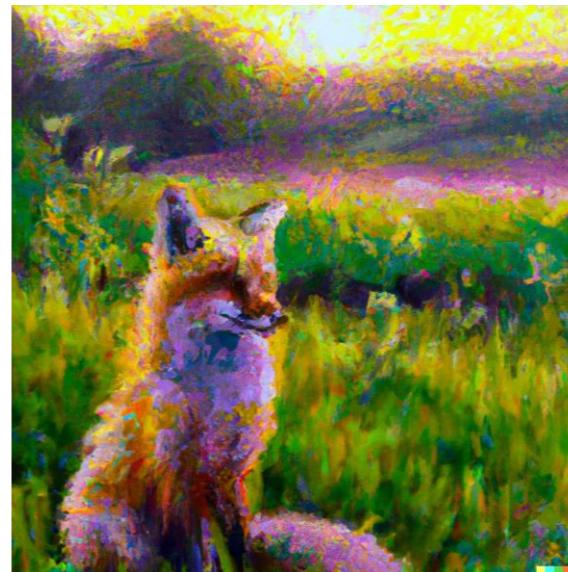
Arte

“Uma pintura de uma raposa sentada em um campo ao nascer do sol no estilo de Claude Monet”

DALL·E 1
(2021)



DALL·E 2
(2022)

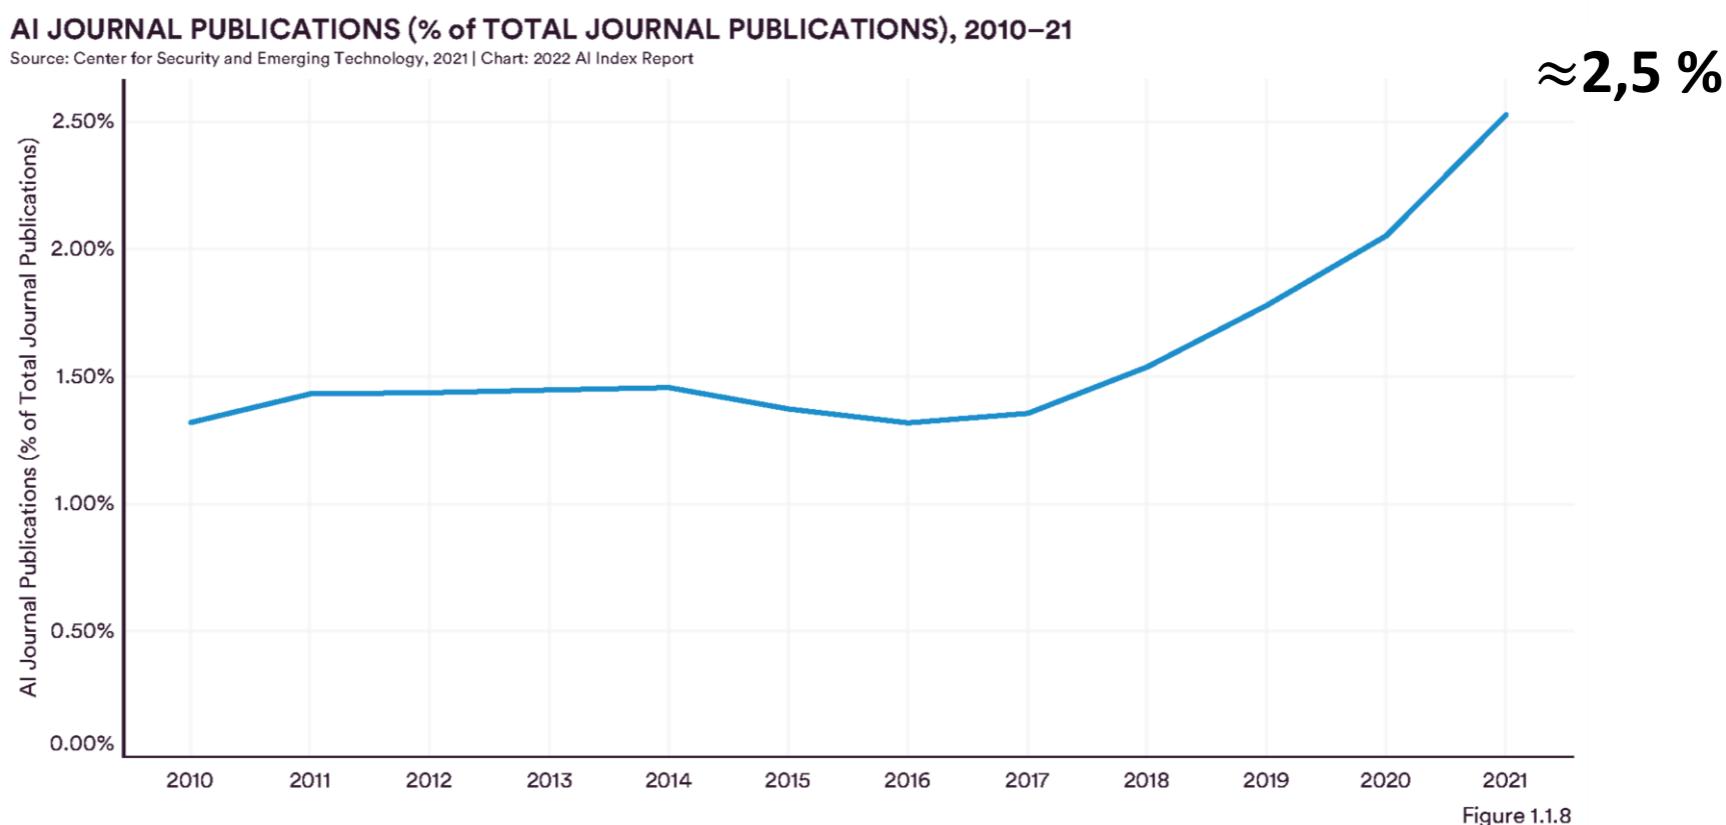
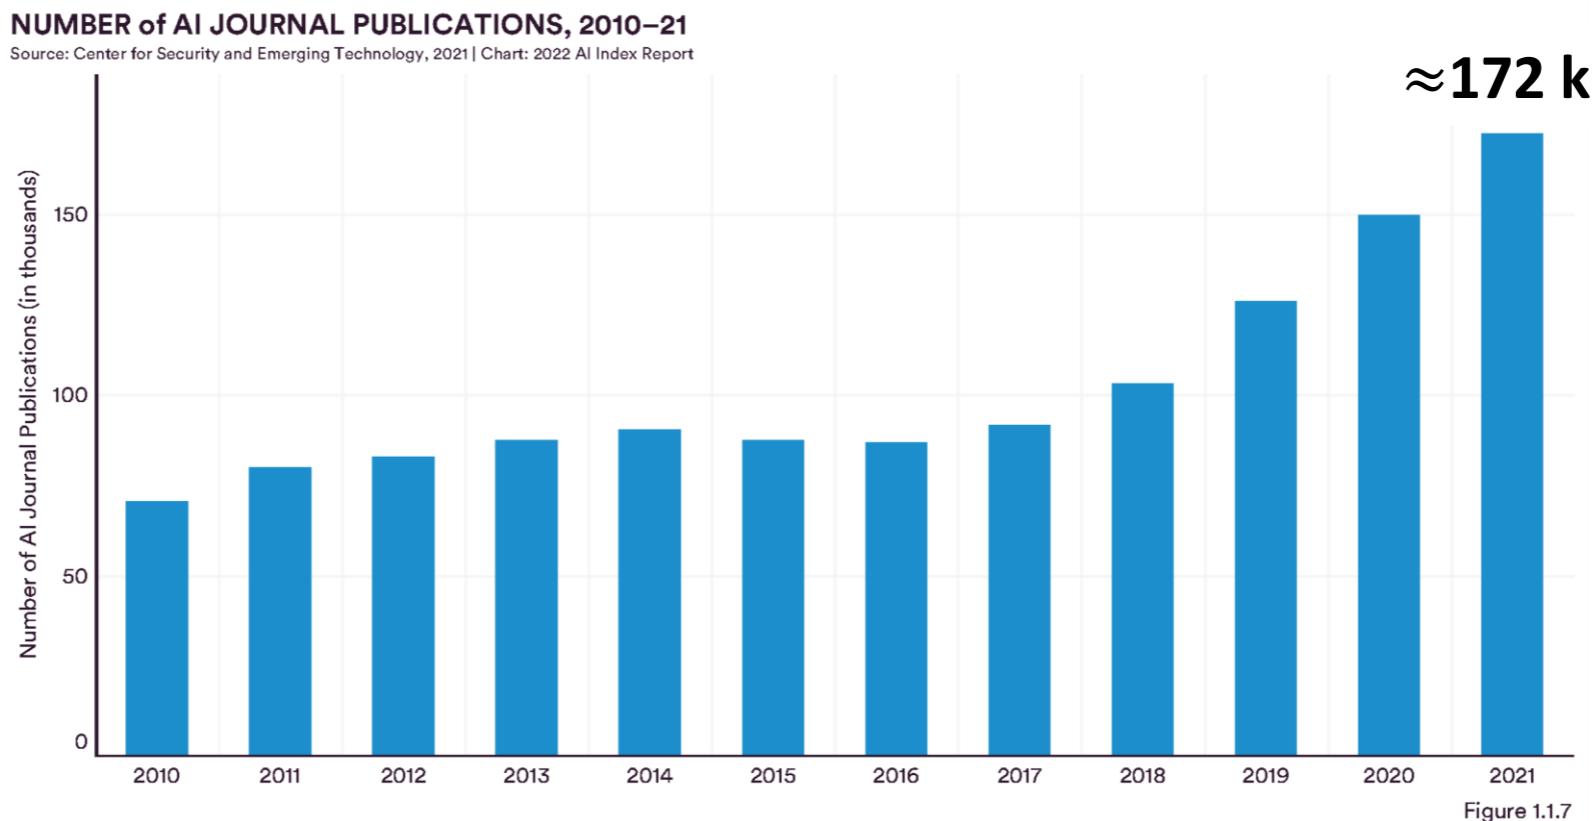


“Um astronauta jogando basquete com gatos no espaço como uma ilustração em um livro infantil”

DALL·E 2
(2022)



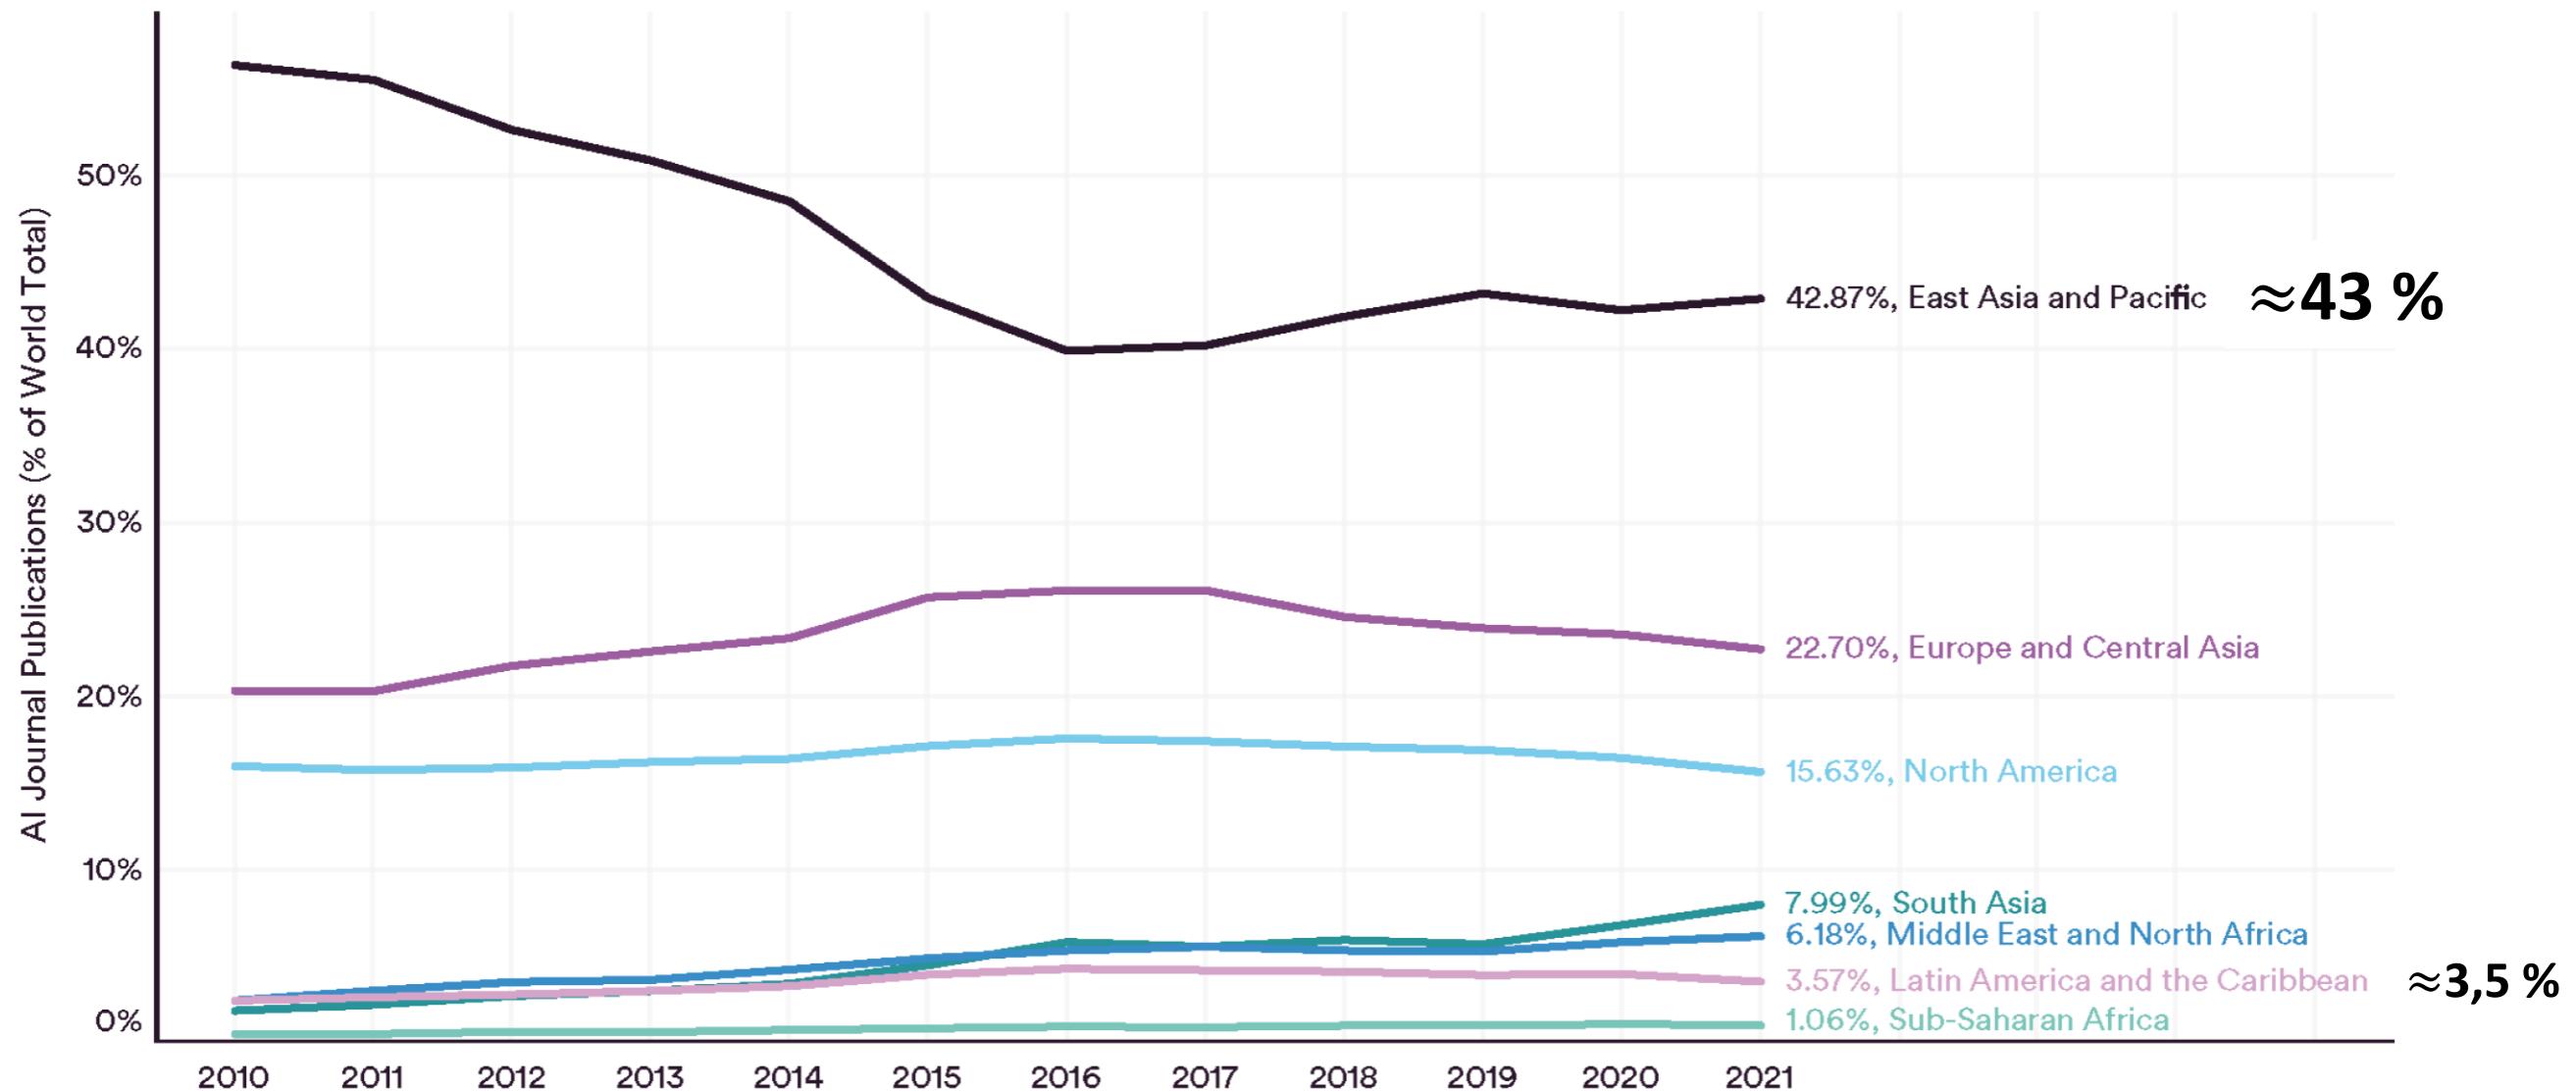
Número de Publicações científicas em IA (2010 – 2021)



Número de Publicações científicas em IA por região (2010 – 2021)

AI JOURNAL PUBLICATIONS (% of WORLD TOTAL) by REGION, 2010–21

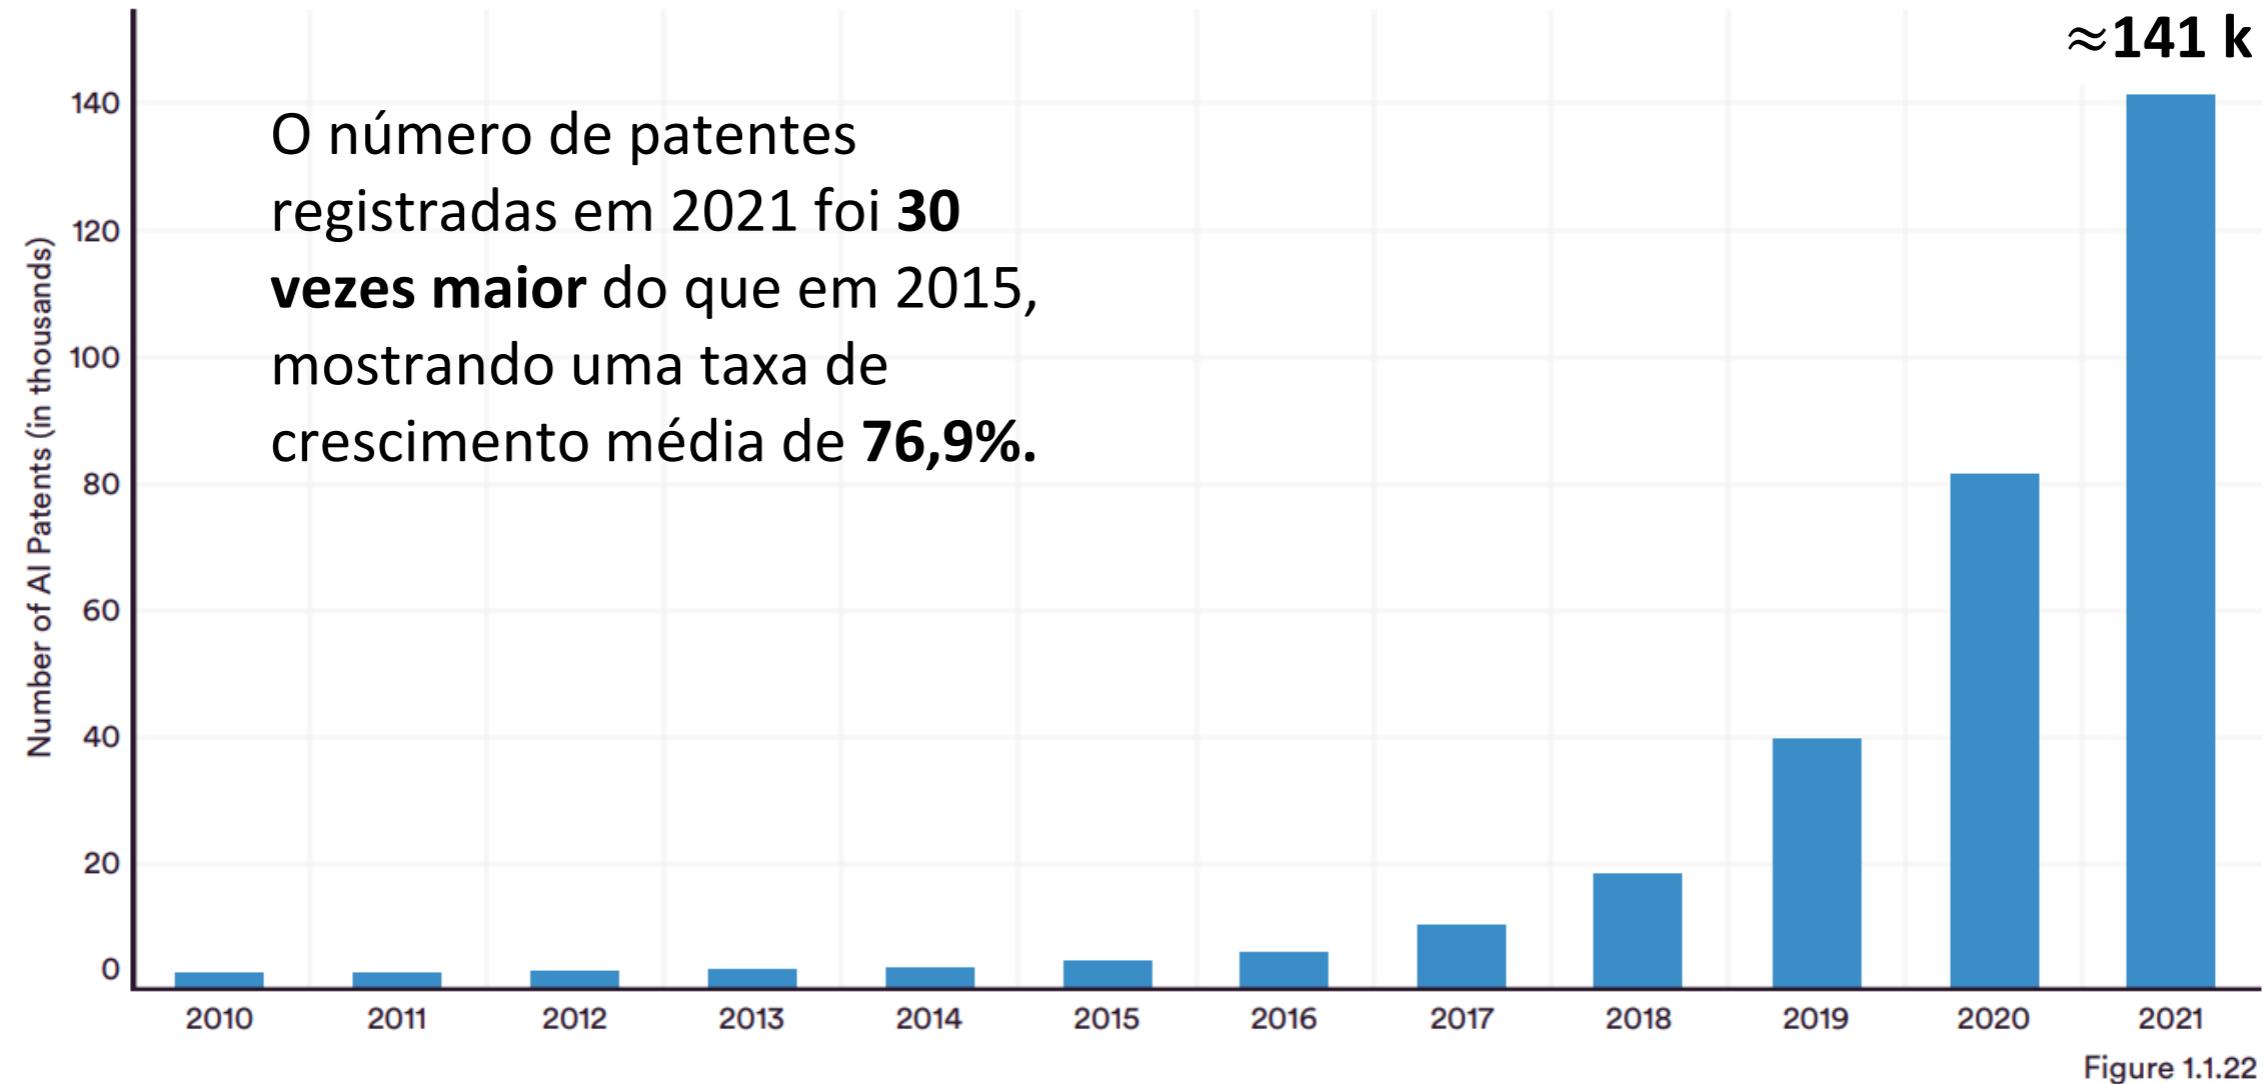
Source: Center for Security and Emerging Technology, 2021 | Chart: 2022 AI Index Report



Número de Patentes em IA (2010 – 2021)

NUMBER of AI PATENT FILINGS, 2010–21

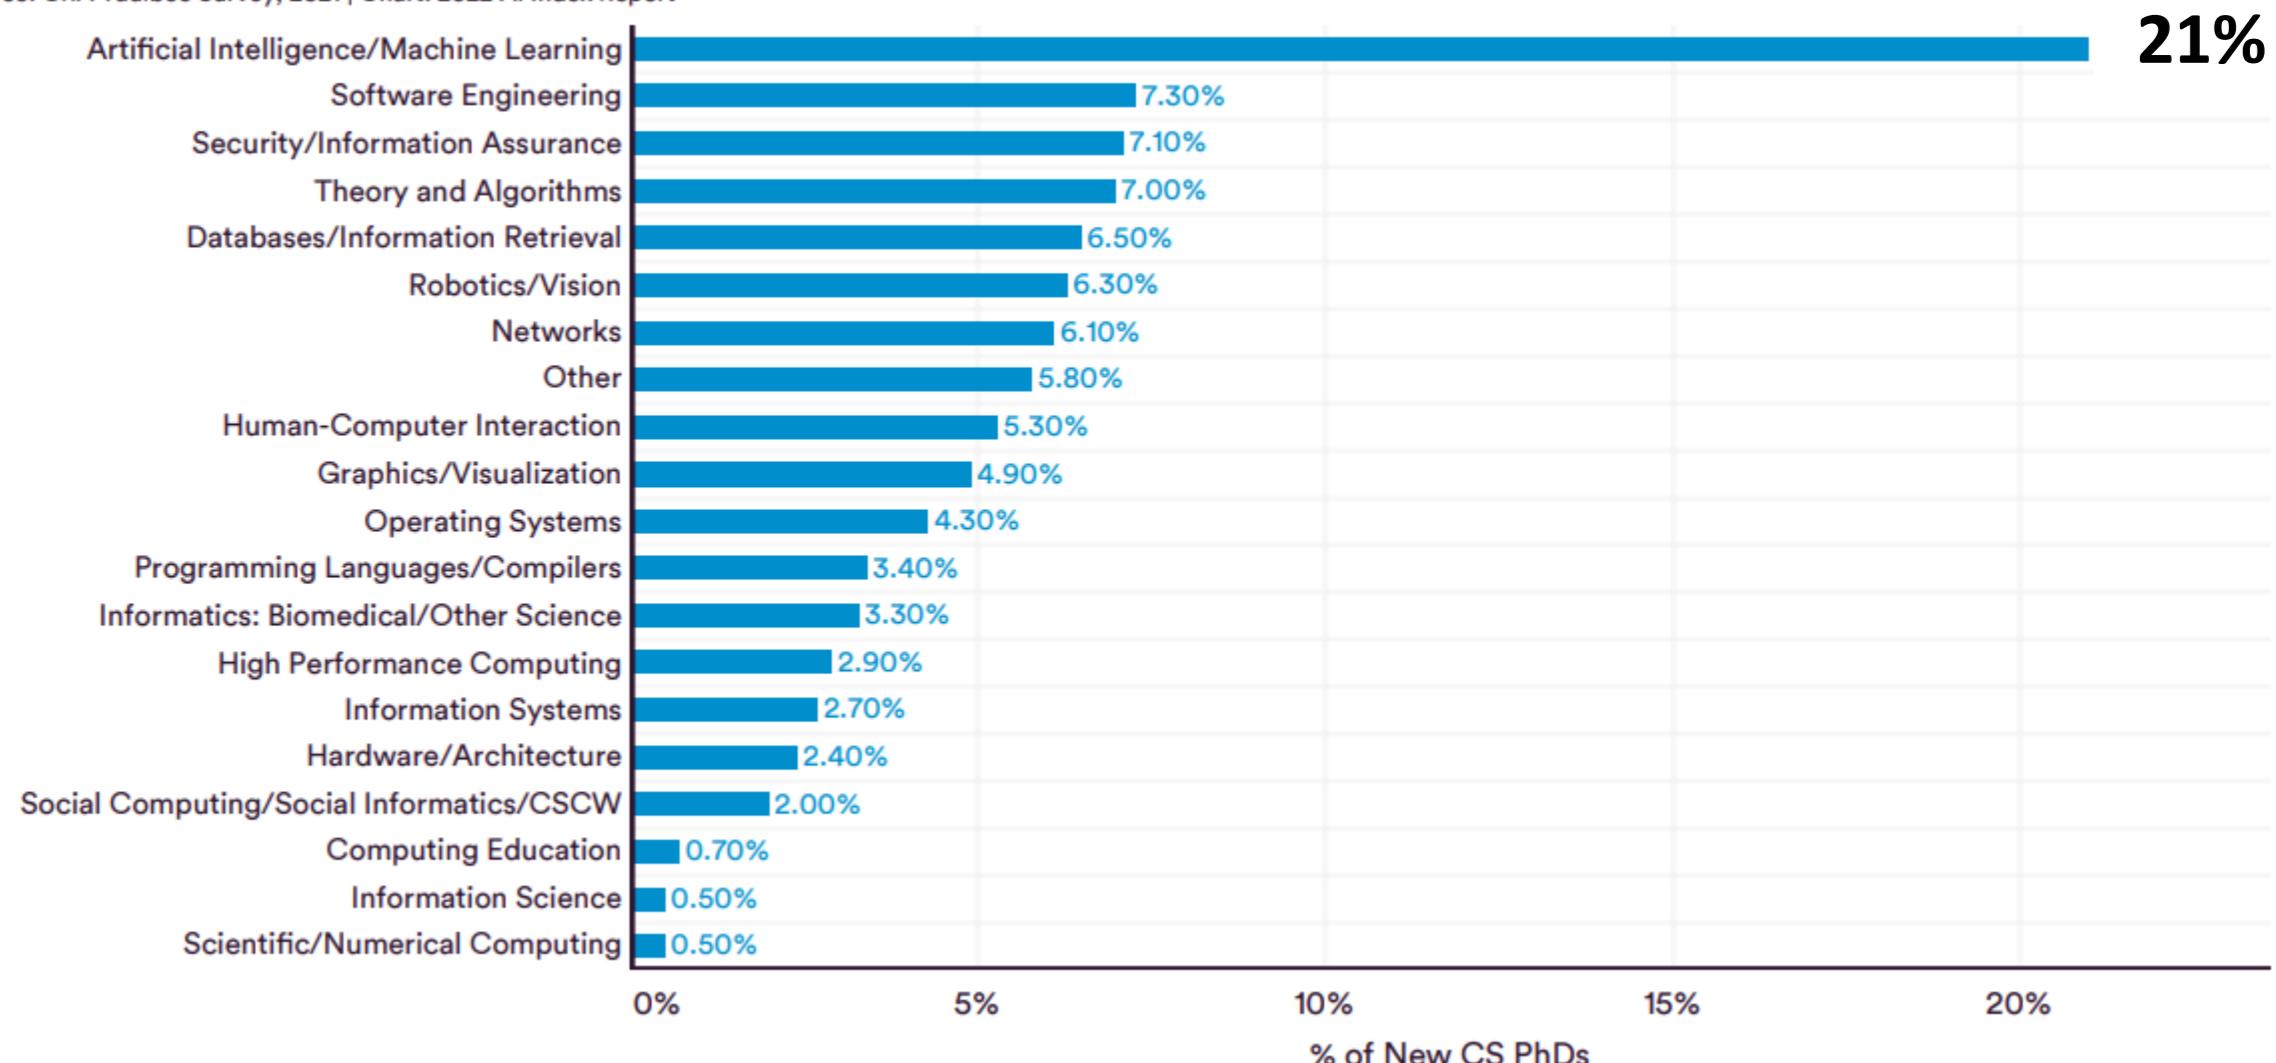
Source: Center for Security and Emerging Technology, 2021 | Chart: 2022 AI Index Report



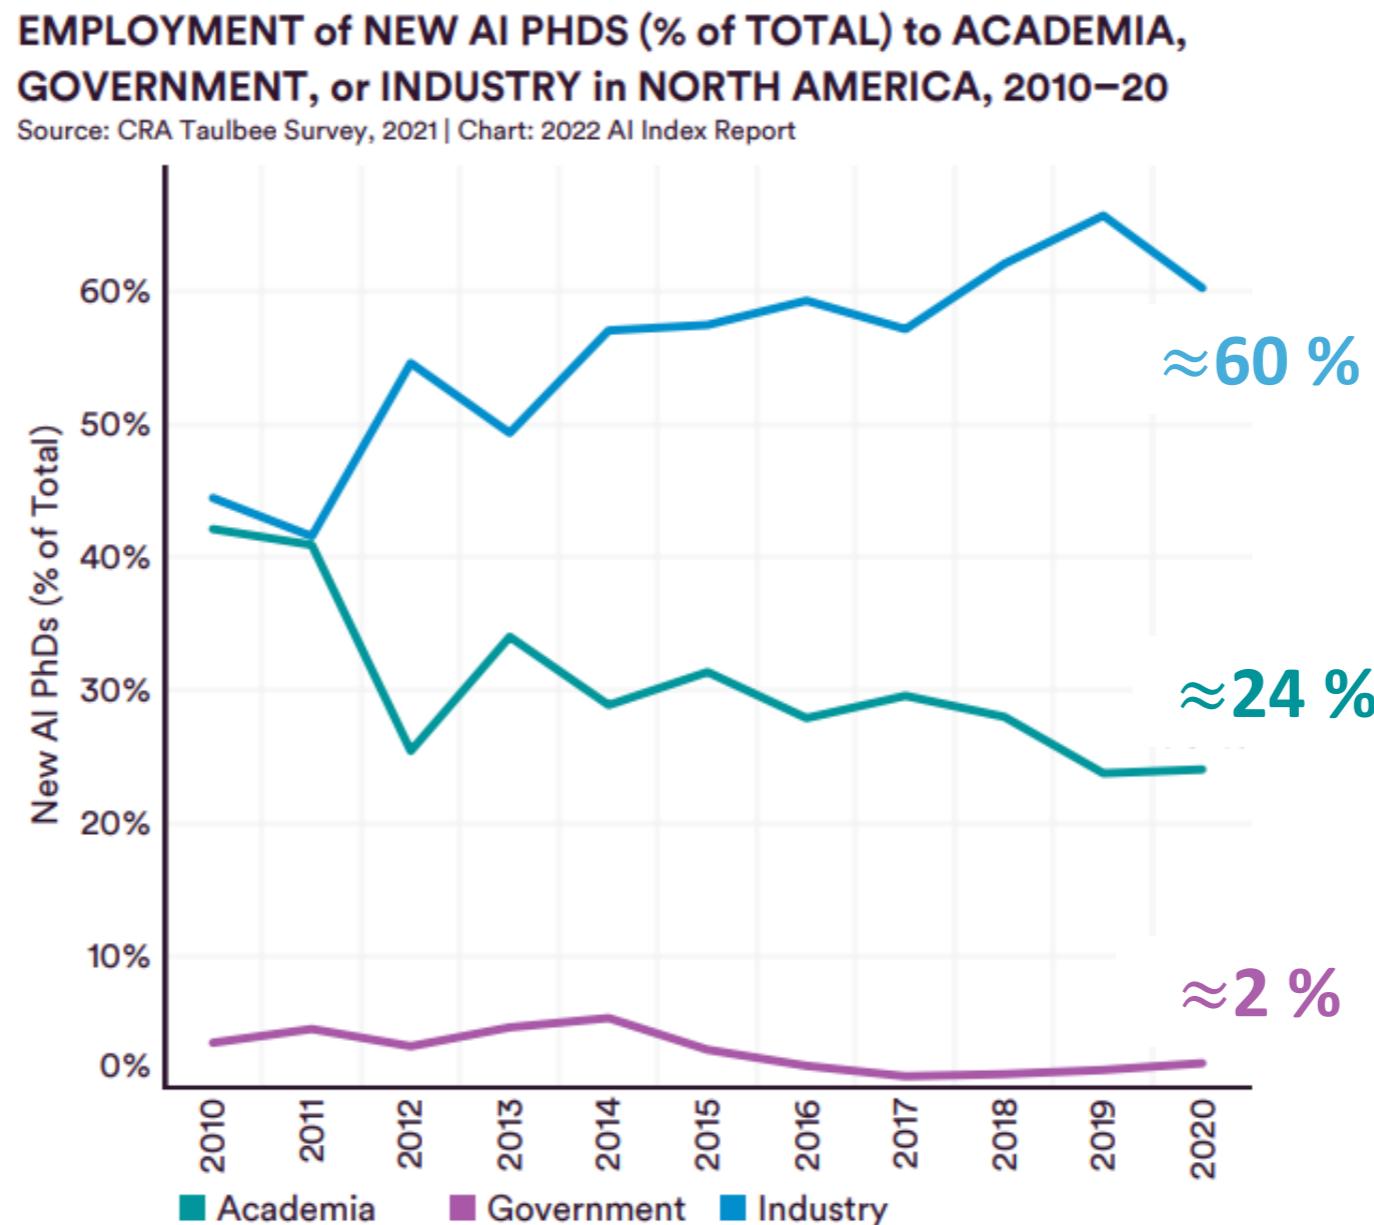
Doutorados em Ciência da Computação por especialidade (2020)

NEW CS PHDS (% of TOTAL) in the UNITED STATES by SPECIALITY, 2020

Source: CRA Taulbee Survey, 2021 | Chart: 2022 AI Index Report



Empregos em Ciência da Computação – Academia x Indústria



Investimento Privado em IA no Mundo

PRIVATE INVESTMENT in AI, 2013–21

Source: NetBase Quid, 2021 | Chart: 2022 AI Index Report



Investimentos Privados em IA por País

PRIVATE INVESTMENT in AI by GEOGRAPHIC AREA, 2021

Source: NetBase Quid, 2021 | Chart: 2022 AI Index Report

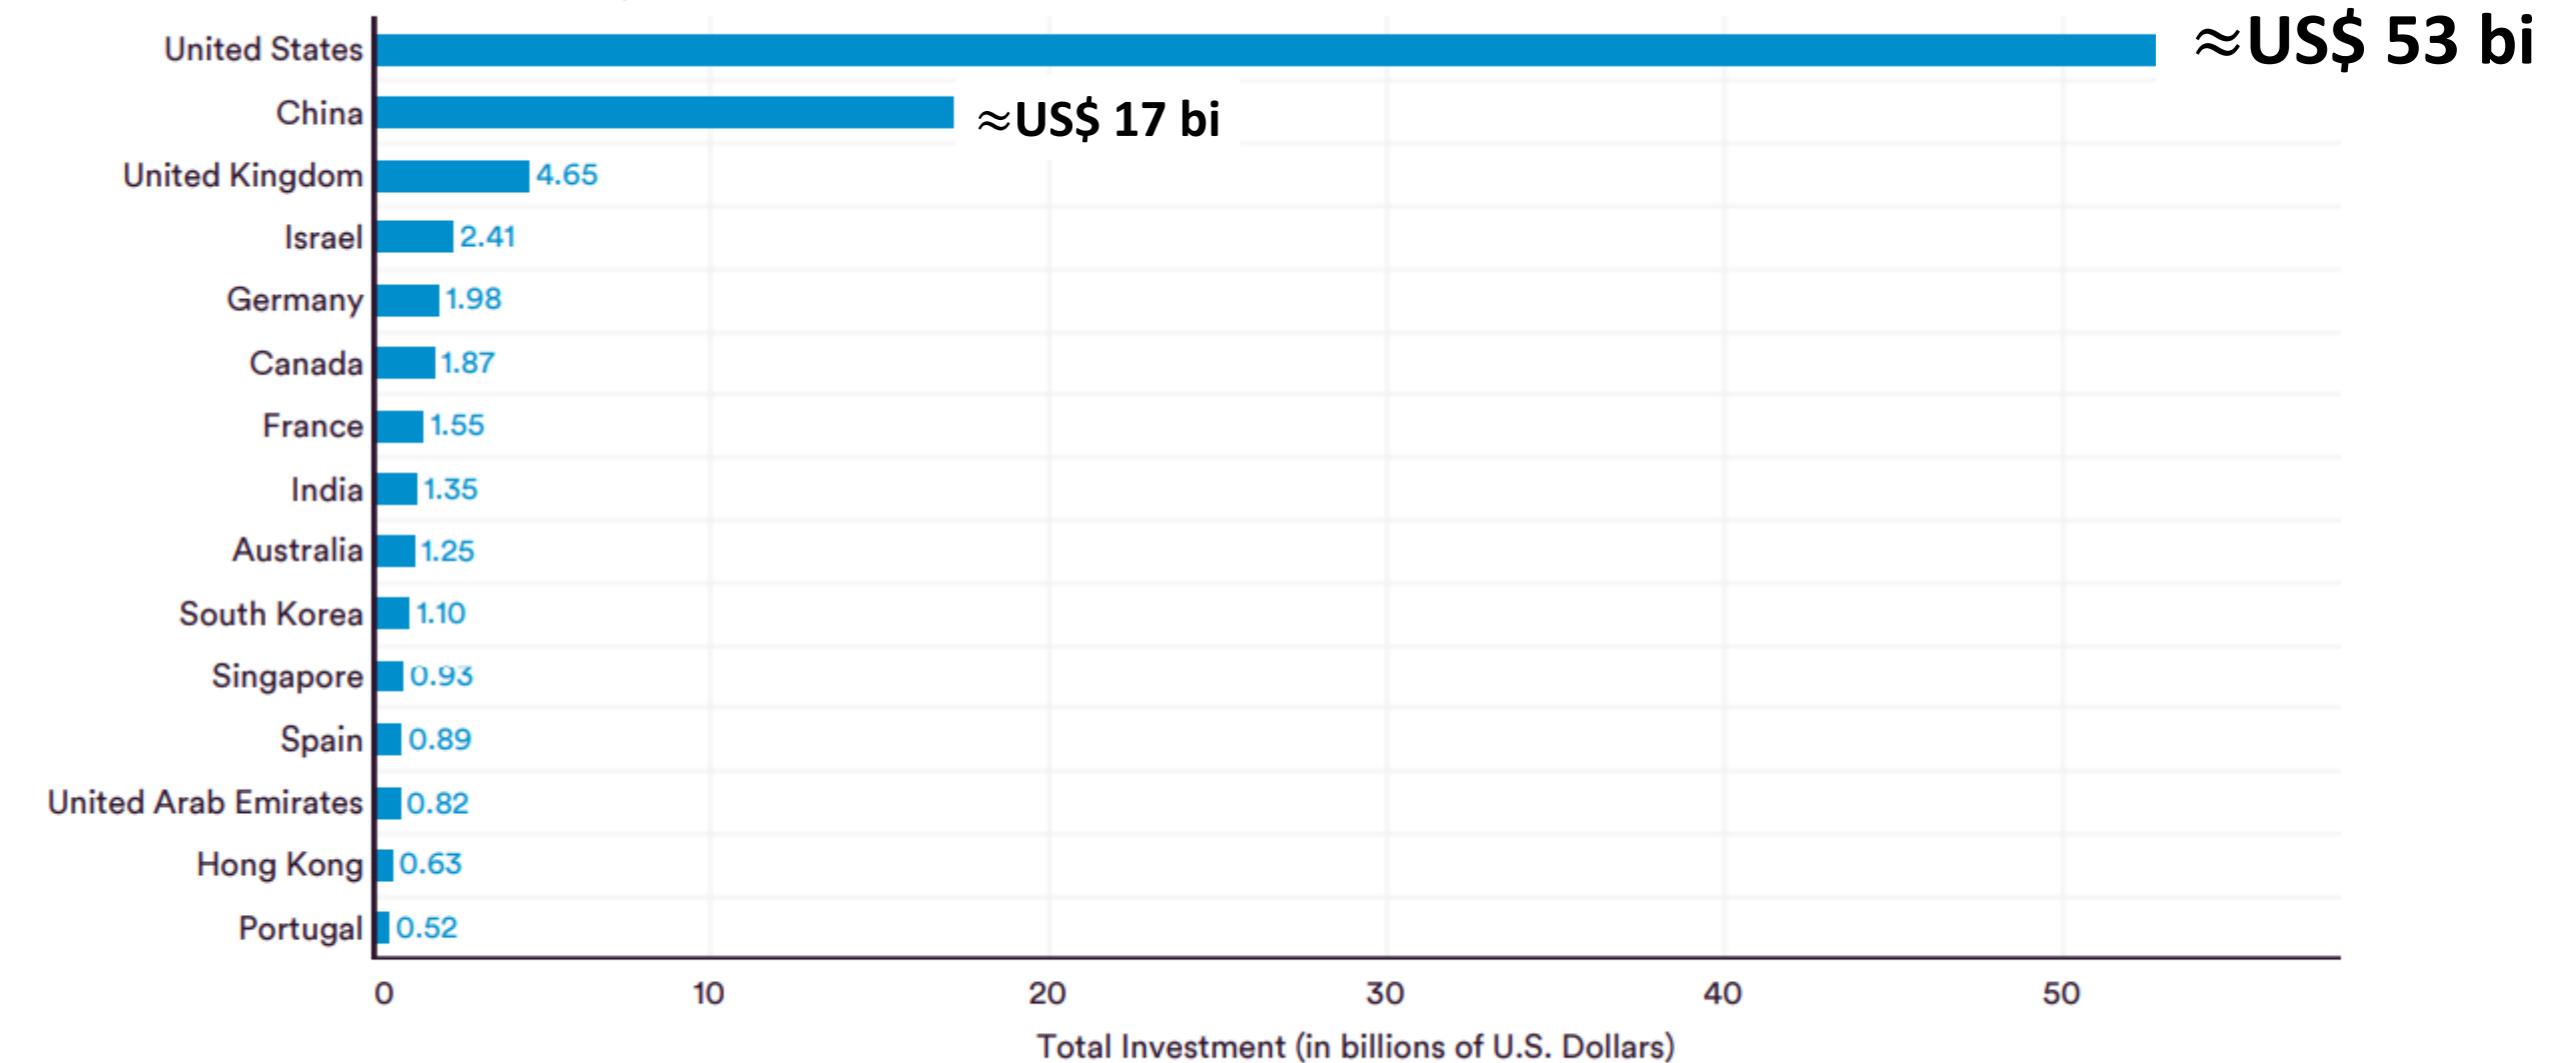
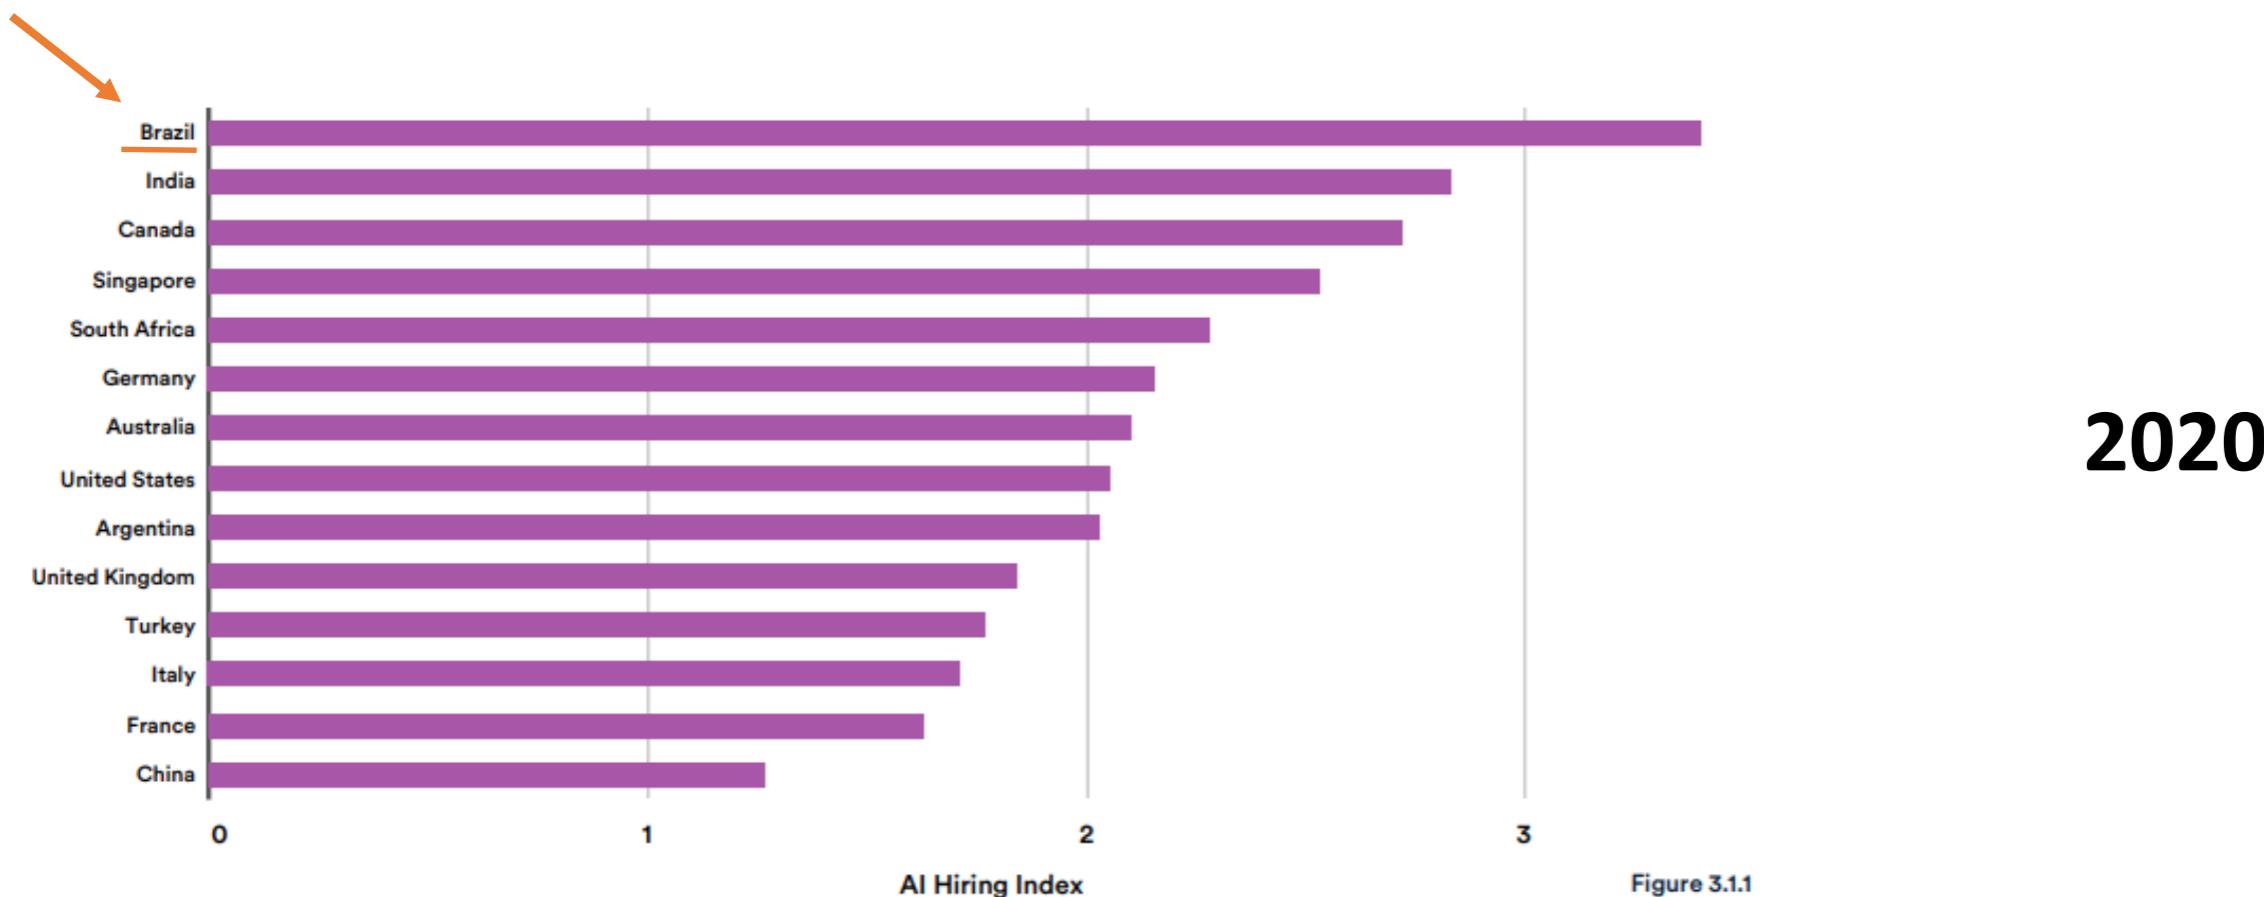


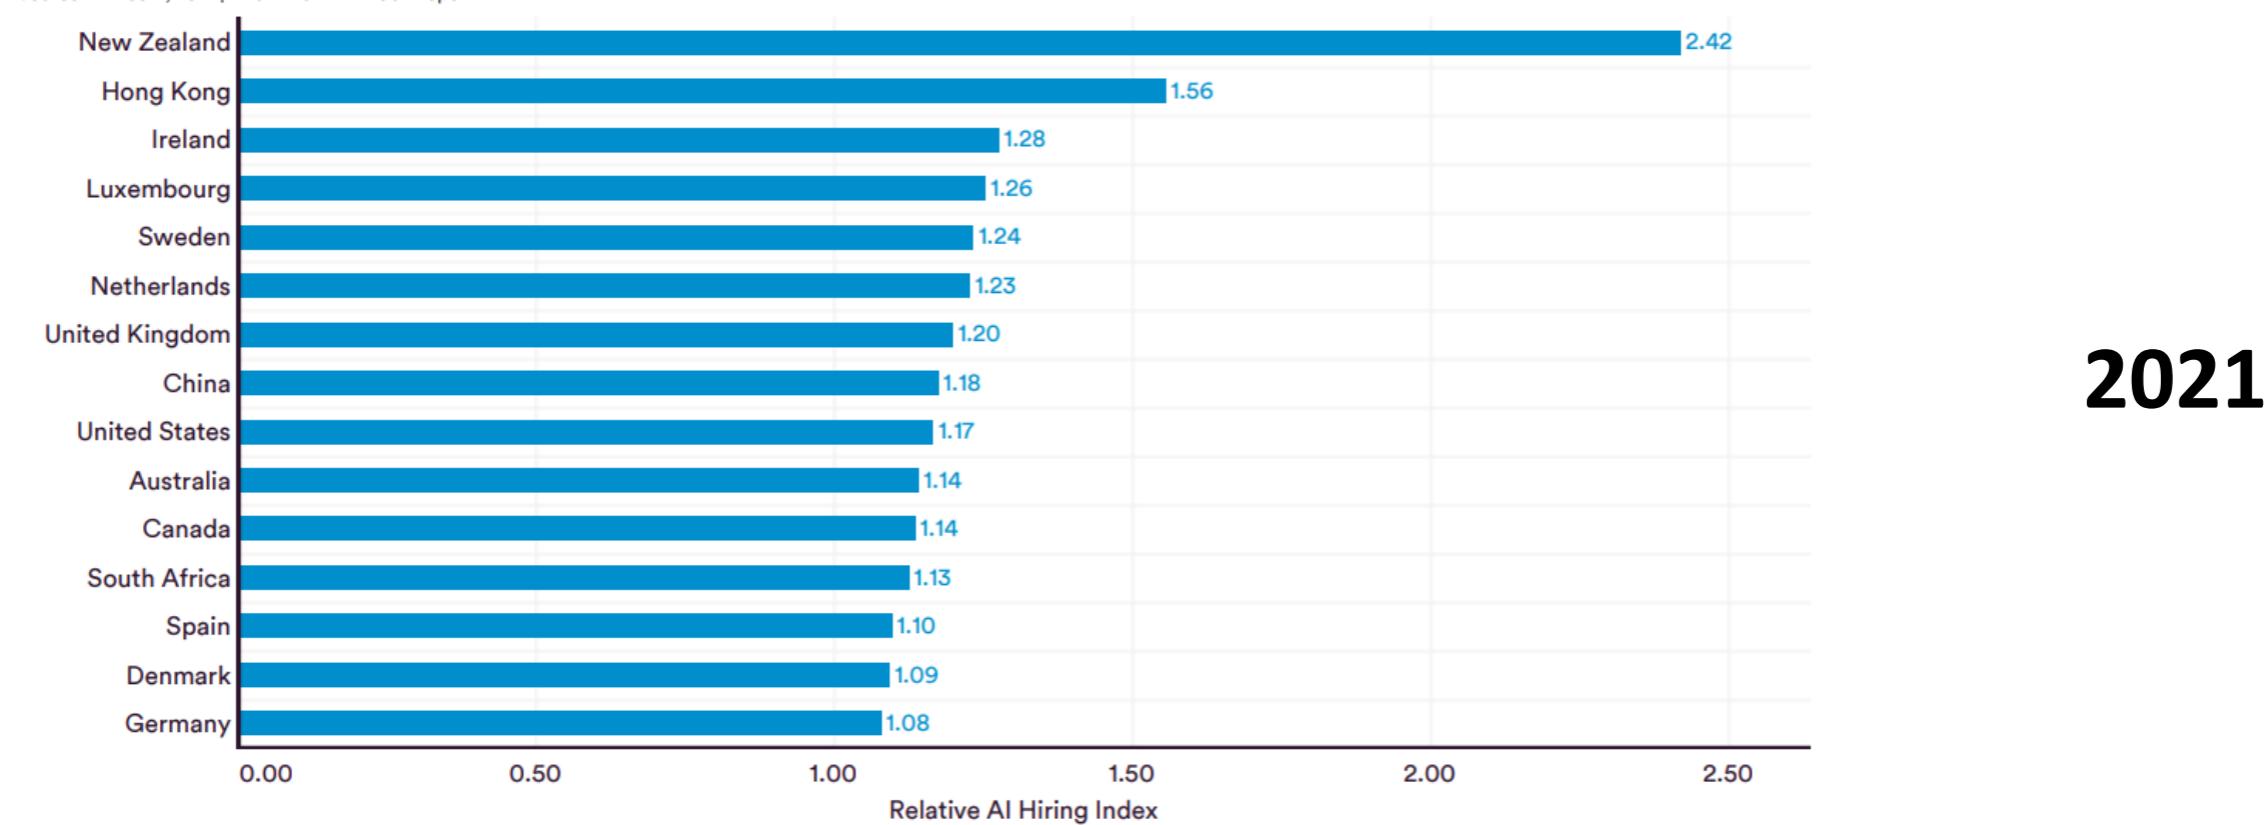
Figure 4.2.4

Índice de contratações de Profissionais de IA por País



RELATIVE AI HIRING INDEX by GEOGRAPHIC AREA, 2021

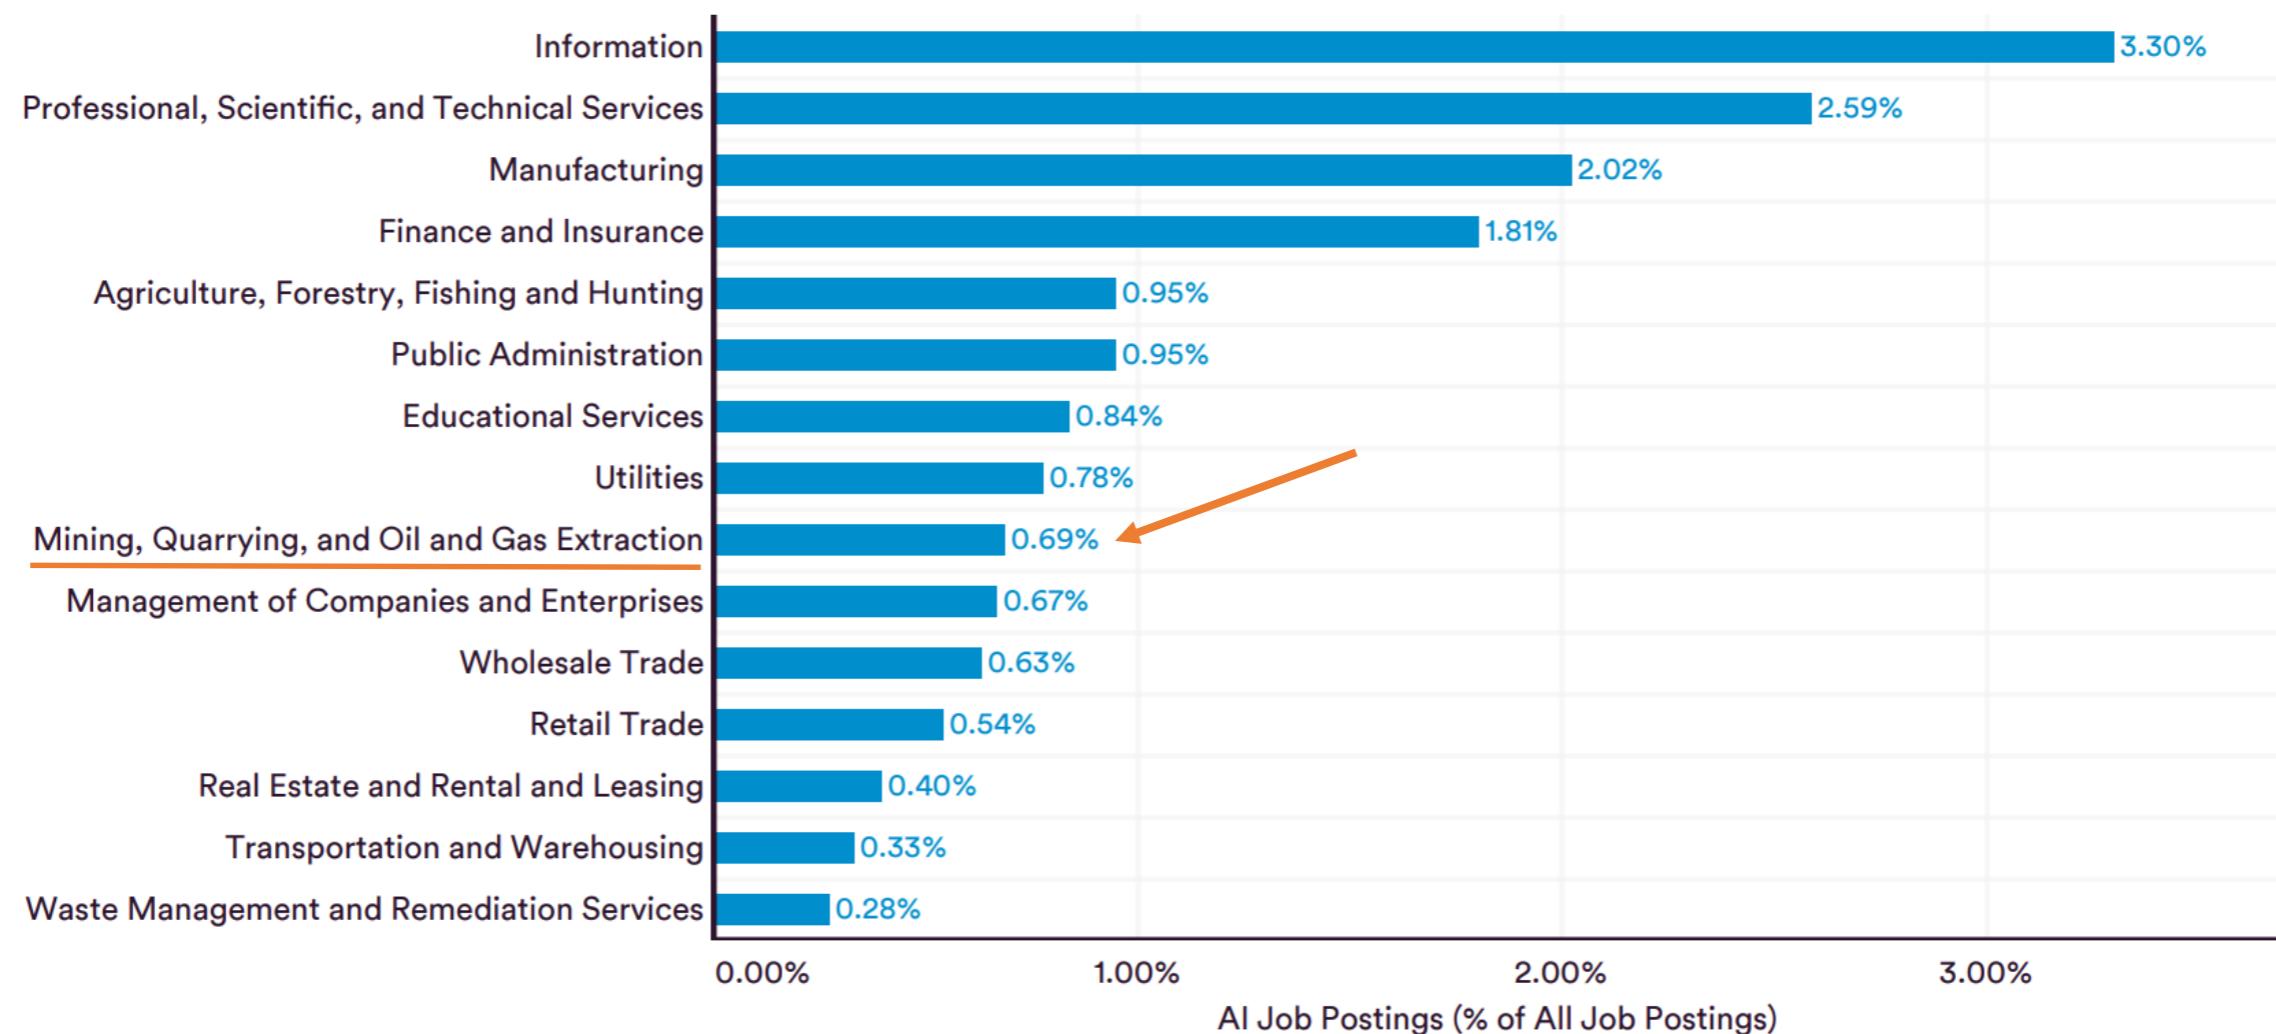
Source: LinkedIn, 2021 | Chart: 2022 AI Index Report



Porcentagem de vagas de trabalhos para IA por setor no US

AI JOB POSTINGS (% of ALL JOB POSTINGS) in the UNITED STATES by SECTOR, 2021

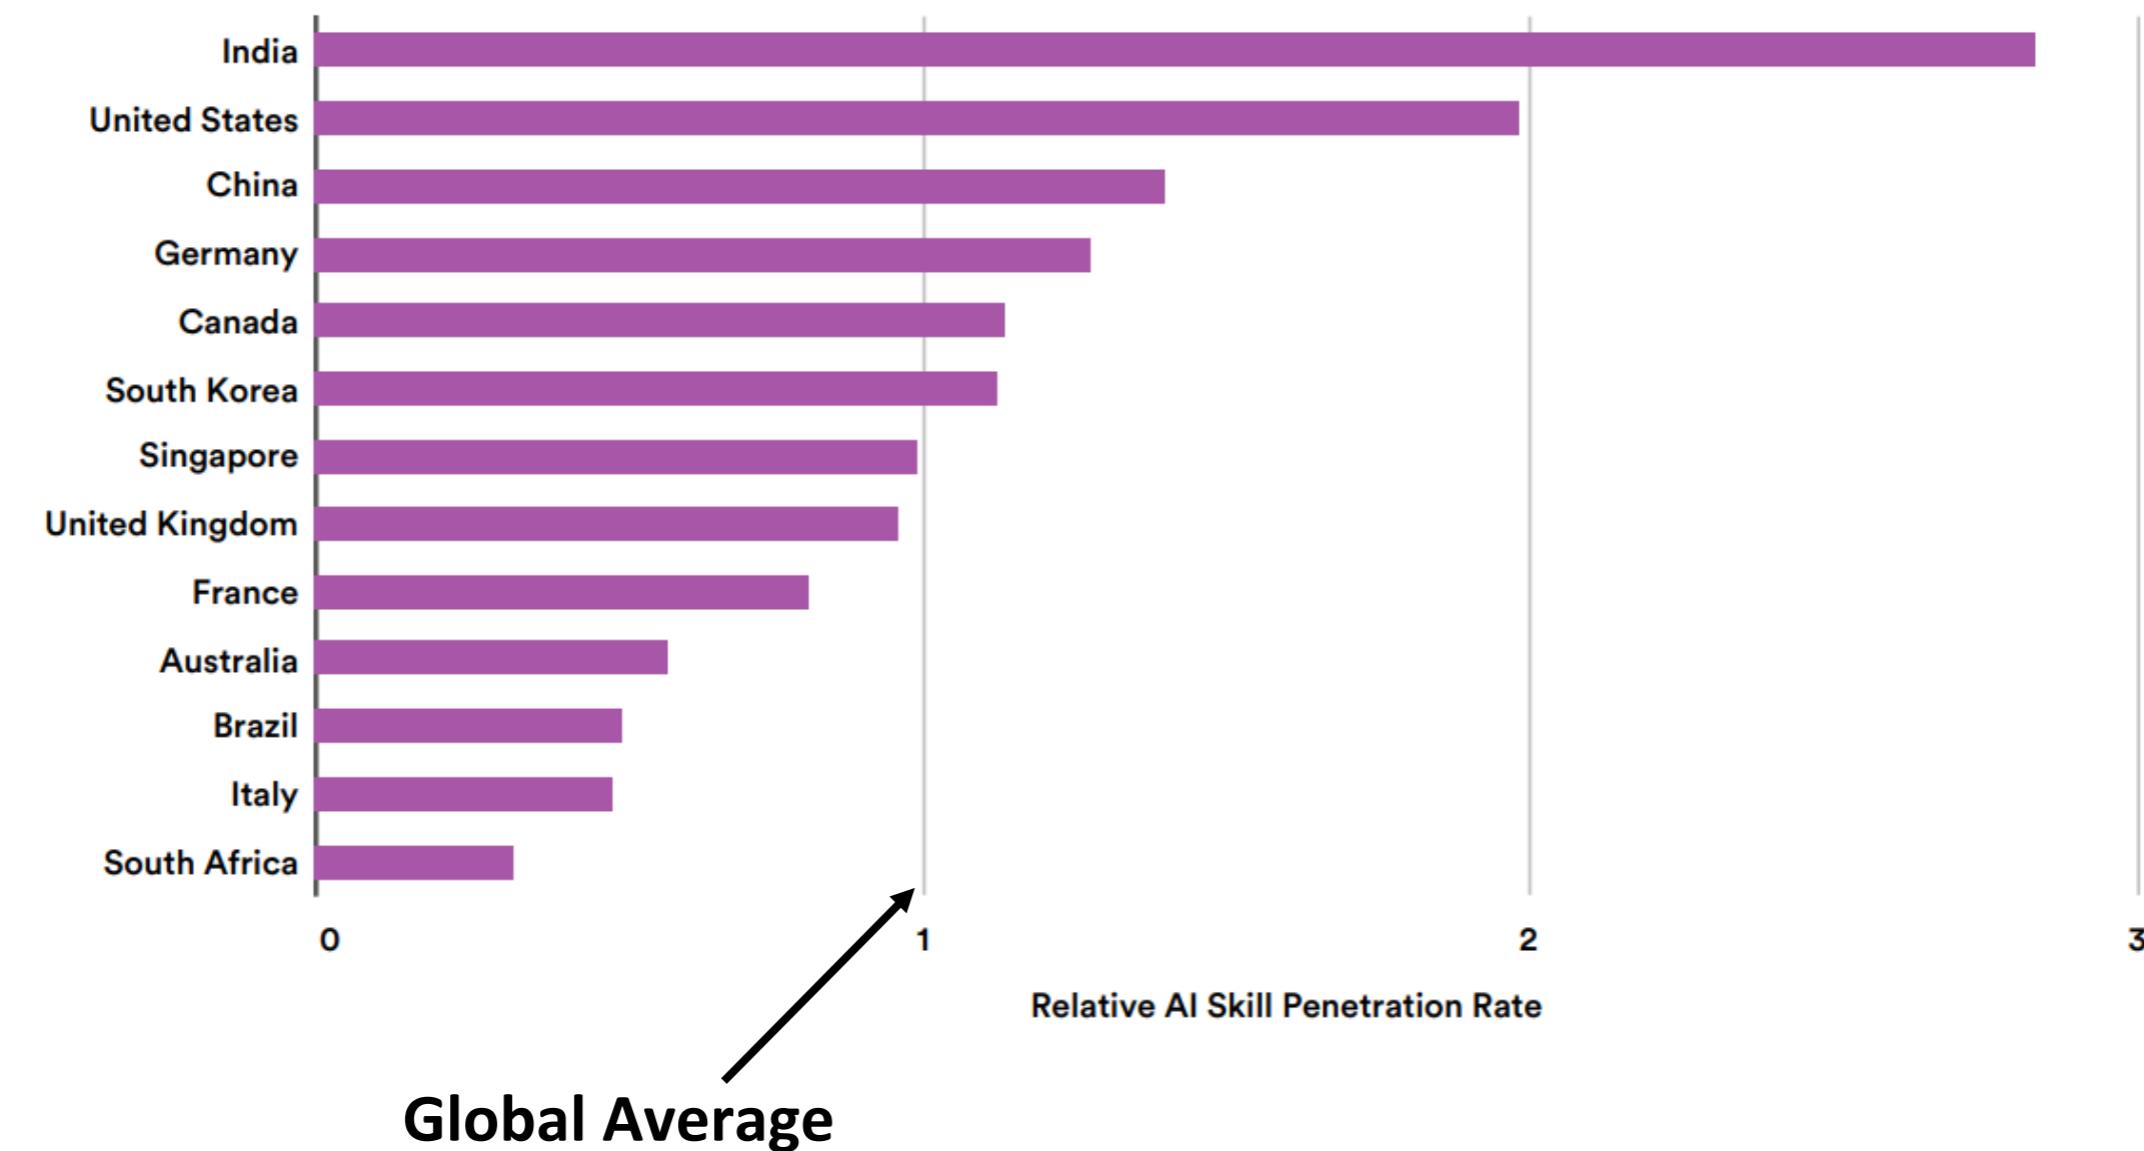
Source: Emsi Burning Glass, 2021 | Chart: 2022 AI Index Report



Importância da IA como habilidade (2020)

RELATIVE AI SKILL PENETRATION RATE by COUNTRY, 2015-20

Source: LinkedIn, 2020 | Chart: 2021 AI Index Report

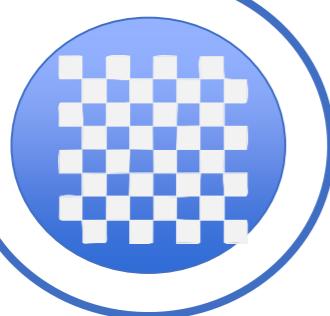


Marcos de desempenho da Inteligência Artificial a Nível Humano

1994

Chinook

O Programa **Chinnok** derrota o Campeão Mundial de Damas *Marion Tinsley*



1997



IBM DeepBlue

O Sistema **IBM's DeepBlue** Derrota o Campeão Mundial de Xadrez Gary Kasparov.

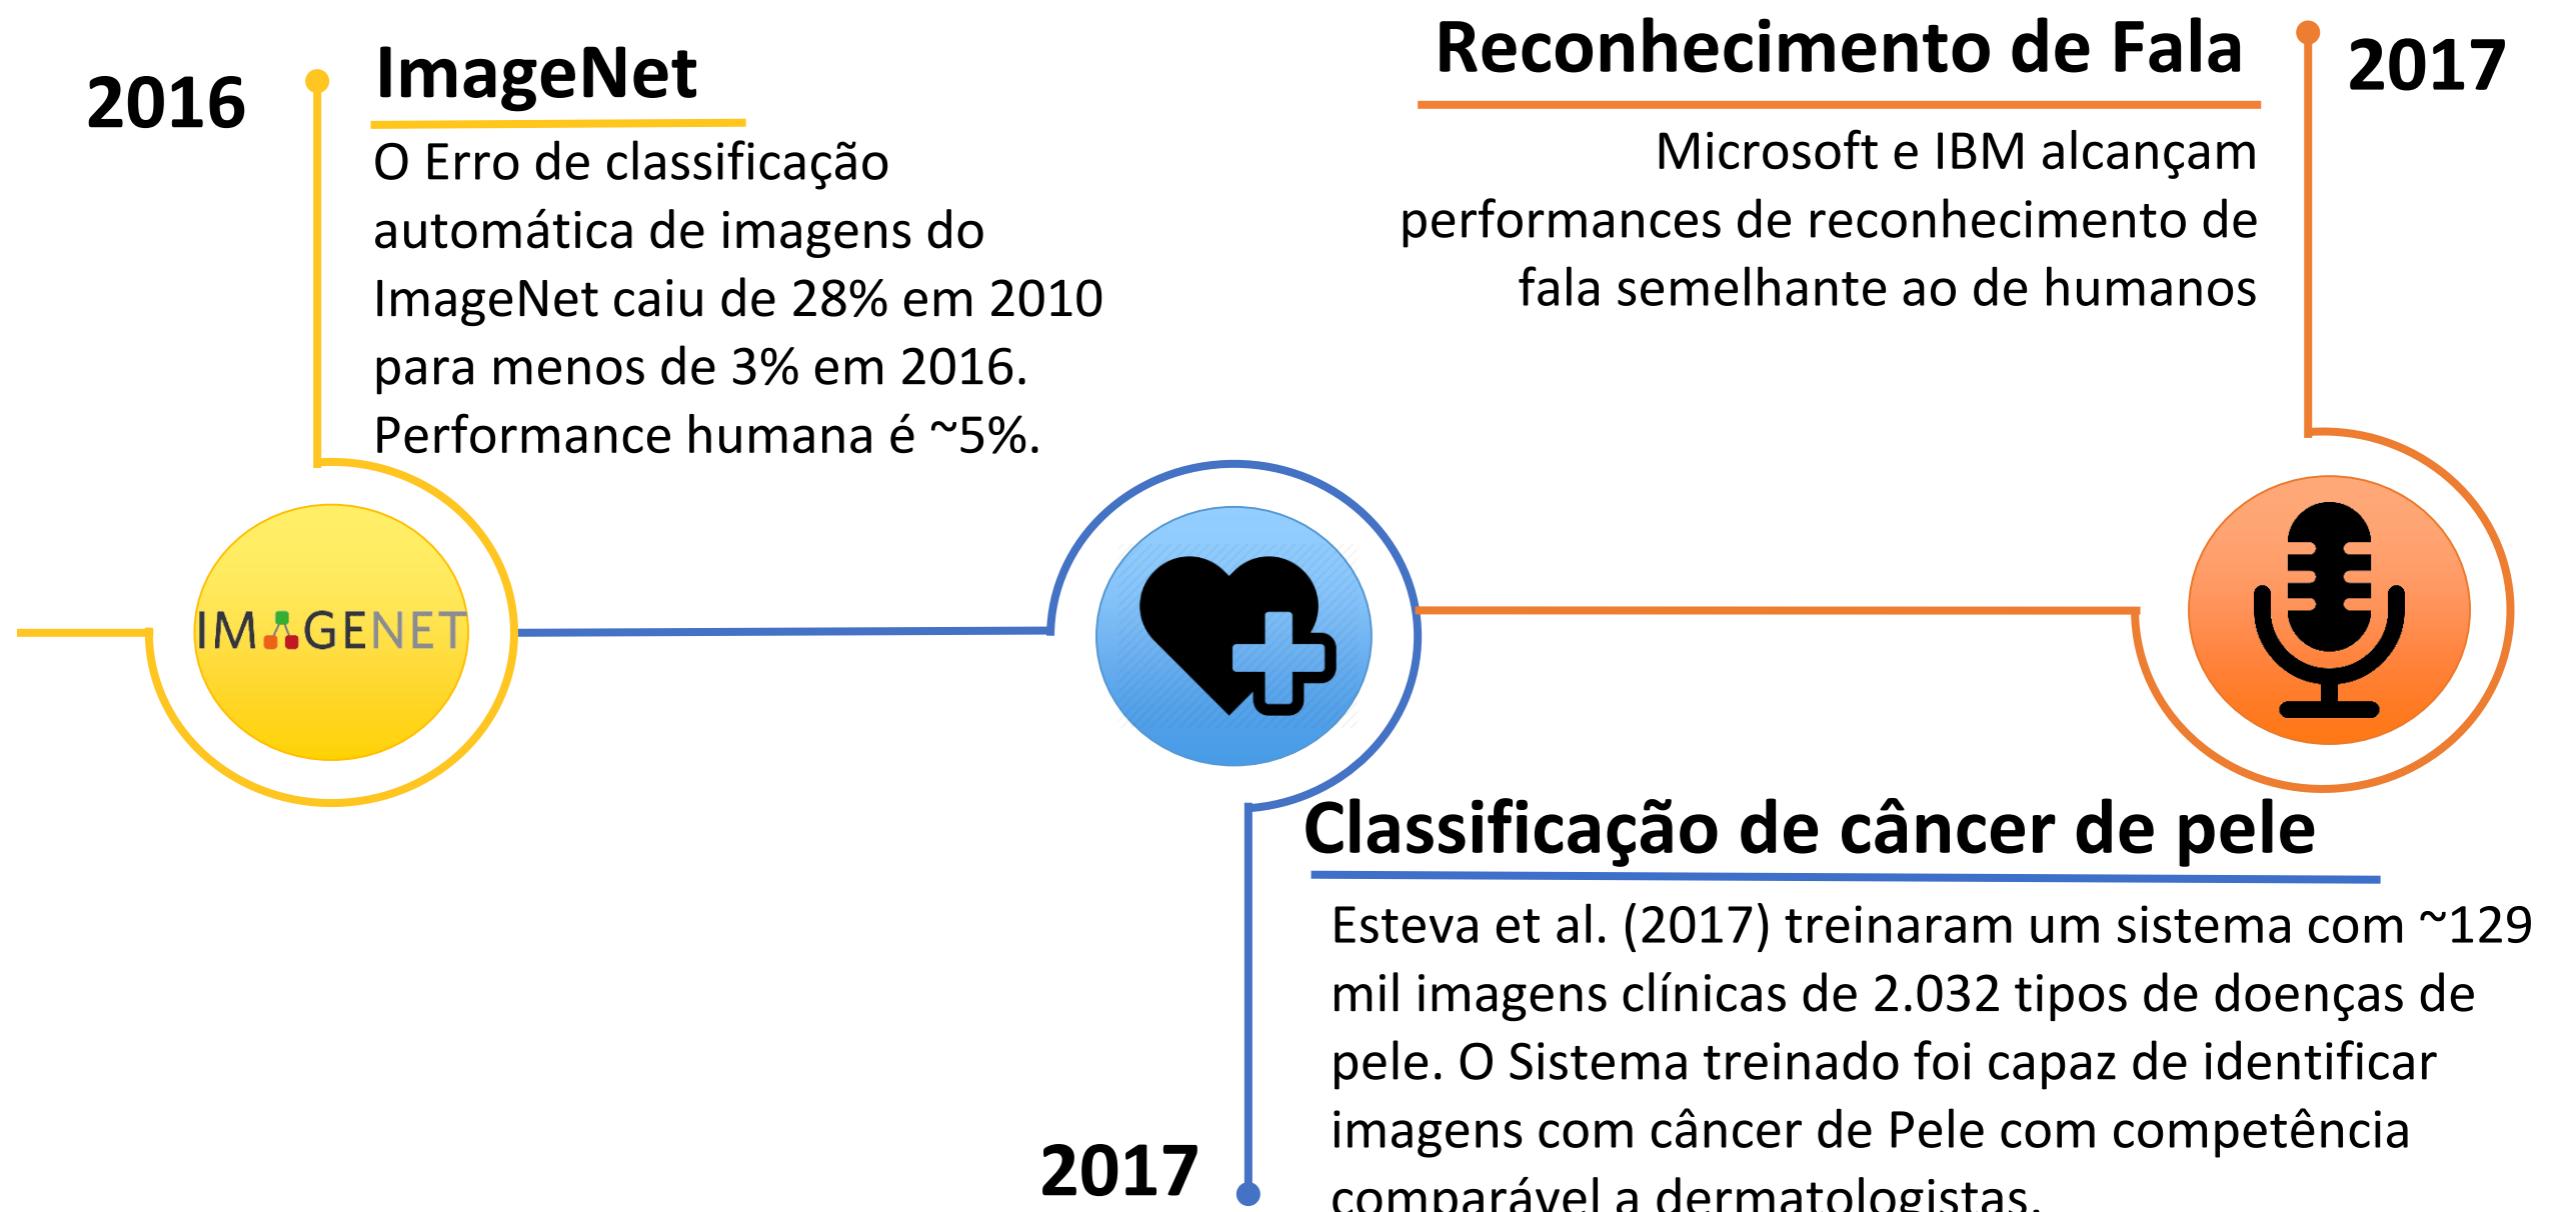
2015

Google DeepMind

Um time do **Google DeepMind** treinou um sistema para aprender como jogar 49 jogos de Atari. O Sistema conseguiu jogar em performance humana a maioria deles



Marcos de desempenho da Inteligência Artificial a Nível Humano



Marcos de desempenho da Inteligência Artificial a Nível Humano

2017

Libratus

O Sistema **Libratus**, criado nos Estados Unidos, derrotou os 4 melhores jogadores de um torneio de Poker que teve 120.000 partidas



2018



OpenAI Five

Um time de 5 redes neurais, chamado de **OpenAI Five**, venceu jogos de Dota2 contra jogadores amadores. O **OpenAI Five** aprendeu jogando partidas contra ele mesmo, equivalente a 180 anos de partidas por dia



Tradução Chinês - Inglês

A Microsoft desenvolveu um Sistema de tradução Chinês – Inglês com performance similar a humana

Marcos de desempenho da Inteligência Artificial a Nível Humano

2018

Google

A Google desenvolveu um sistema de detecção de câncer de próstata com acurácia de 70%. A média de precisão alcançada por patologistas gerais certificados pelos EUA era de 61%.



2018



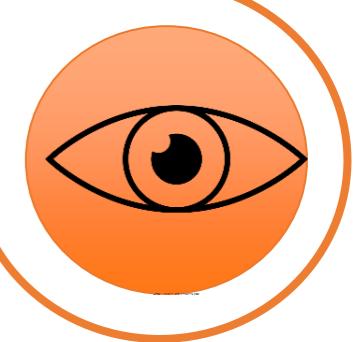
AlphaFold

A organização *DeepMind* desenvolveu o sistema **AlphaFold**, que utilizou dados de sequências geométricas para prever a estruturas 3D de proteínas

2019

Retinopatia diabética

Pesquisadores desenvolveram um sistema de *Deep Learning* capaz de detectar **Retinopatia Diabética** com acurácia comparada a especialistas



O que é Machine Learning?

Definição de Machine Learning

Machine learning (ou aprendizado de máquina) é o uso e o desenvolvimento de sistemas computacionais que sejam capazes de aprender e se adaptar sem seguir instruções explícitas, usando algoritmos e modelos estatísticos para analisar e fazer inferências a partir de padrões de dados.



O que é Machine Learning?

Machine learning é comumente visto como:

Algo complexo



Algo sofisticado



Algo futurista



O que é Machine Learning?

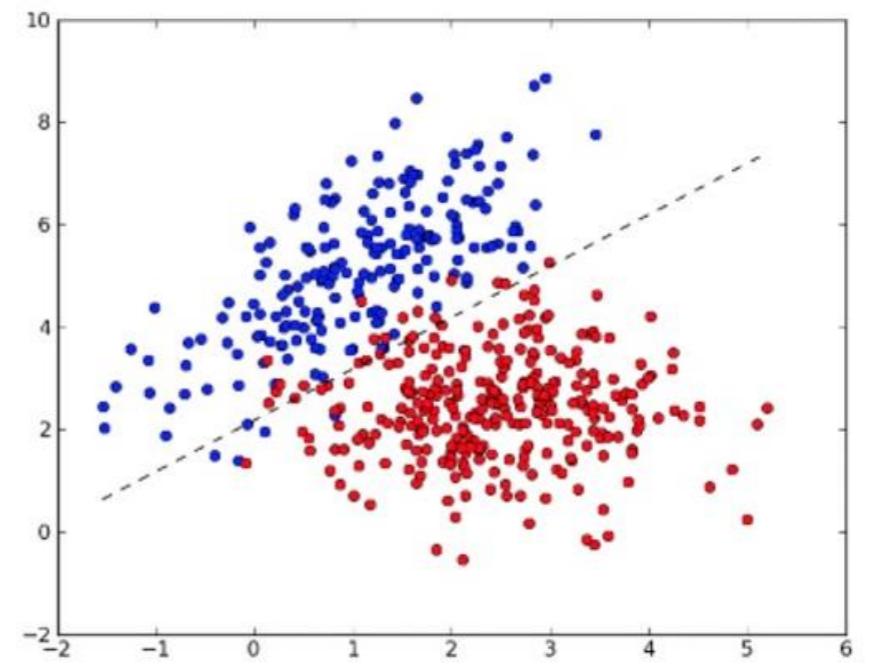
Alguns problemas:

- Estas definições não exatamente definem como o *Machine Learning* realmente funciona
- Estas definições são ótimas para pessoas leigas no assunto, mas não para estudantes de Machine Learning!

O que é Machine Learning?

Machine Learning is nothing but a geometry problem!!

(Lazy Programmer)

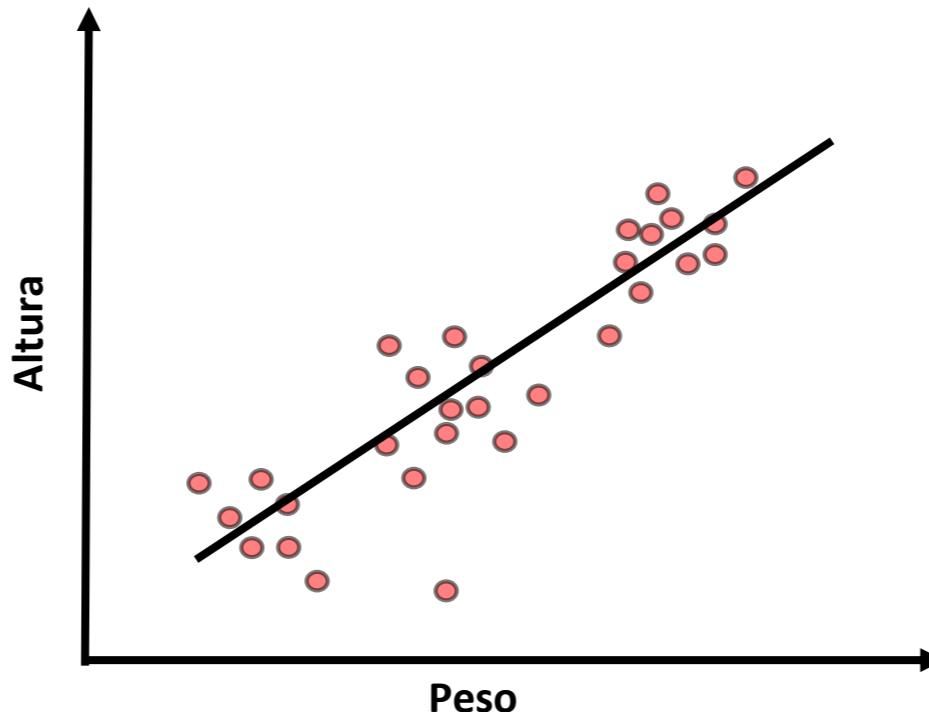


O que é Machine Learning?

Exemplo: Regressão

Geometria?!

- Regressão basicamente é a tentativa de ajustar dados por linhas, curvas, planos, etc.
- Estatísticos mais antigos: "Machine Learning é somente um ajuste de curva glorificado"



O que é Machine Learning?

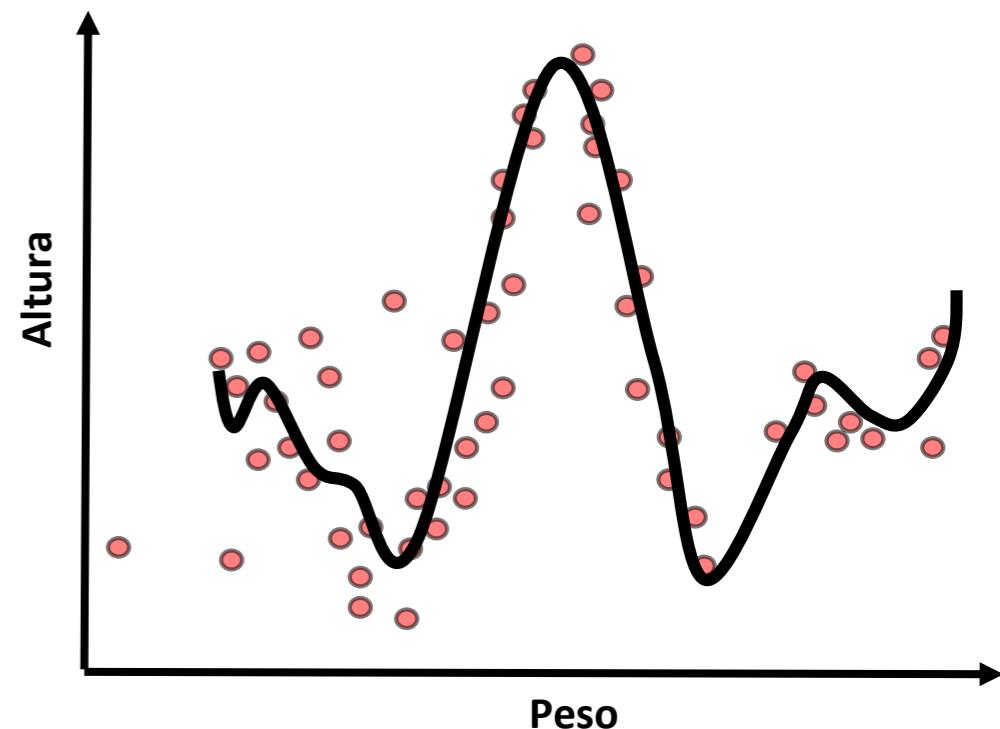
Exemplo: Regressão

Algumas vezes os dados não podem ser representados por uma reta

Mas podemos procurar um polinômio que ajusta melhor os dados

Ou seja,

Machine Learning ainda é um problema geométrico!!



O que é Machine Learning?

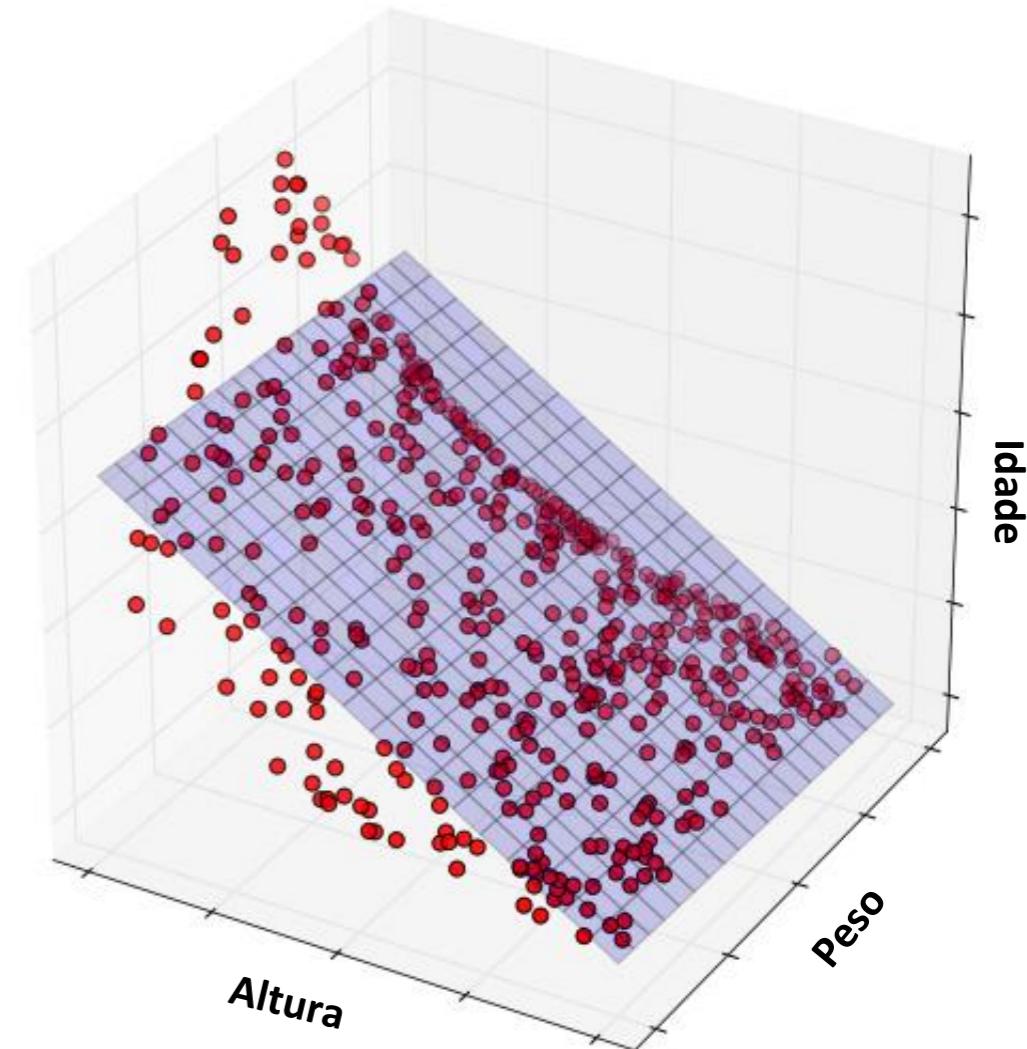
Exemplo: Regressão

Algumas vezes os dados possuem mais de 2 características

Mas ainda podemos procurar uma feição geométrica
que ajusta melhor os dados

Ou seja,

Machine Learning ainda é um problema geométrico!!



O que é Machine Learning?

Exemplo: Regressão

Nota!

Algumas vezes os dados possuem mais de 2 características

Quando temos um dado com 3 variáveis (ou 3 dimensões),

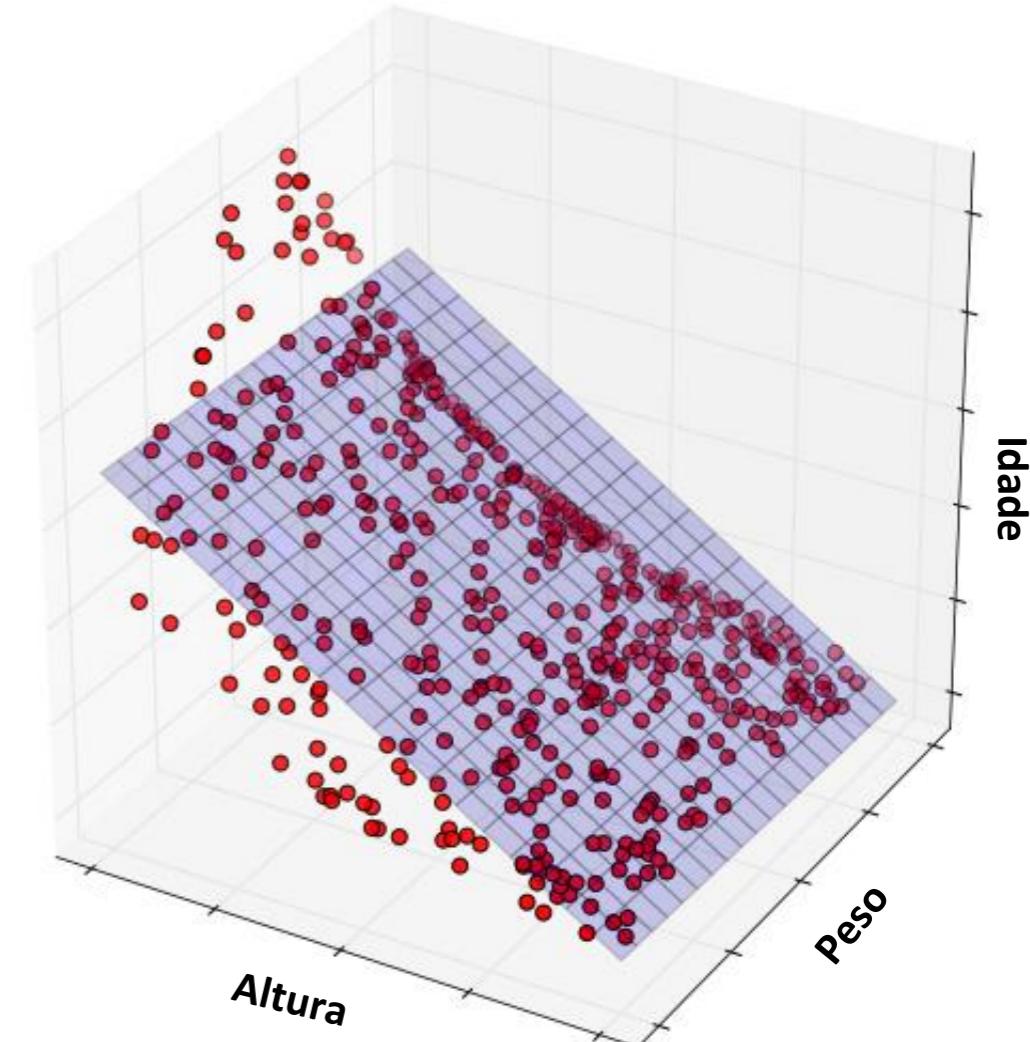
ajustamos um plano ao invés de uma reta (2D)

Mas podemos procurar um polinômio que ajusta melhor os dados

Quando temos mais de 3 variáveis, podemos dizer que ajustamos o dado a um “hiperplano”, que possui dimensão $n-1$.

Exemplo: Machine Learning ainda é um problema geométrico!!

- **Dado 2D – ajustamos uma reta 1D**
- **Dados 3D – ajustamos um plano 2D**



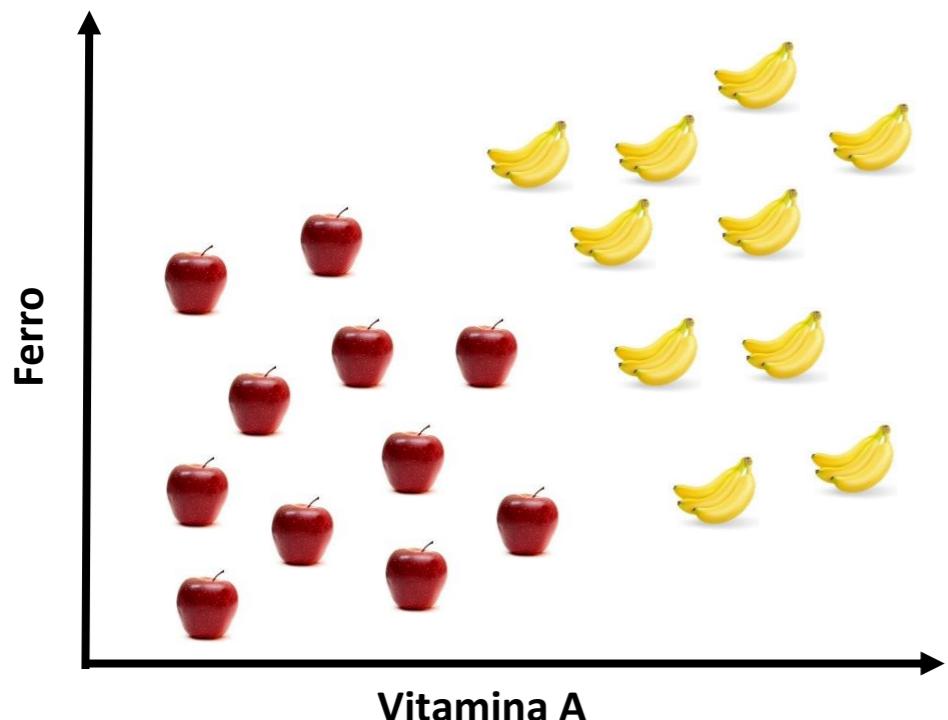
O que é Machine Learning?

Exemplo: Classificação



O que é Machine Learning?

Exemplo: Classificação



Maçã

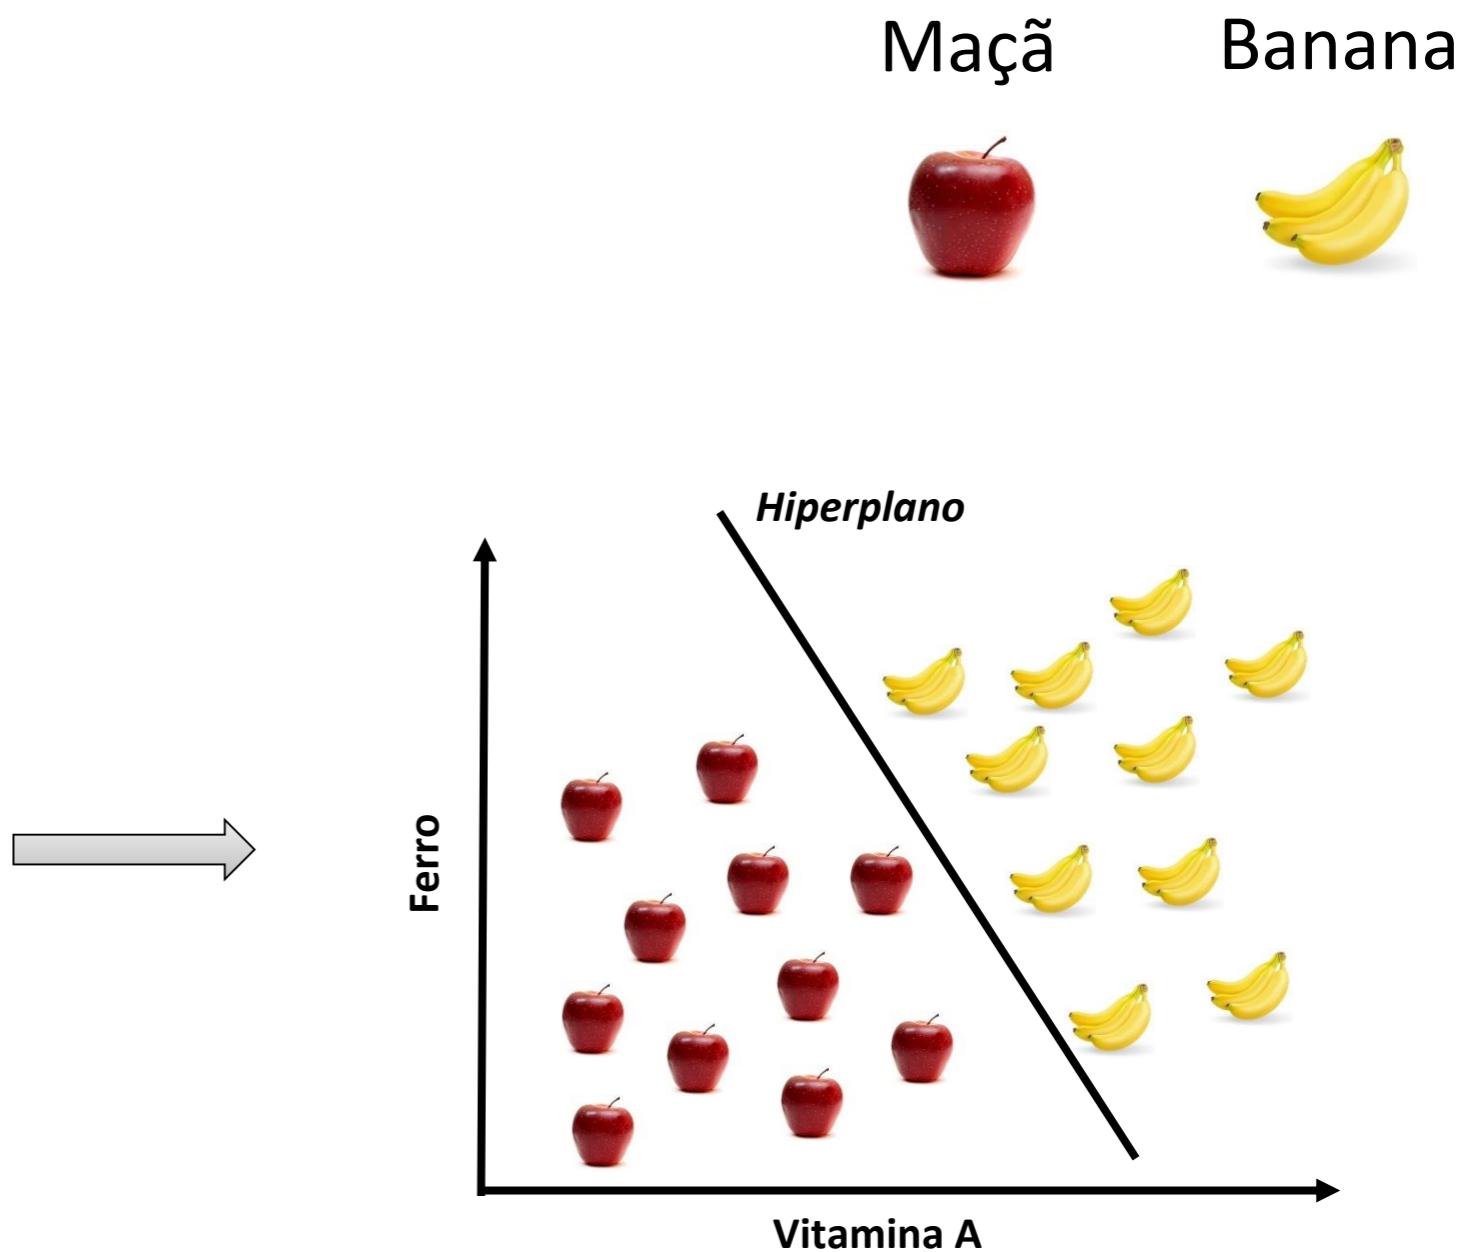
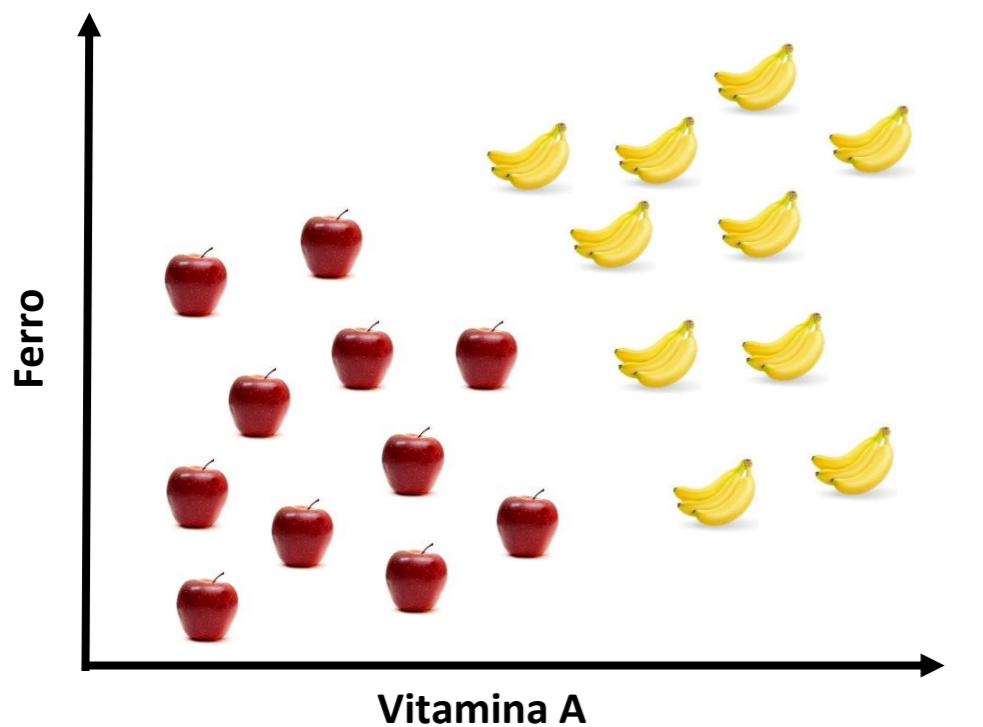


Banana



O que é Machine Learning?

Exemplo: Classificação



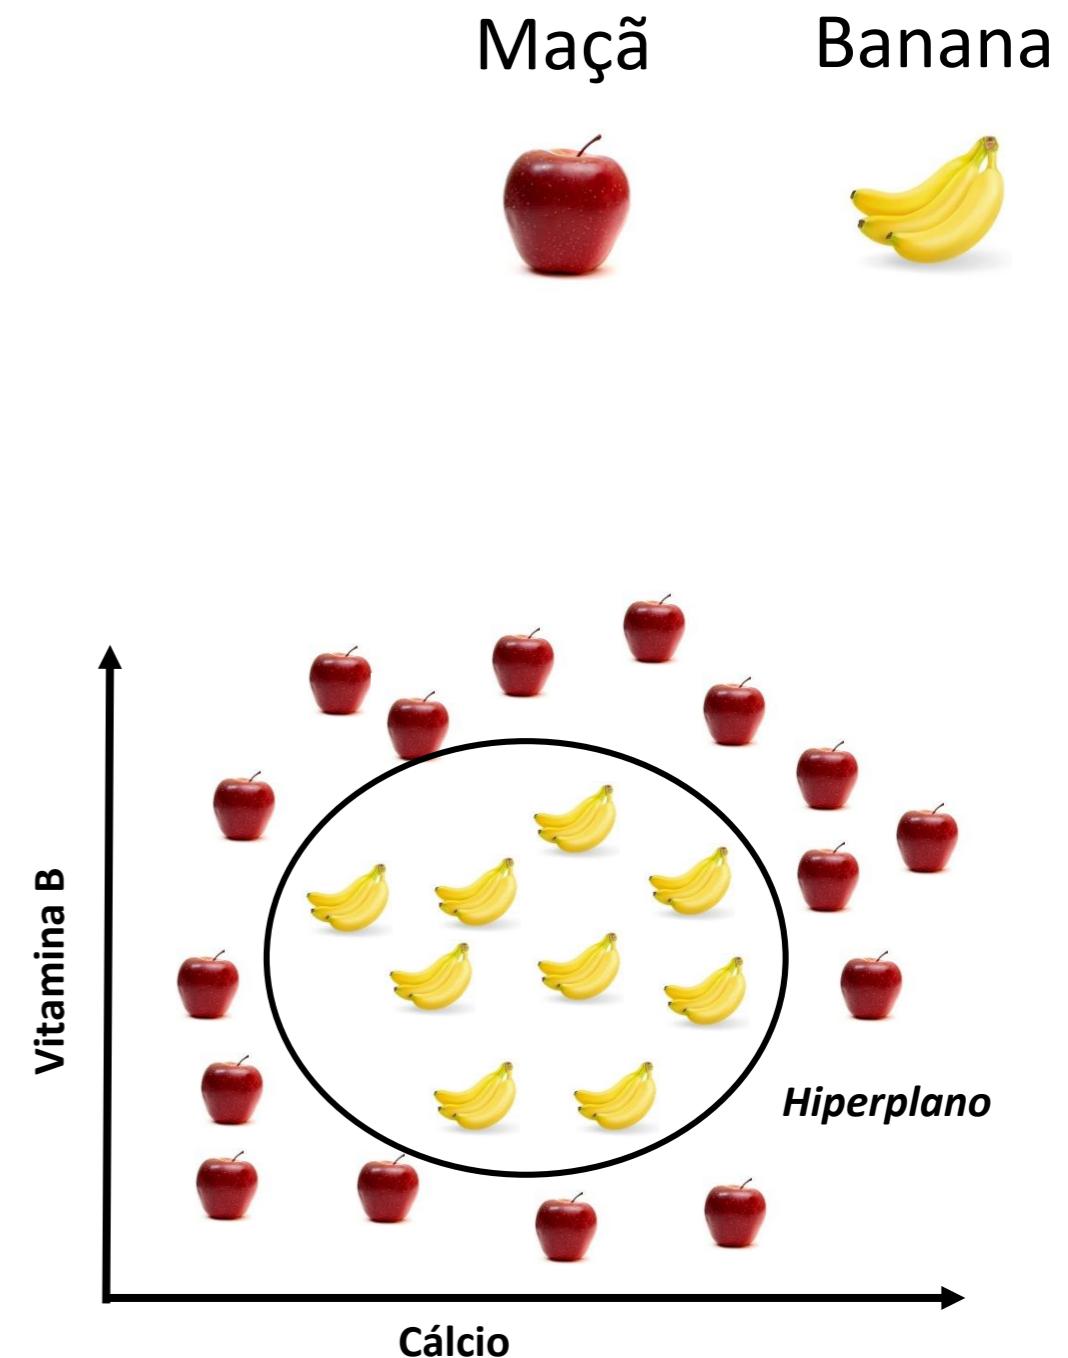
O que é Machine Learning?

Exemplo: Classificação

Assim como a regressão, a classificação pode ser mais complexa (não-linear).

Ainda sim,

Machine Learning ainda é um problema geométrico!!

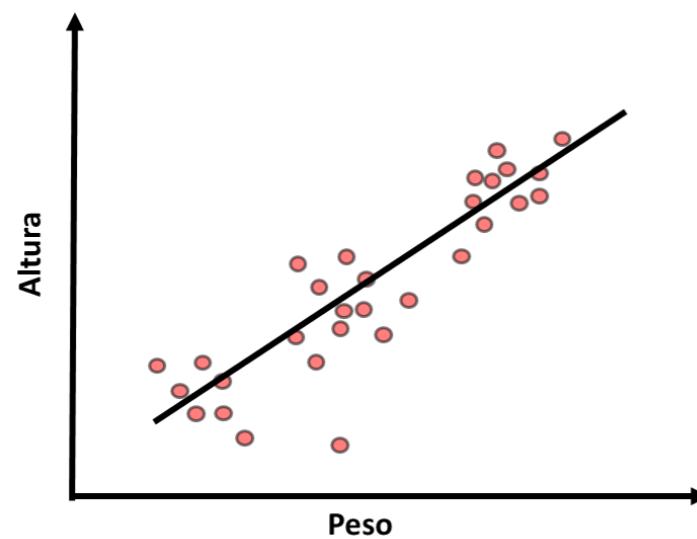


Ensinando a Máquina

Resumo

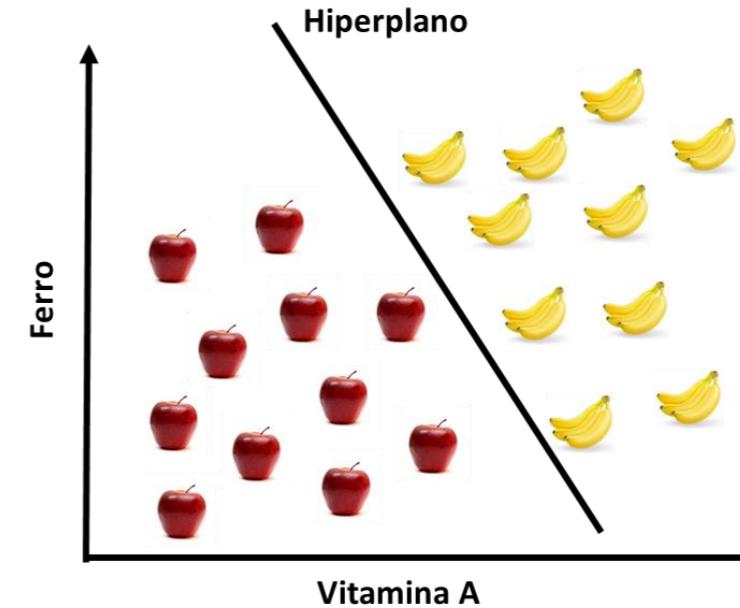
Regressão

Ajustamos as linhas/curvas (hiperplanos) o mais próximo possível dos dados



Classificação

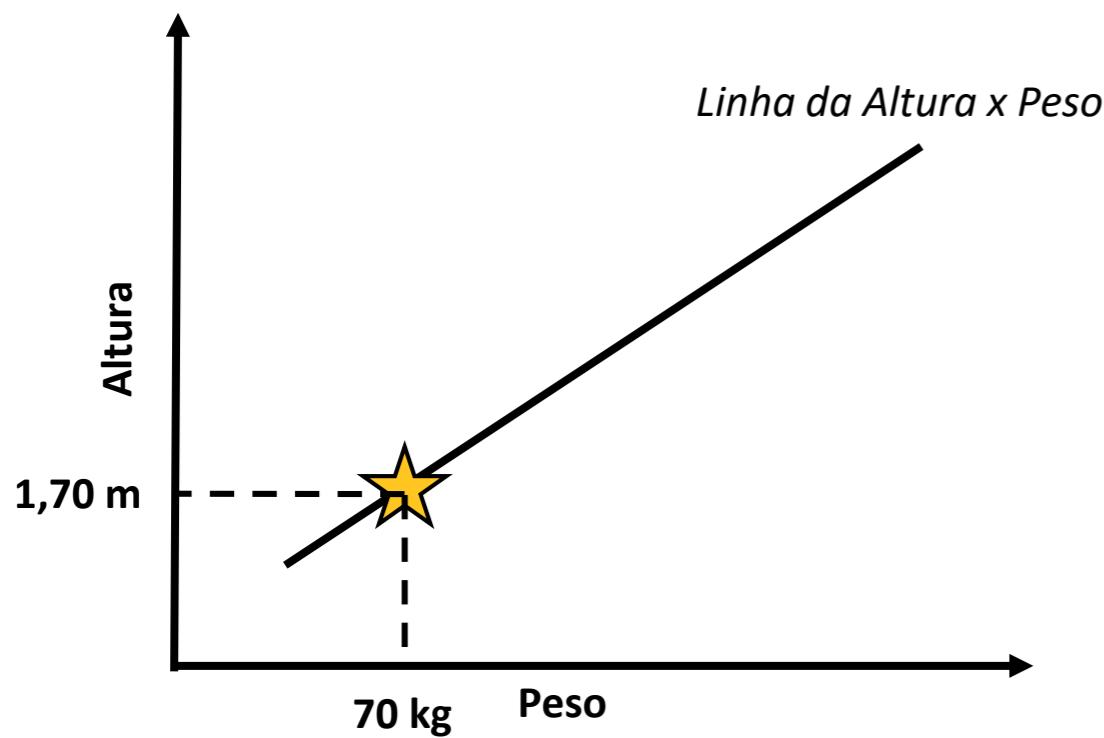
Ajustamos as linhas/curvas (hiperplanos) de tal forma que melhor separe os tipos de dados



O que é Machine Learning?

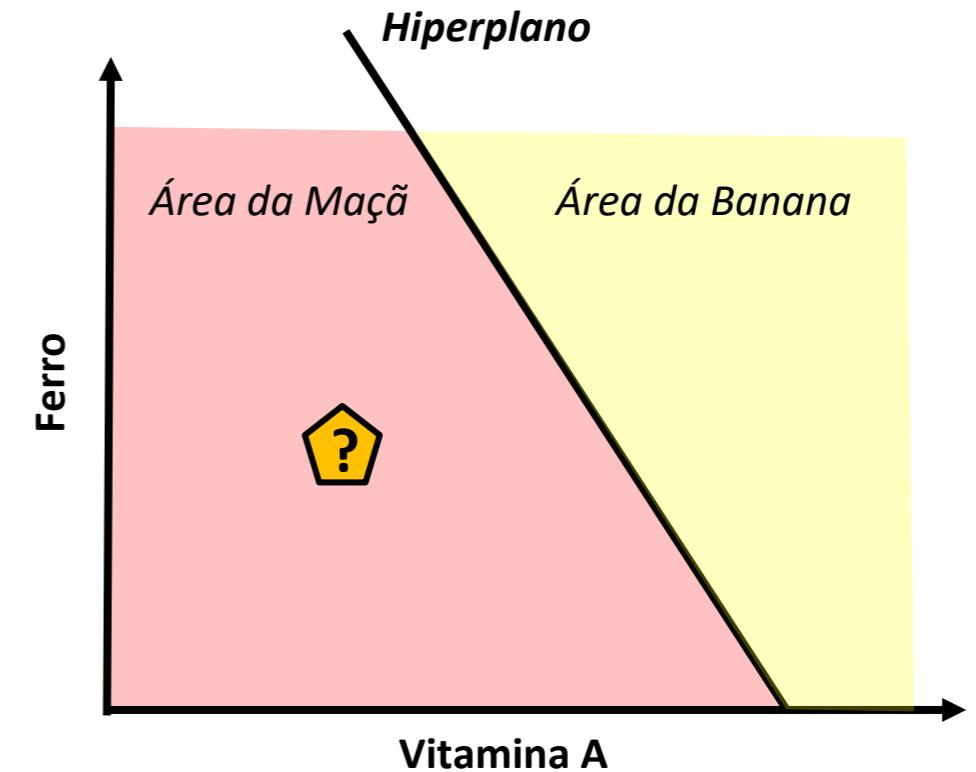
Regressão

Ajustamos as linhas/curvas (hiperplanos) o mais próximo possível dos dados



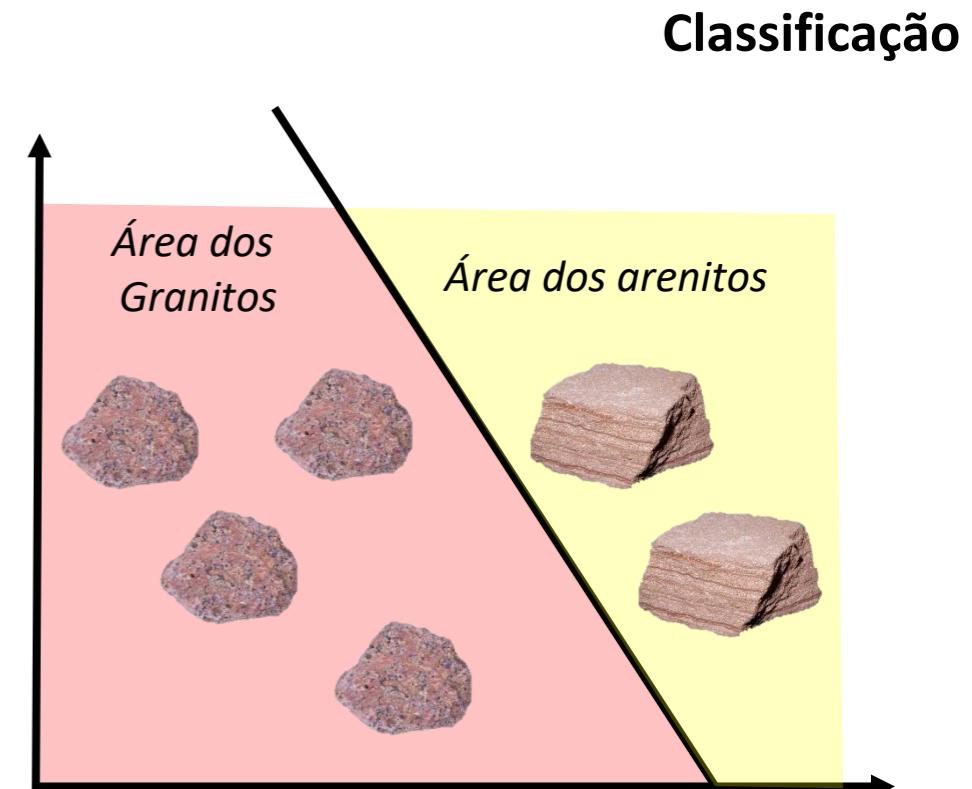
Classificação

Ajustamos as linhas/curvas (hiperplanos) de tal forma que melhor separe os tipos de dados

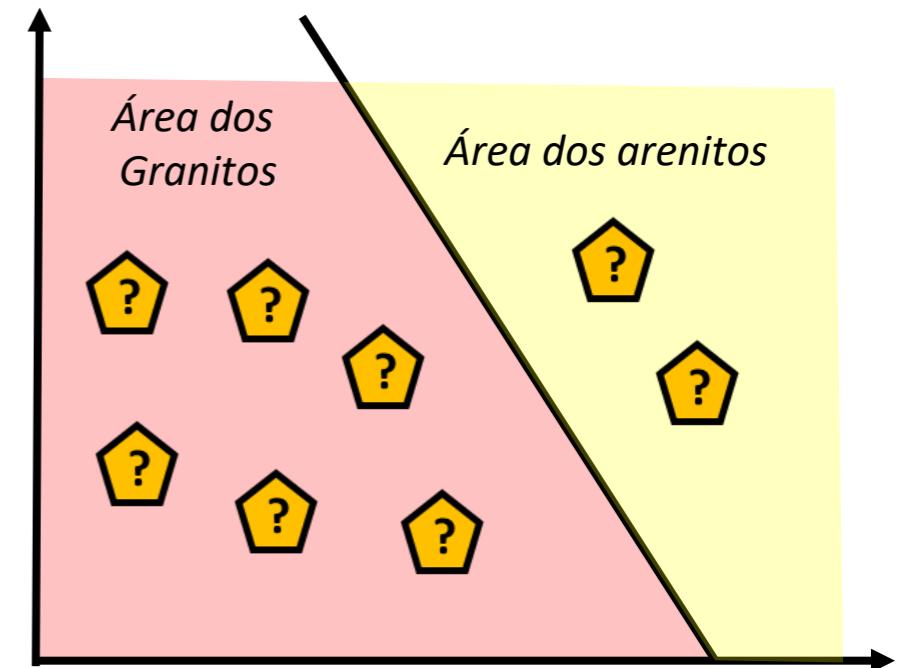


Então, o que iremos aprender neste curso??

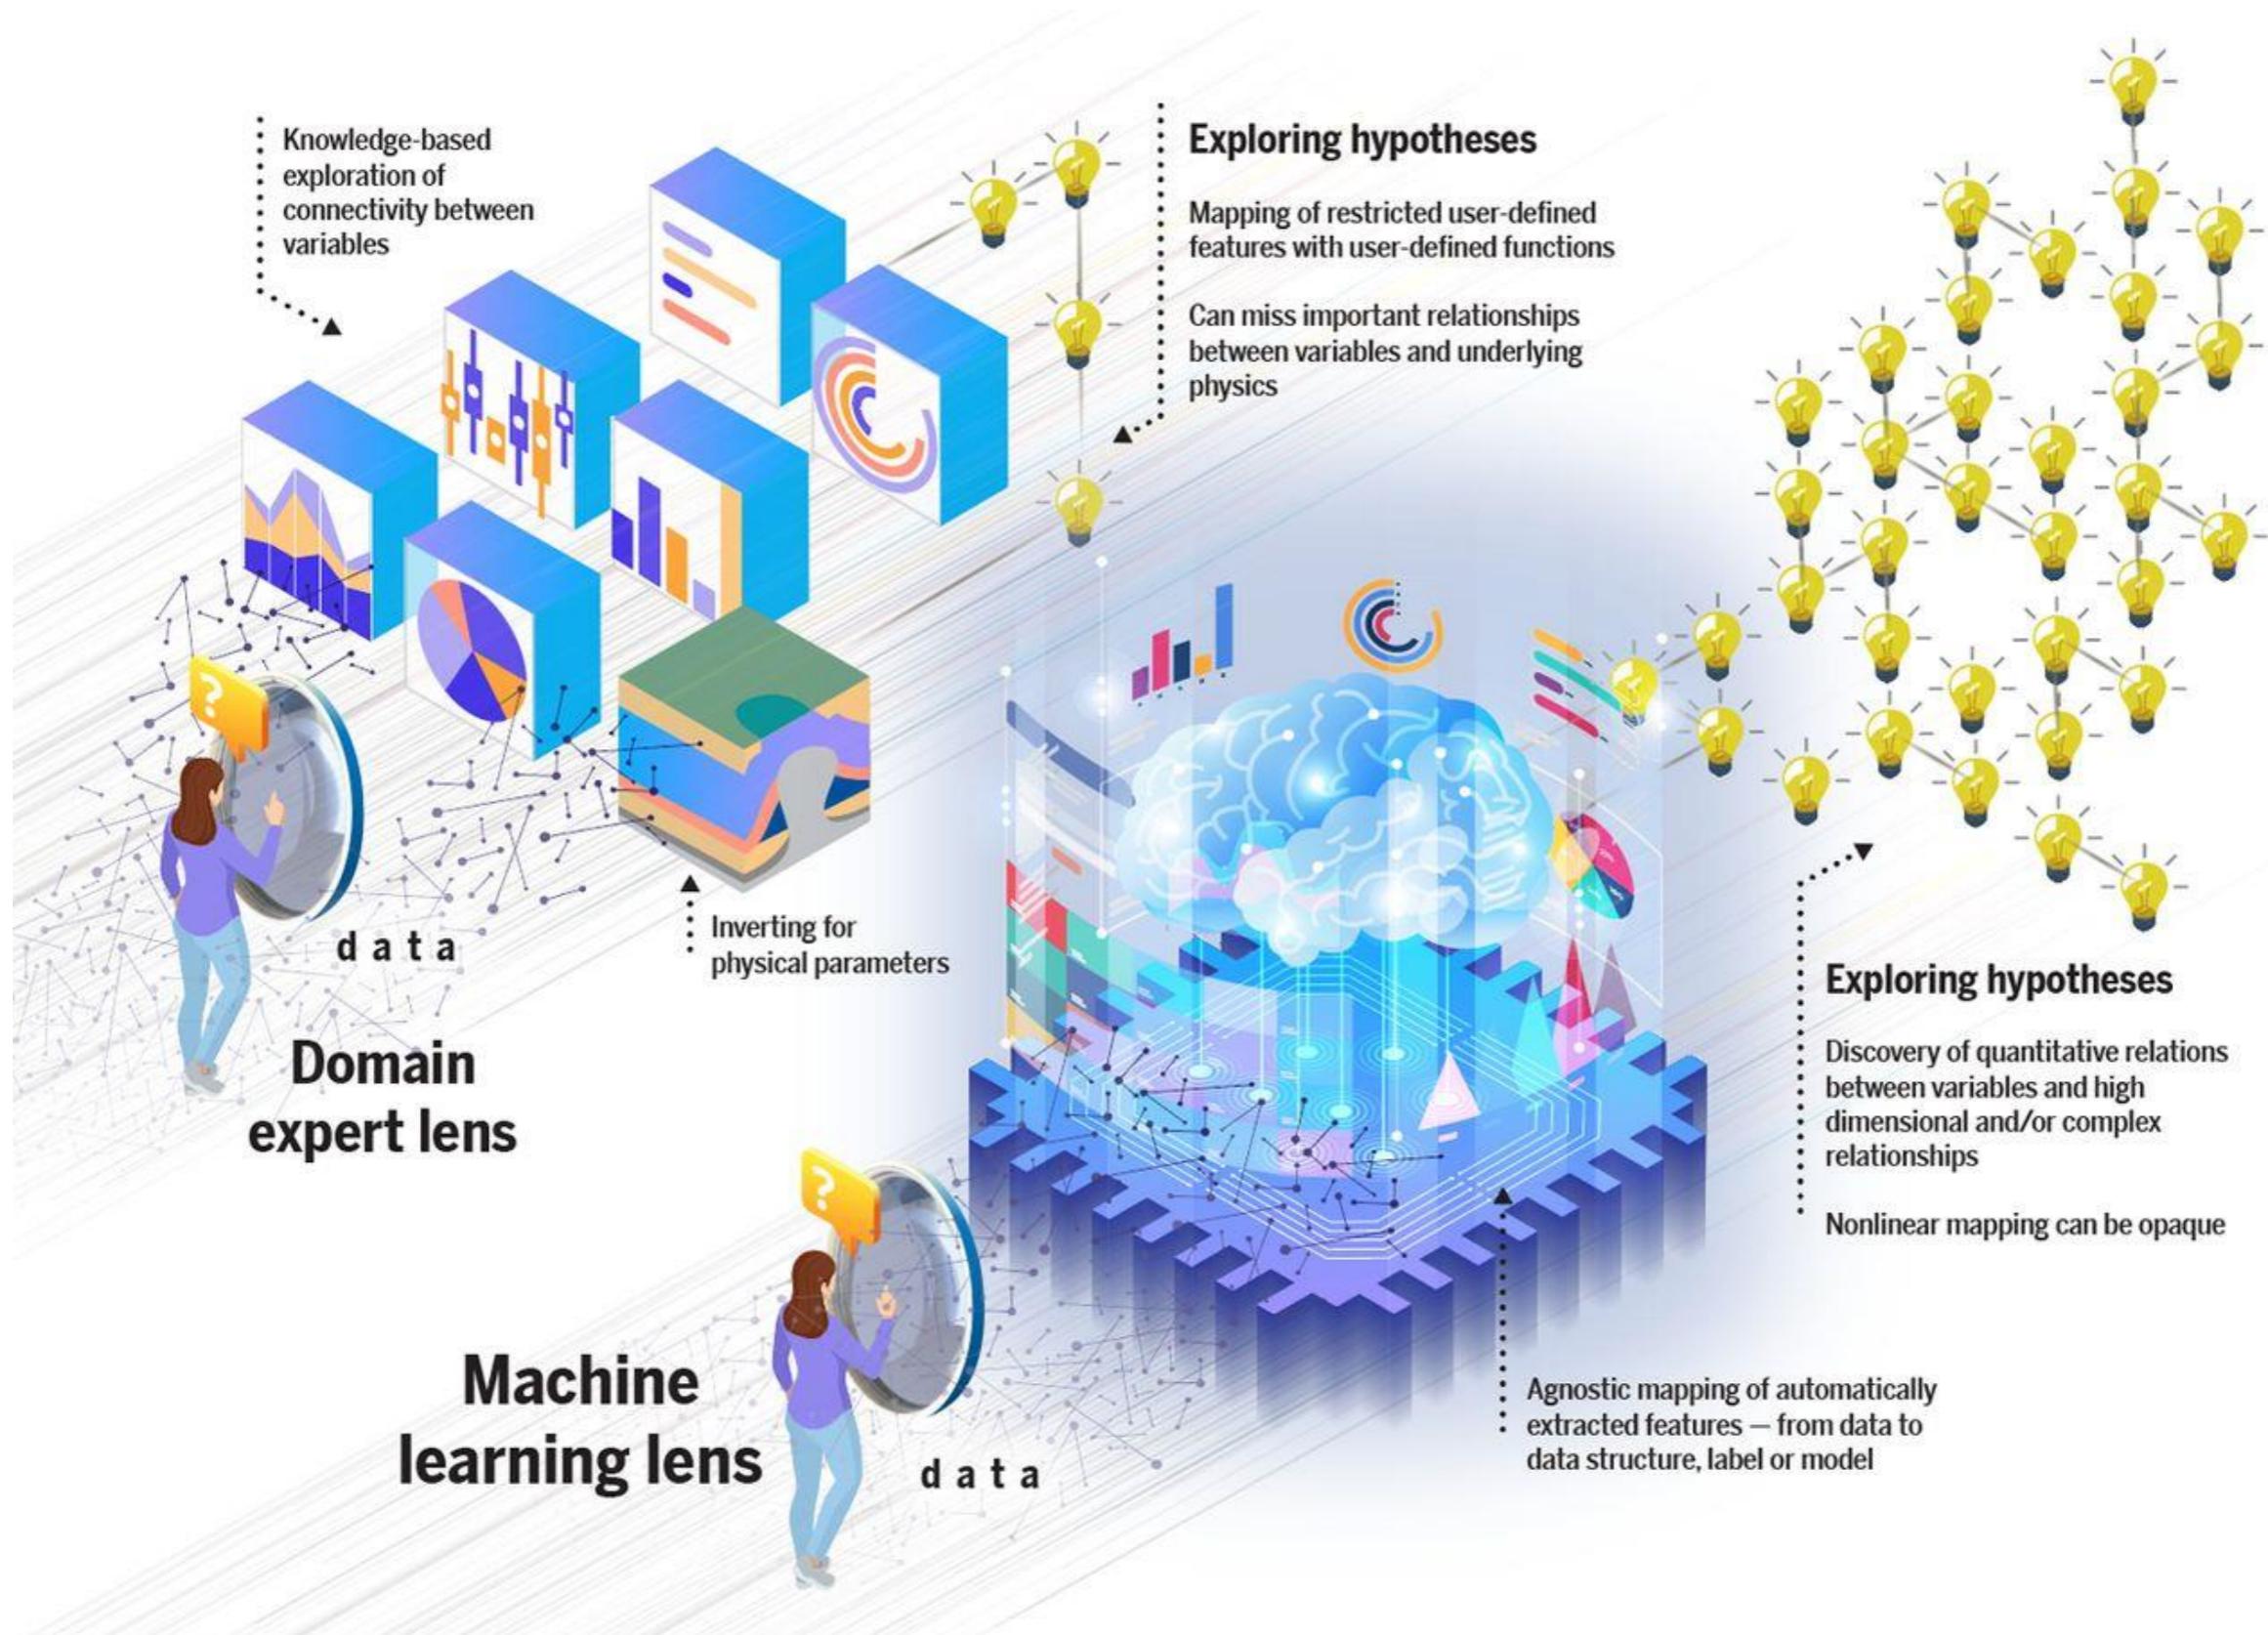
1) Treinar modelos de ML para definir quais as características de sensores remotos para cada litologia



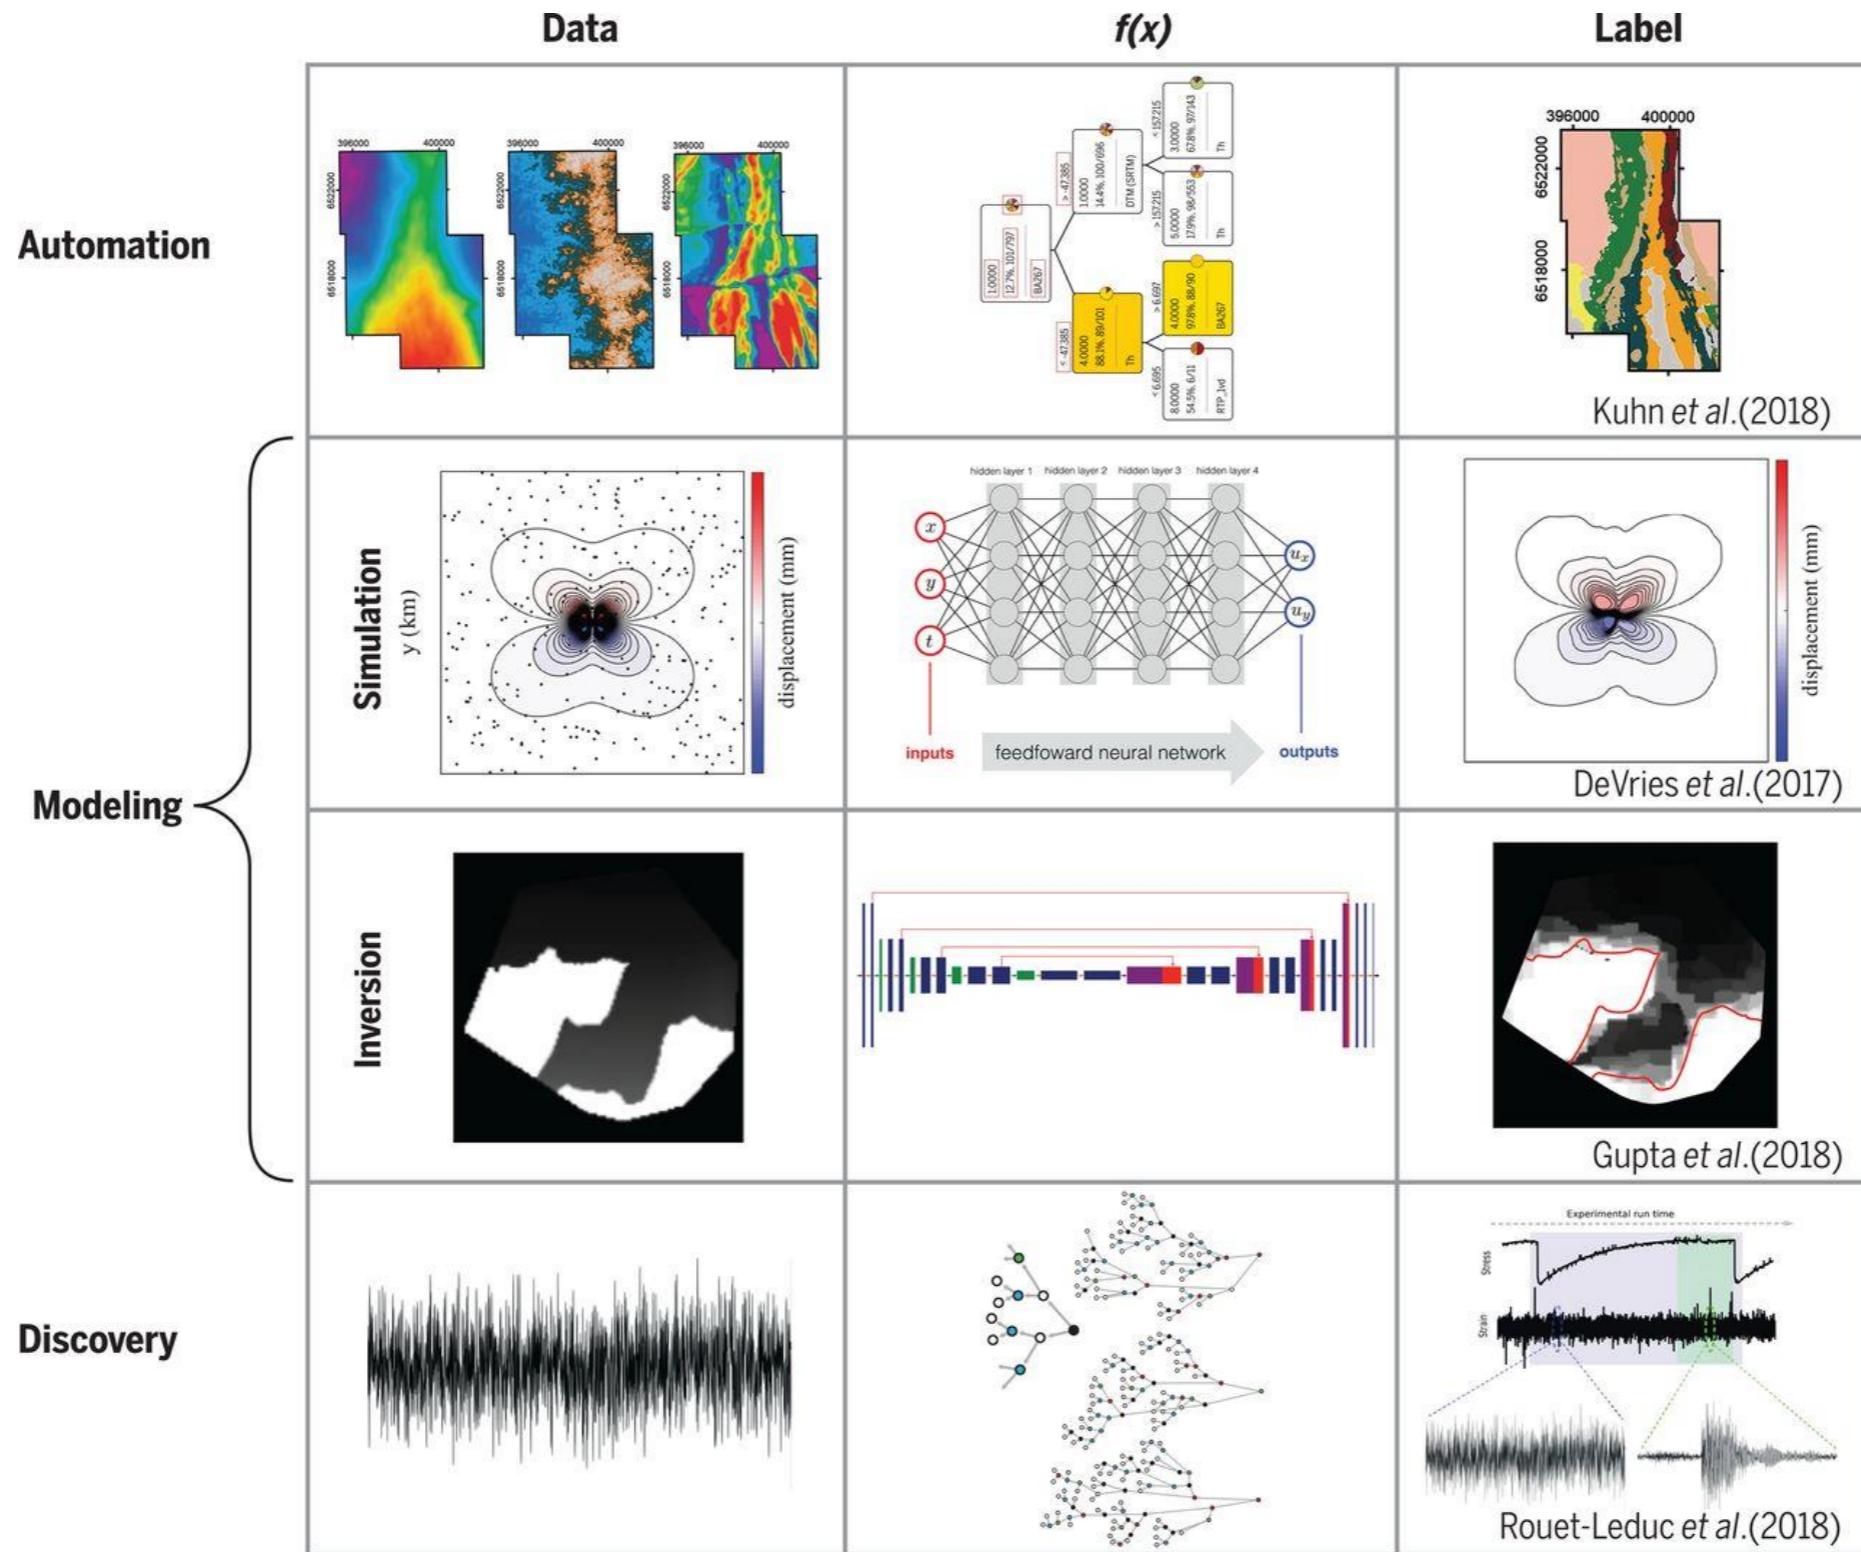
2) Utilizar esses modelos treinados em locais que não sabemos a litologia, para averiguar a qual litologia pré-treinada eles mais se assemelham



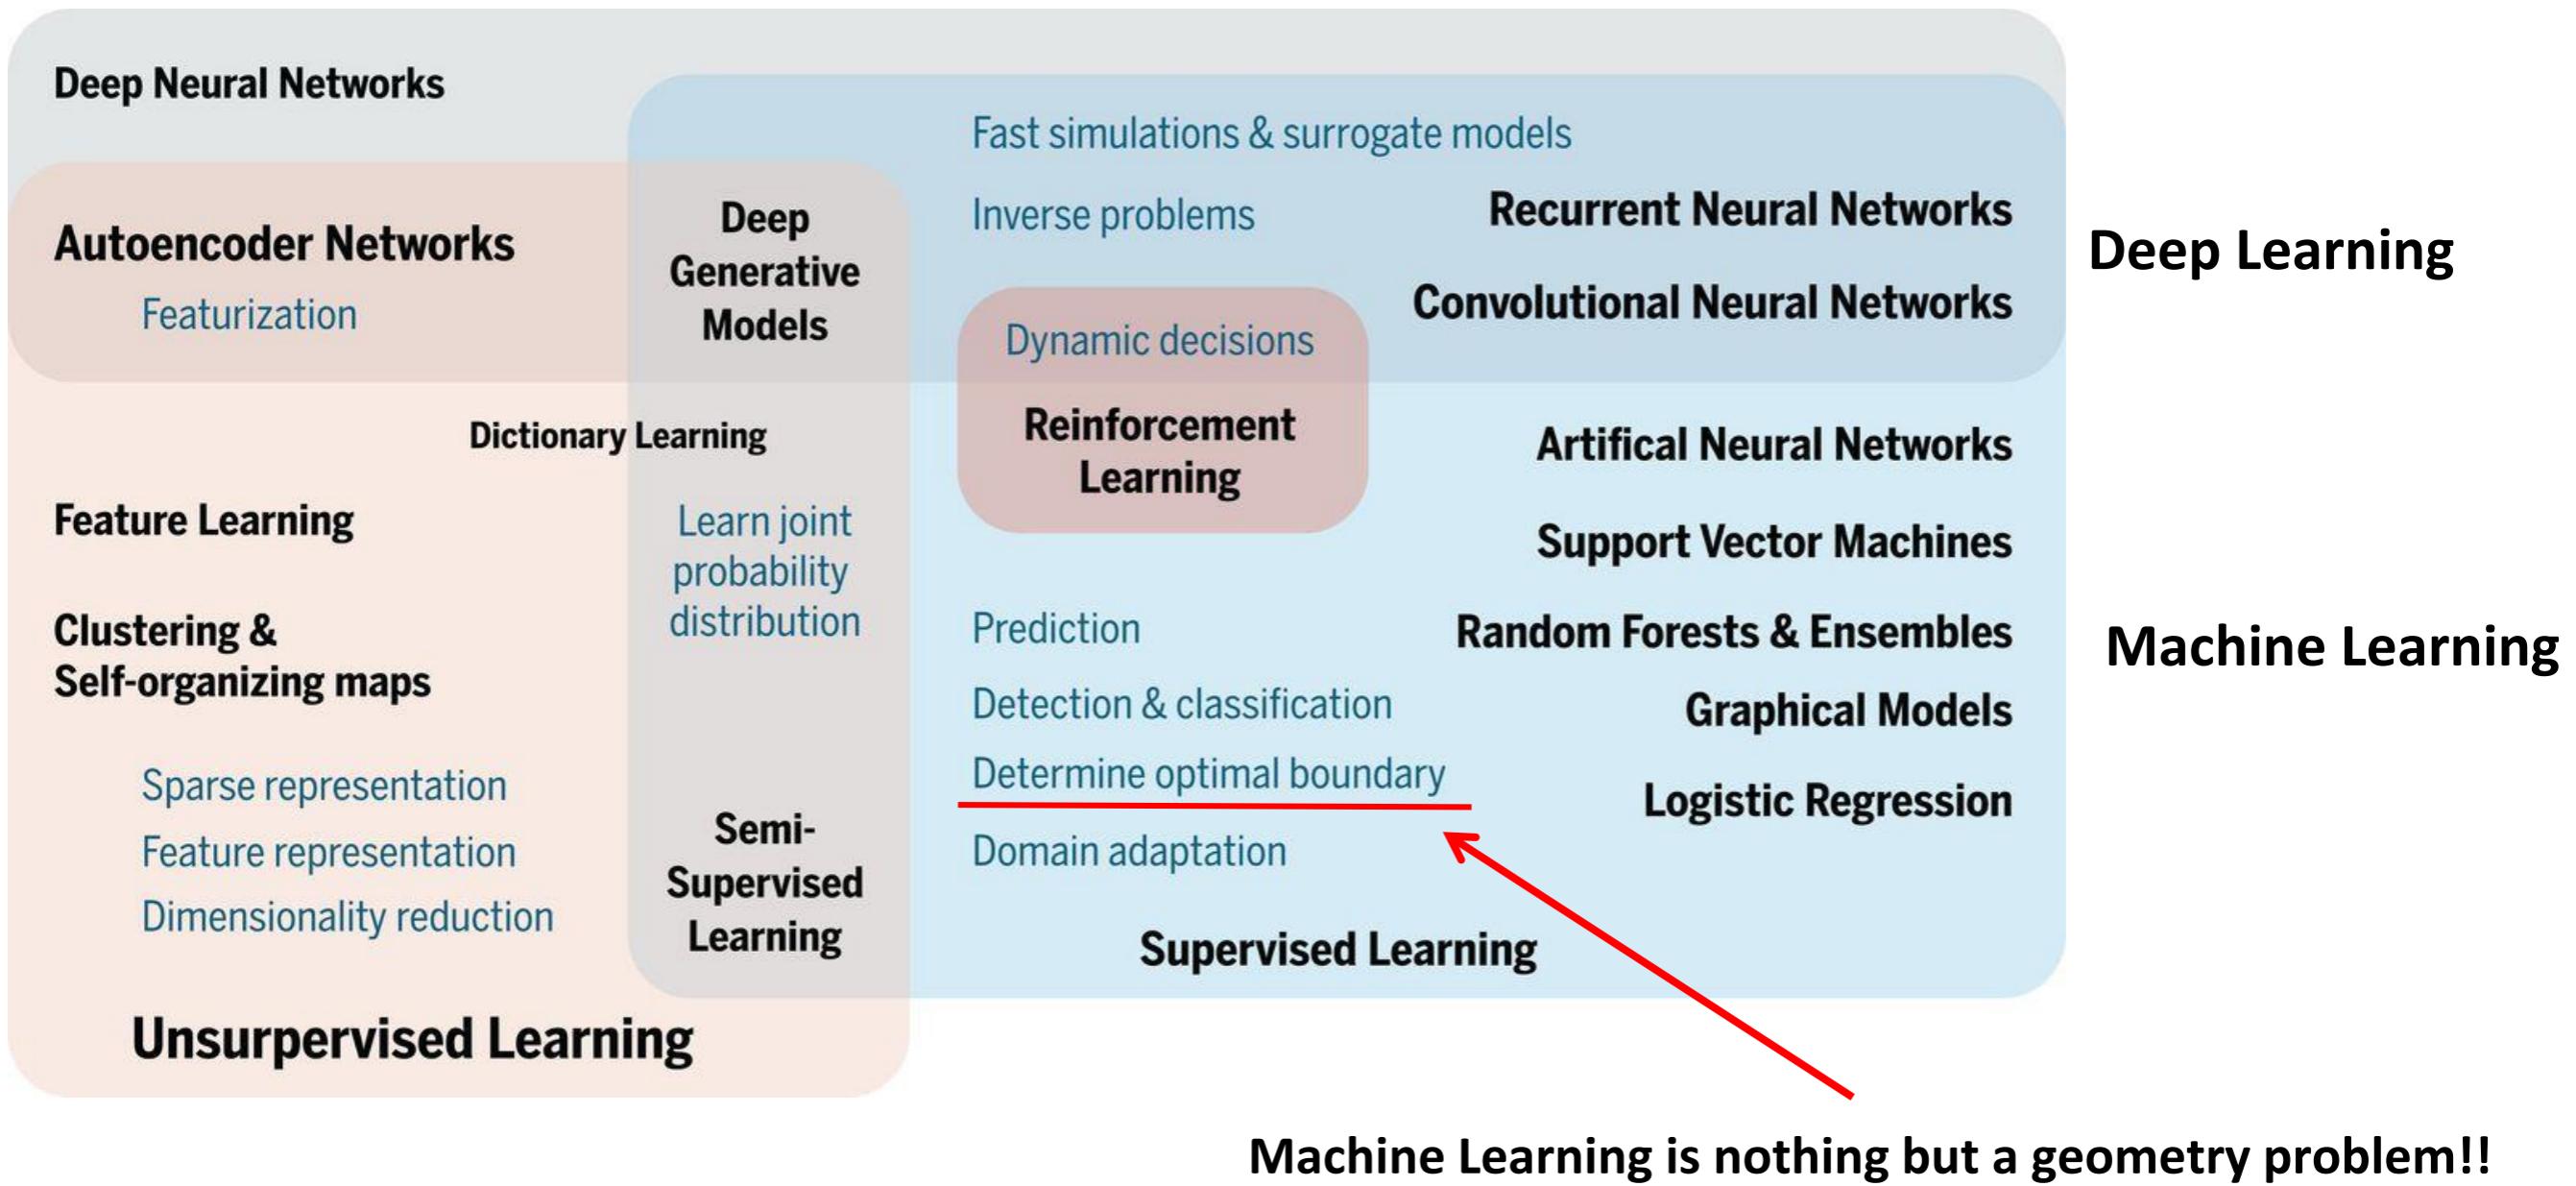
Machine Learning na Geociências



Machine Learning na Geociências



Algoritmos de Machine Learning



Machine Learning
no
Serviço Geológico do Brasil



SERVIÇO GEOLÓGICO DO BRASIL
CPRM



Journal of the Geological Survey of Brazil

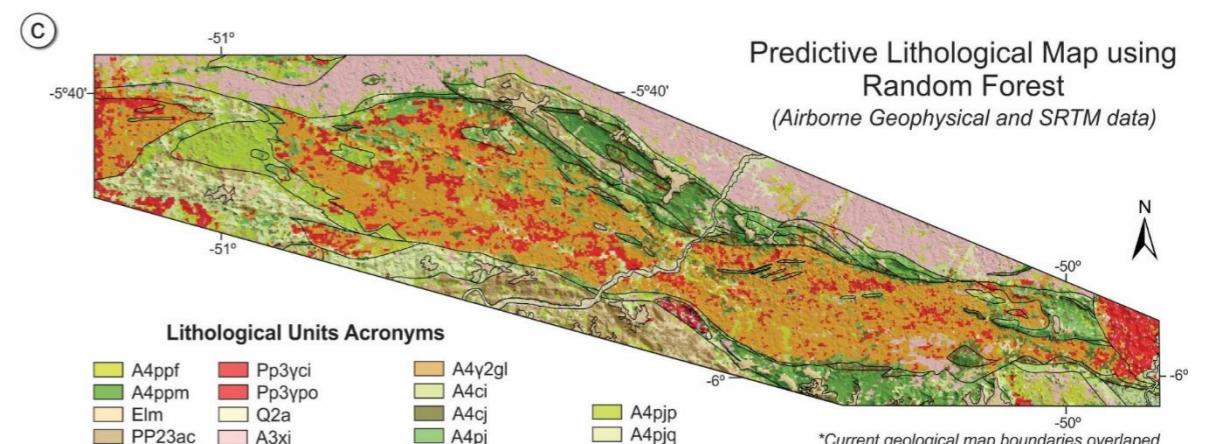
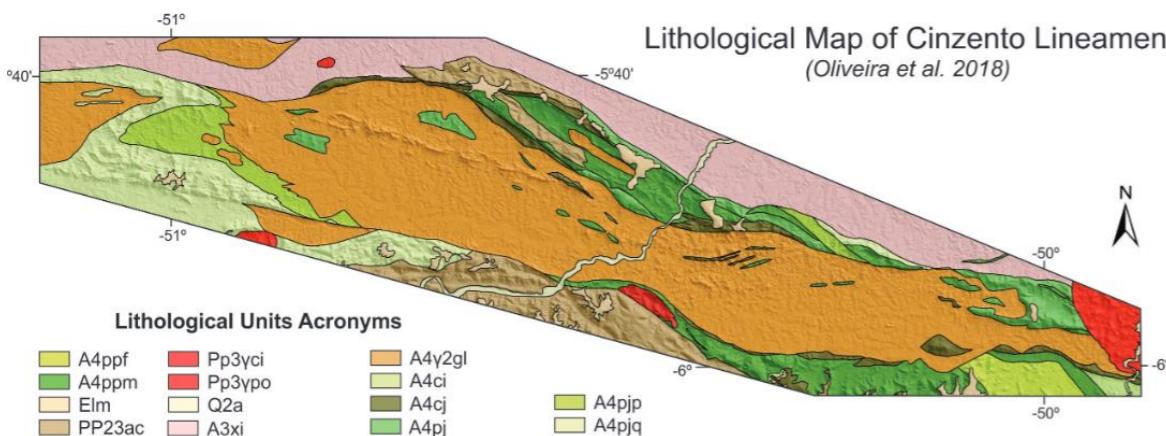
Predictive lithological mapping through machine learning methods: a case study in the Cinzento Lineament, Carajás Province, Brazil

Iago Sousa Lima Costa¹ , Felipe Mattos Tavares² , Junny Kyley Mastop de Oliveira³ 

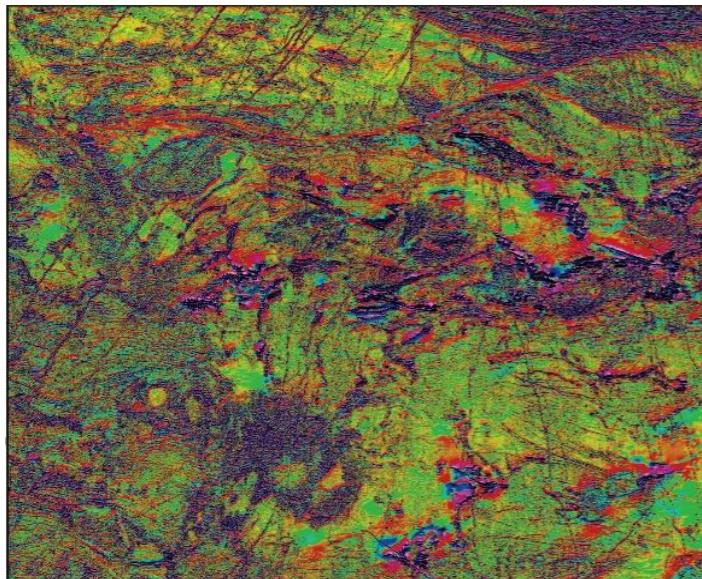
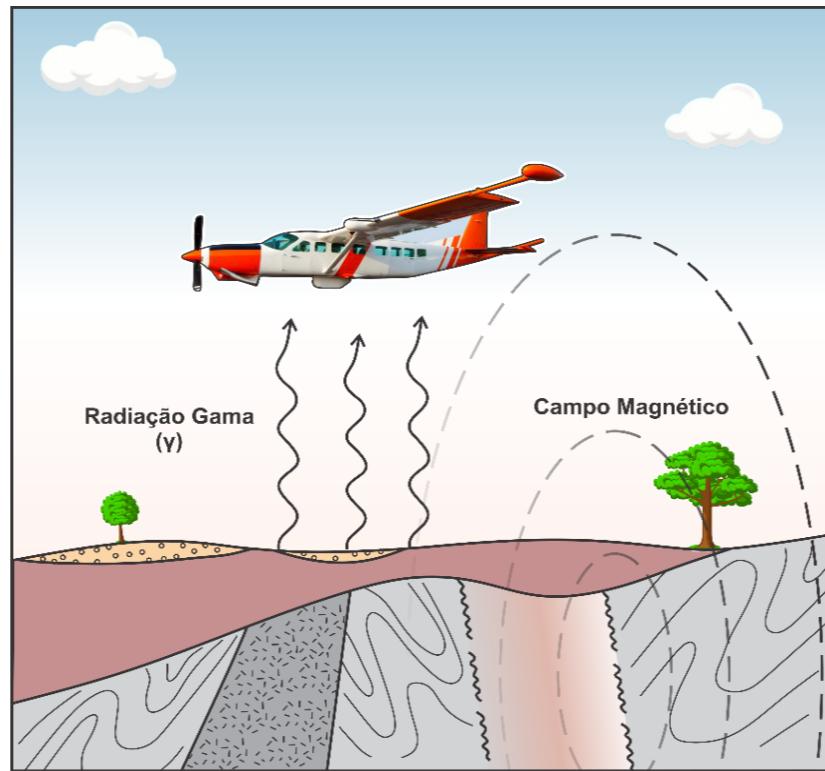
¹ CPRM - Geological Survey of Brazil. SBN, Quadra 02, Bloco H, 2º Andar, Distrito Federal, Brasília, Brazil, CEP: 70040-904.

² CPRM - Geological Survey of Brazil. Av. Pasteur, 404 - Urca, Rio de Janeiro, Rio de Janeiro, Brazil, CEP: 22290-240.

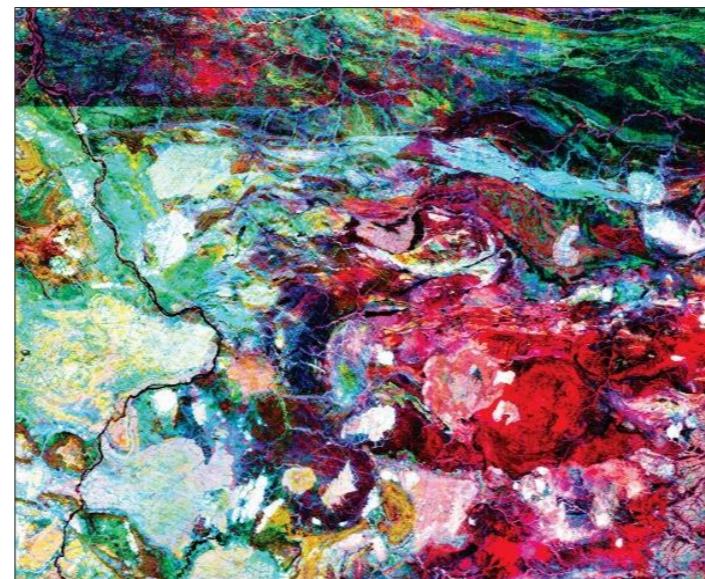
³ CPRM - Geological Survey of Brazil. Av. Perimetral, 3645 - Marco, Pará, Belém, Brazil, CEP: 66095-904



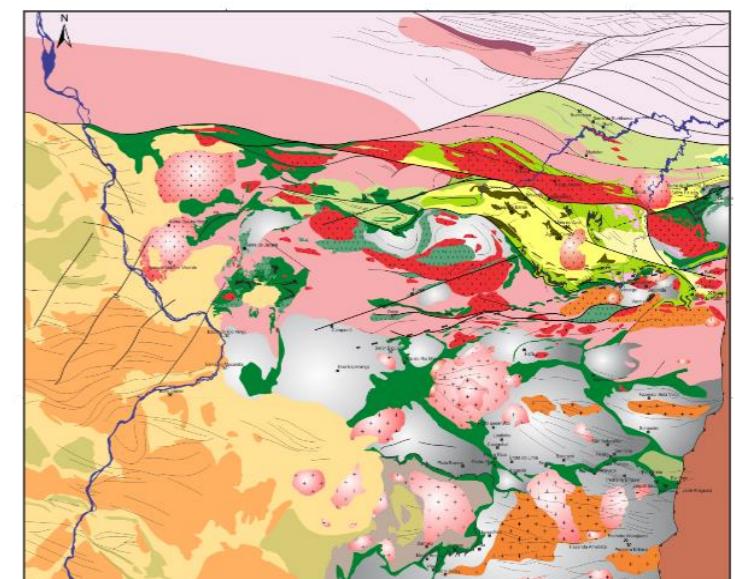
Dados



Dado Magnetométrico

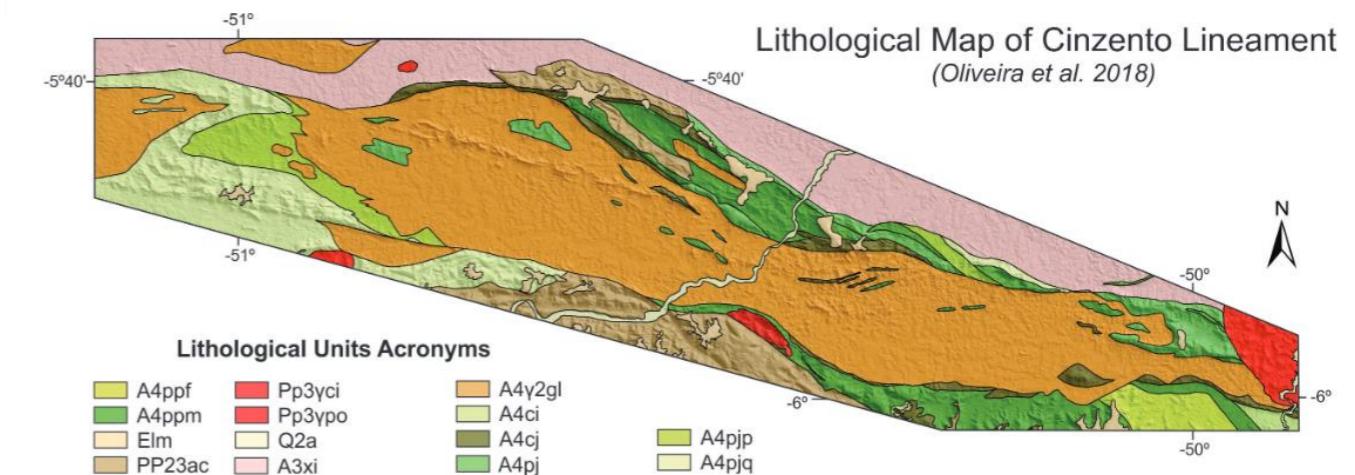
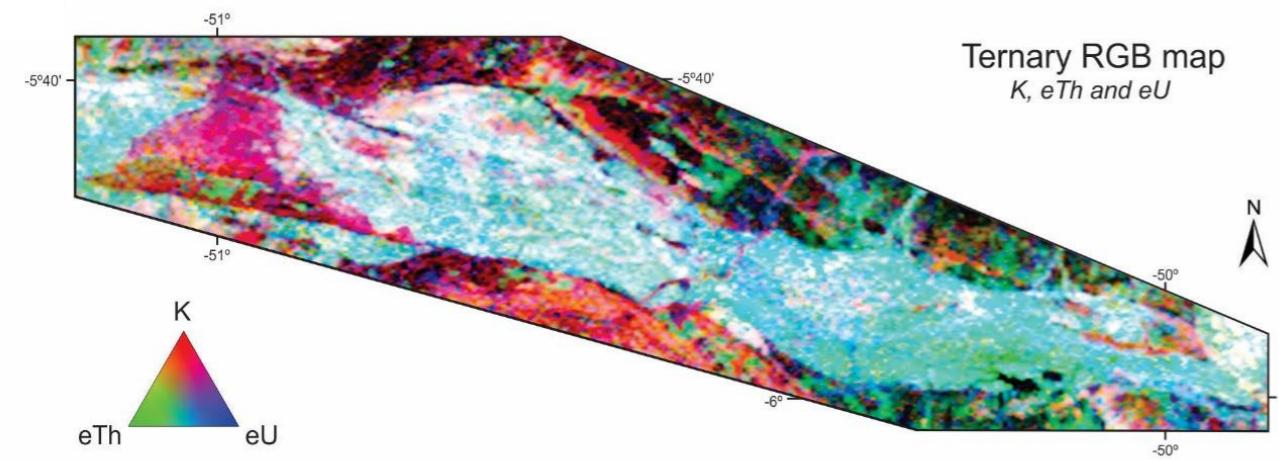
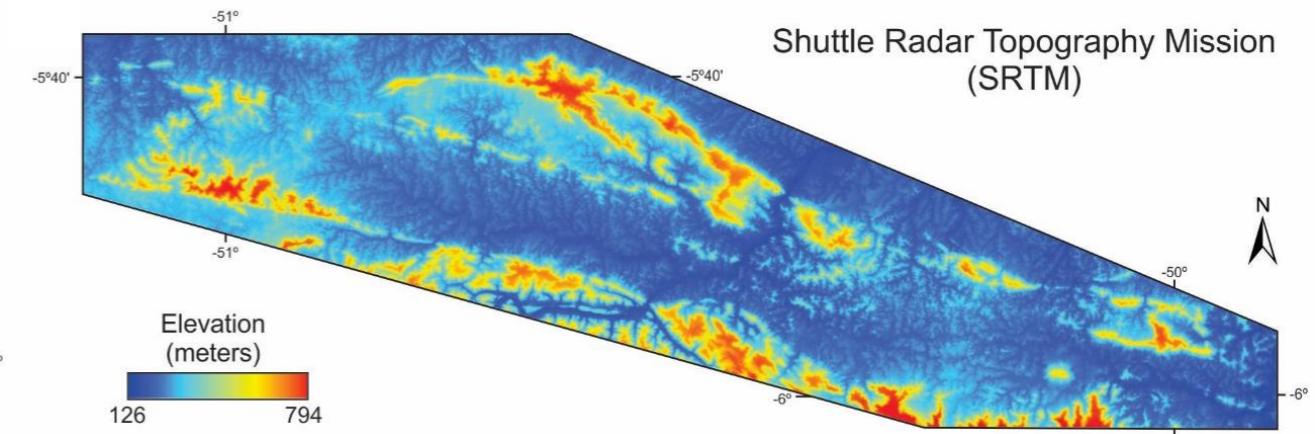
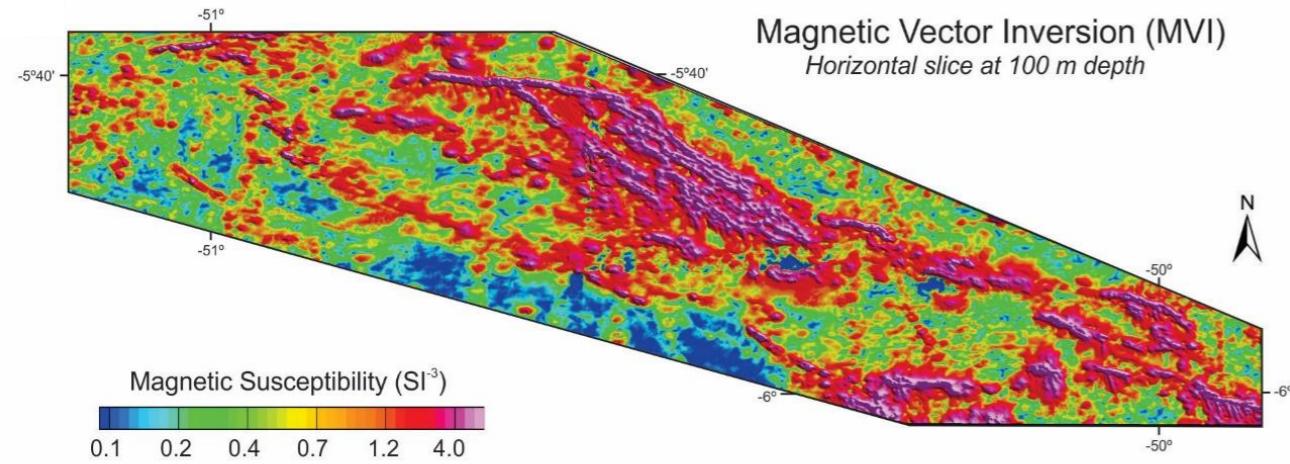


Dado Gamaespectrométrico



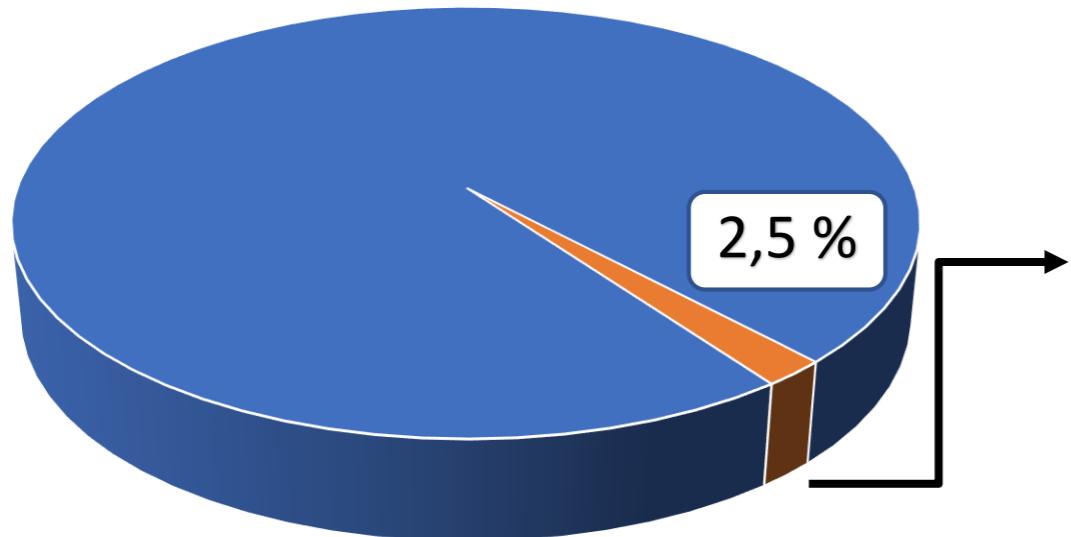
Mapa Geológico

Dados



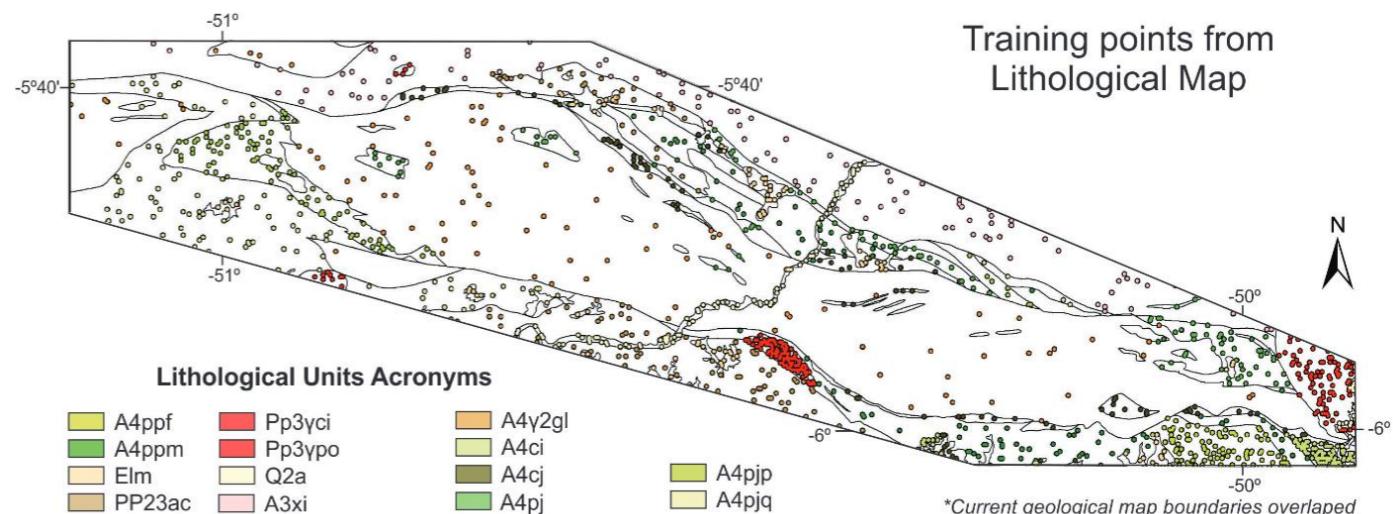
Dados

Dados de Treinamento



100
pontos de treinamento
por litologia
(1400 pontos)

Unidade Litológica	MVI *10-3	Urânio ppm	Potássio %	Tório ppm	Elevação m
Q2a	0.278	1.824	0.845	3.877	159.4
A4ppf	0.522	1.806	1.174	2.157	350.6
A4y2gl	1.722	3.524	0.635	7.886	230.1
A3xi	0.923	0.792	0.231	3.044	247.7
A4ppm	0.120	0.654	0.058	2.435	423.0

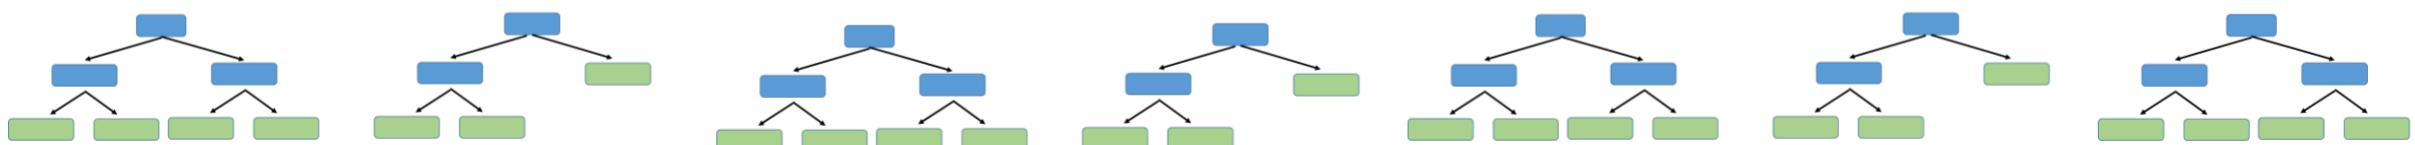
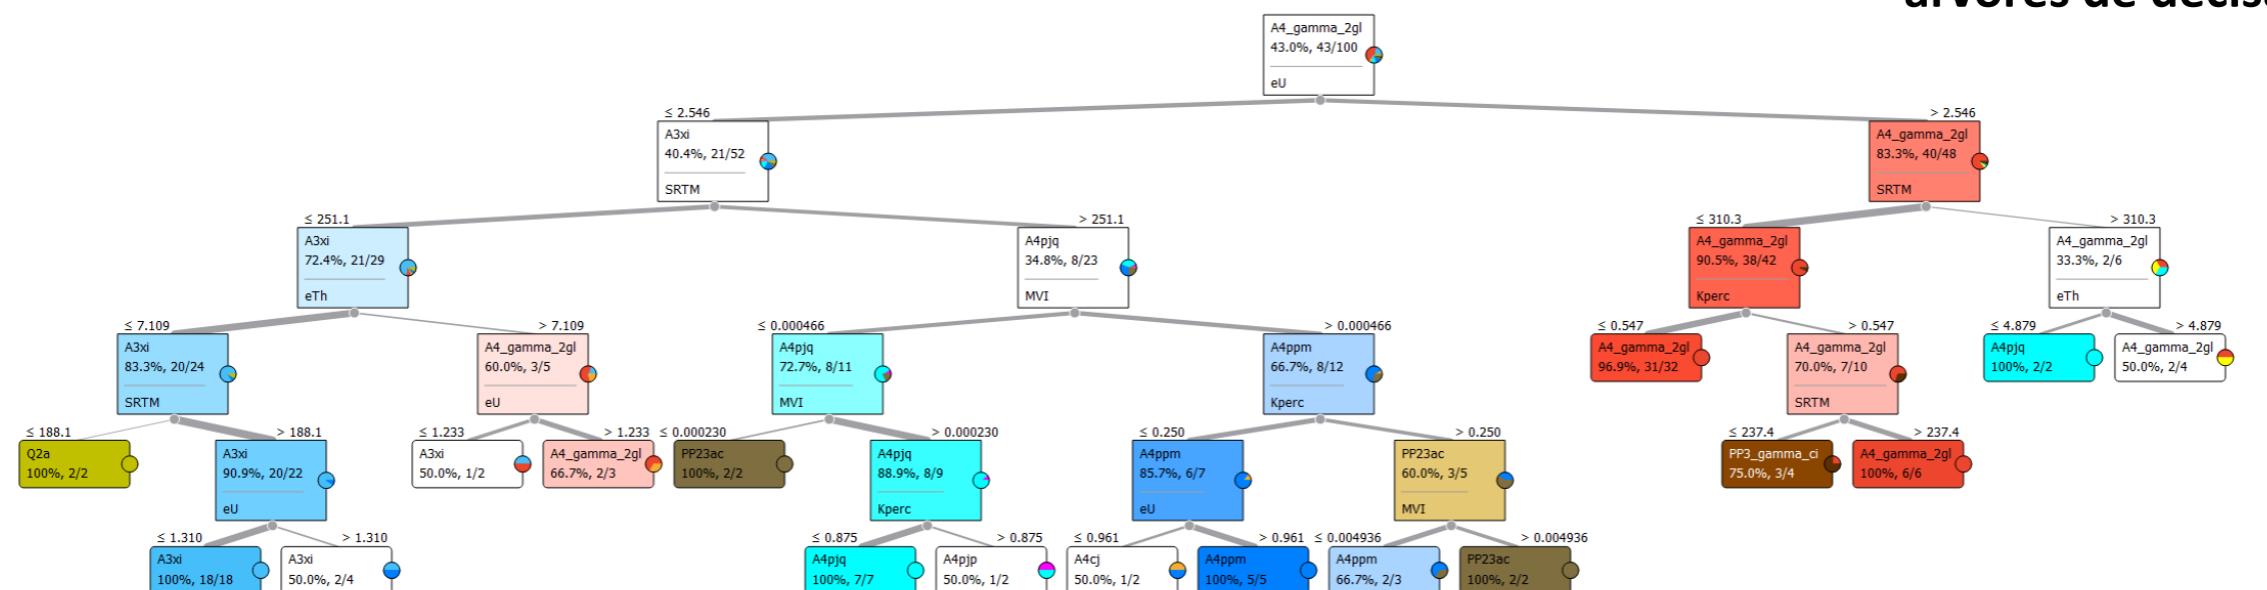


Avaliação dos Algoritmos de ML

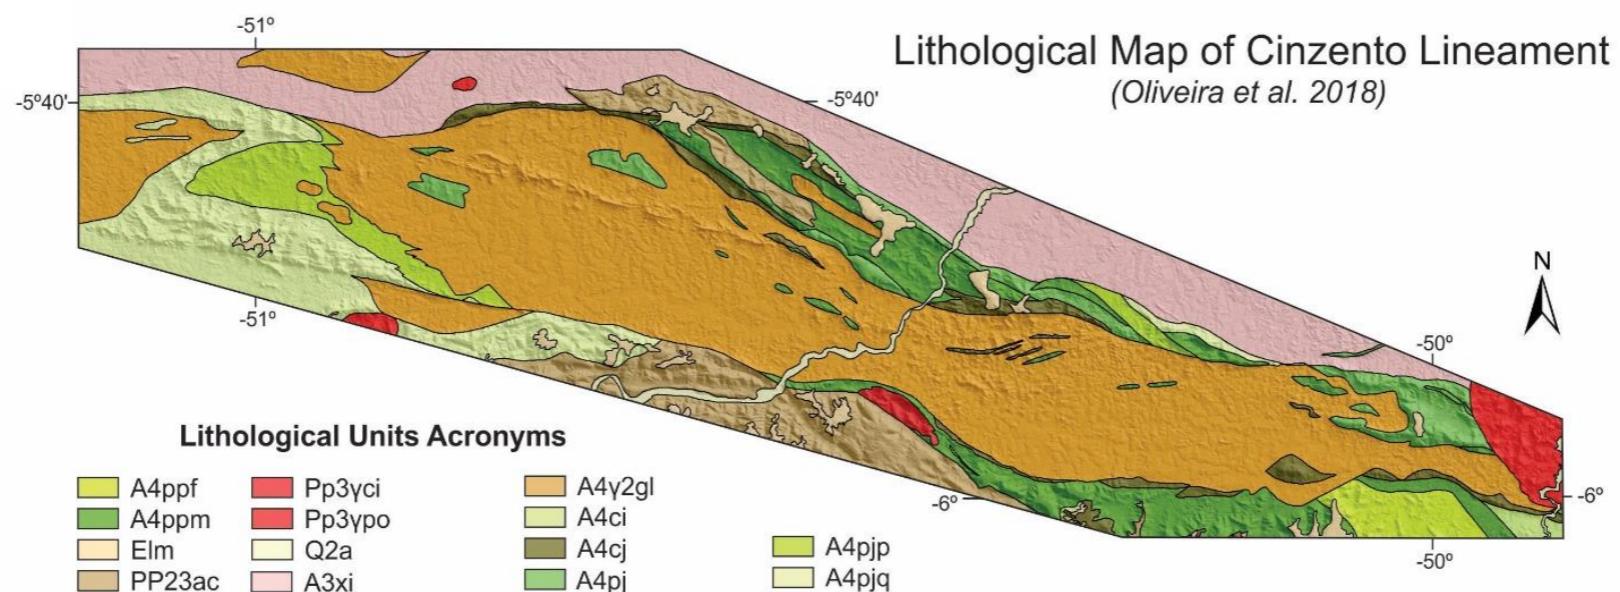
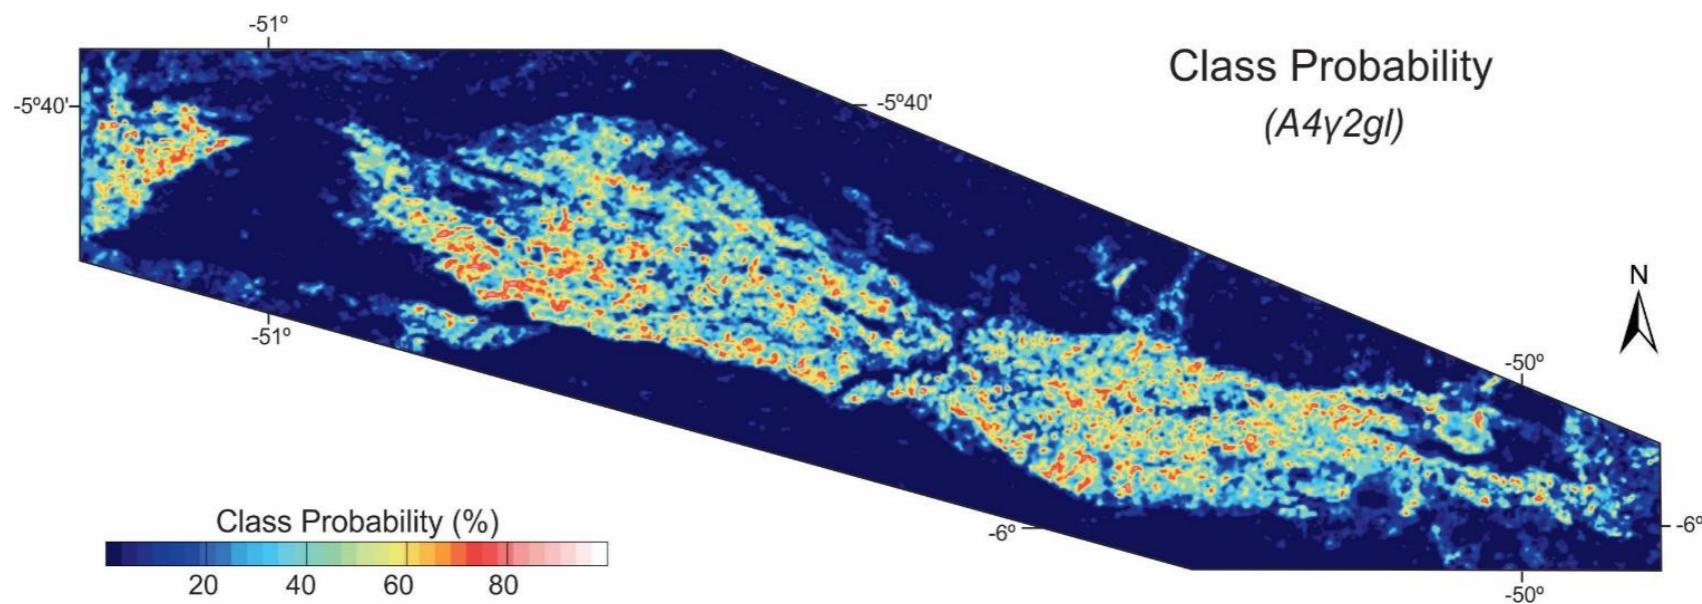
Algoritmo de <i>Machine Learning</i>	Cross-validation Accuracy (%)
Random Forest	76.9
Neural Network	74.1
Naive Bayes	67.3
k-Nearest Neighbors	64.2
Support Vector Machines	25.9

Random Forest

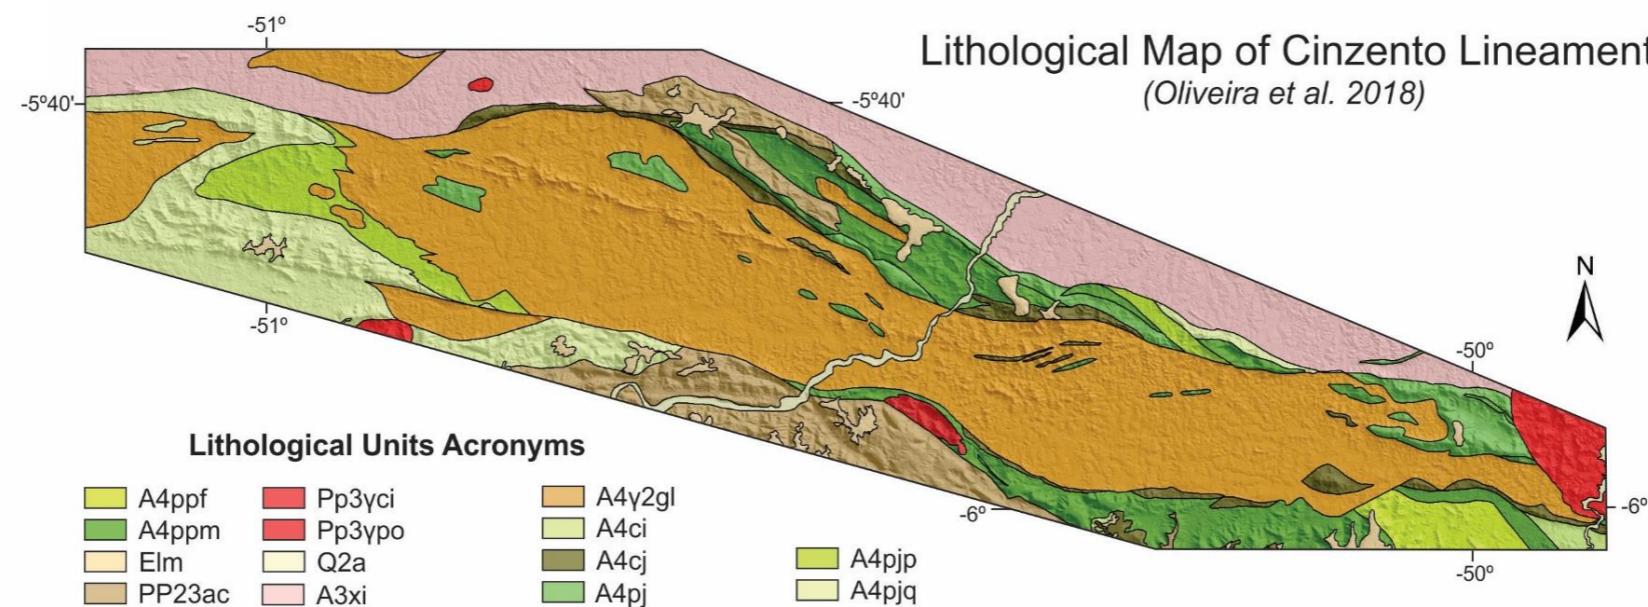
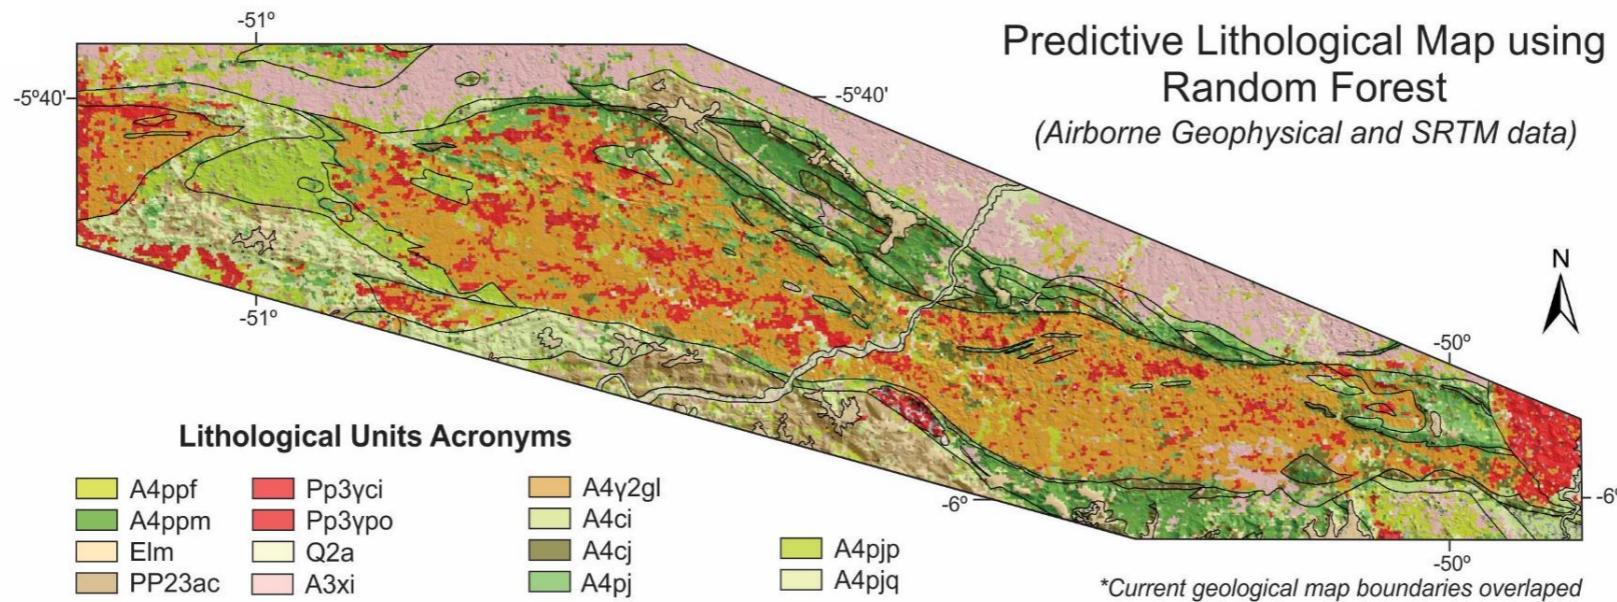
100
árvores de decisão



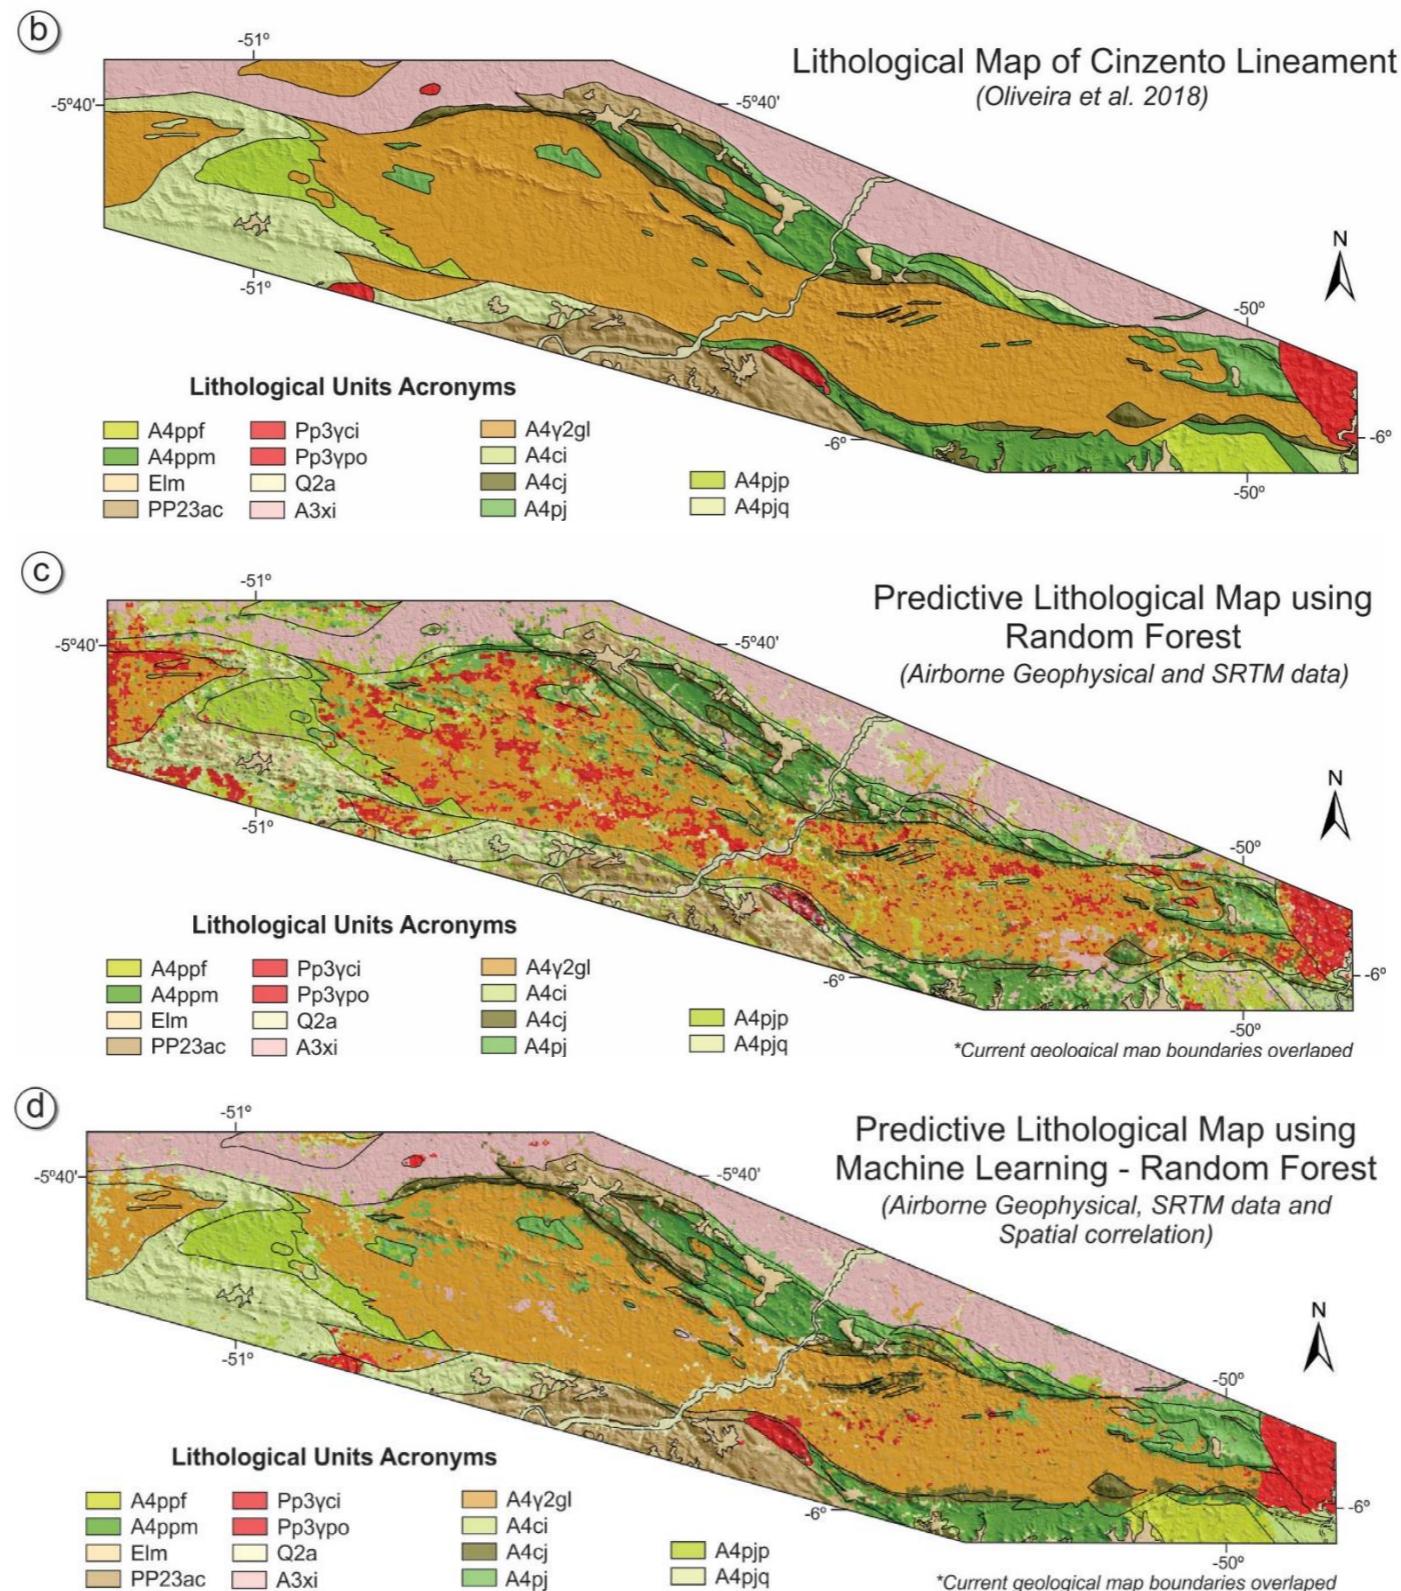
Resultados



Resultados



Resultados





Uranium anomalies detection through Random Forest regression

Iago Sousa Lima Costa  ^a, Isabelle Cavalcanti Corrêa de Oliveira Serafim  ^a, Felipe Mattos Tavares  ^b and Hugo José de Oliveira Polo  ^a

^aCPRM – Geological Survey of Brazil, Brasília, Brazil; ^bCPRM – Geological Survey of Brazil, Rio de Janeiro, Brazil

“Brasil possui a sétima maior reserva de urânio convencional no mundo, com 310.000 toneladas. No entanto, esta reserva pode aumentar drasticamente tendo em vista que somente 25 % do território brasileiro foi explorado sistematicamente (Heider, 2016).”

Motivação

Tavares, F.M., Costa, I.S.L. (2018). Conventional and Unconventional uranium resources in the Carajás Mineral Province - Brazil : Prospectivity criteria for IOCG and Granite-Related deposits. In: International Symposium on Uranium Raw Material for the Nuclear Fuel Cycle: Exploration, Mining, Production, Supply and Demand, Economics and Environmental Issues (URAM-2018), IAEA, Vienna, Austria.

Serafim, I.C.C.O., Carmelo, A.C., Botelho, N.F. (2019) Airborne Radiometric identification of Uranium anomalies in northeast goiás. IV Simpósio Brasileiro de Metalogenia, Gramado, Porto Alegre, Brasil.

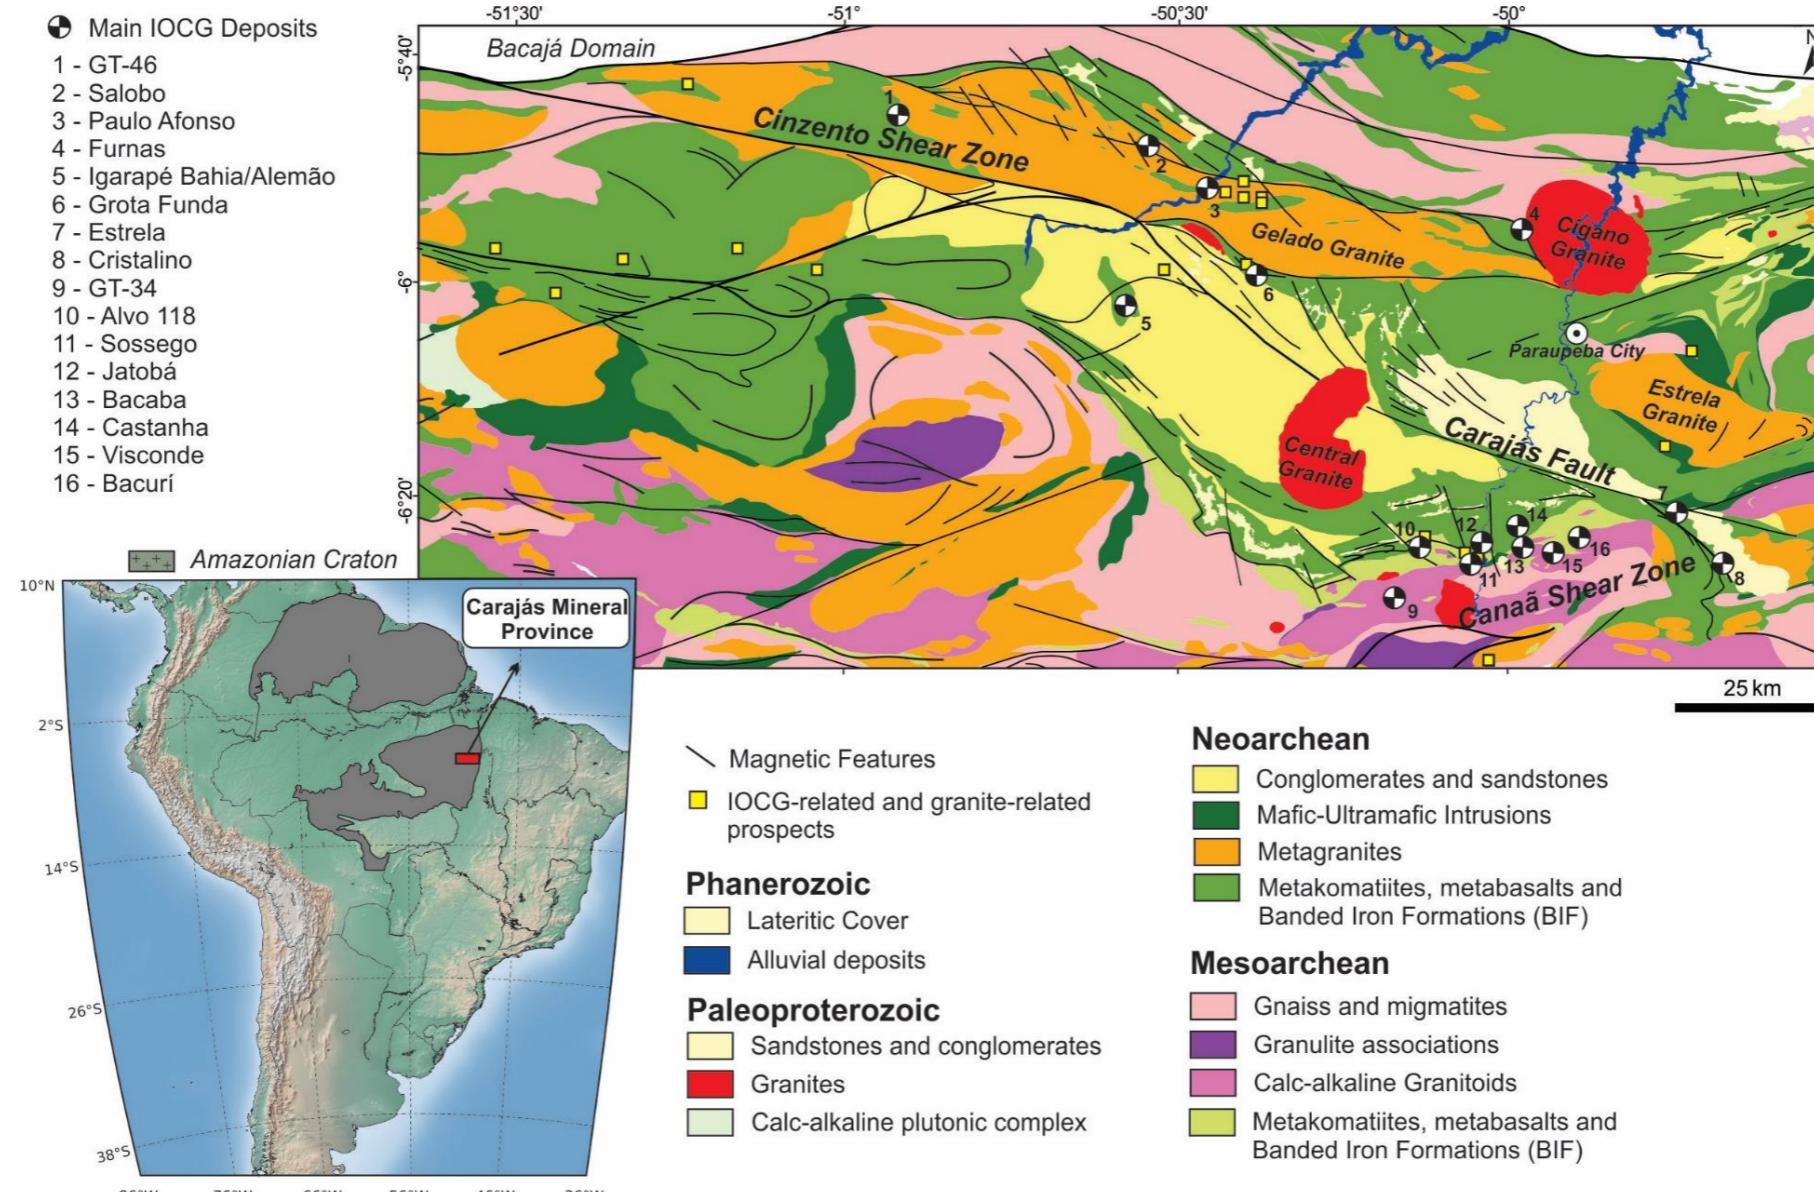
Polo, H.J.O., Tavares, F.M., Serafim, I.C.C.O. (2019) Avaliação preliminar do potencial para depósitos de urânio no Brasil com base em integração de dados. IV Simpósio Brasileiro de Metalogenia, Gramado, Porto Alegre, Brasil.

➤ **Costa et al. (2020)** *Uranium anomalies detection through Random Forest regression. Exploration Geophysics.*

Polo et al. (2022a) Mapa de avaliação do potencial de urânio do Brasil: escala 1:5.000.000.

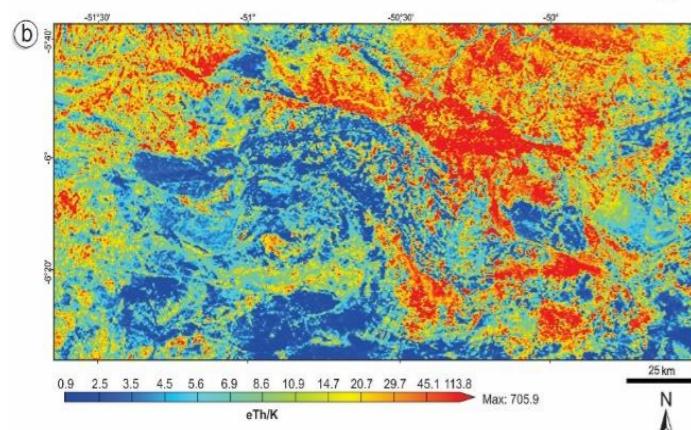
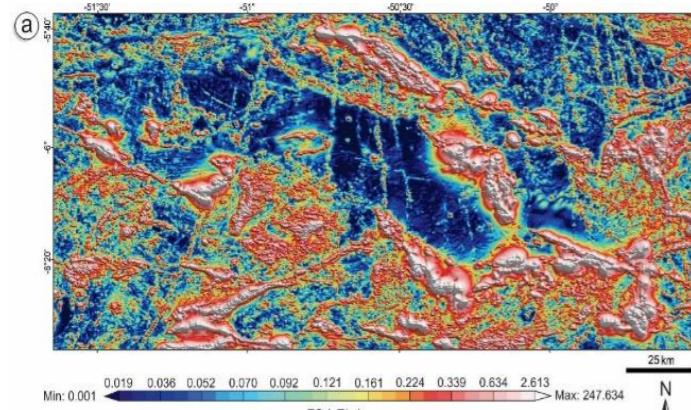
Polo et al. (2022b) Avaliação em escala continental da favorabilidade para depósitos de urânio no Brasil. International Joint Conference Radio 2022.

Área de Estudo

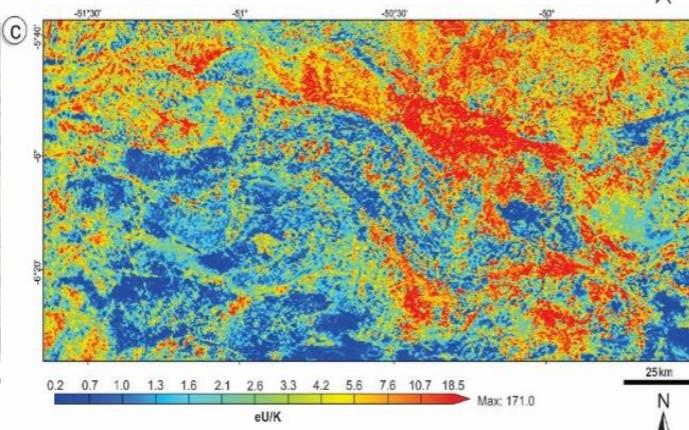
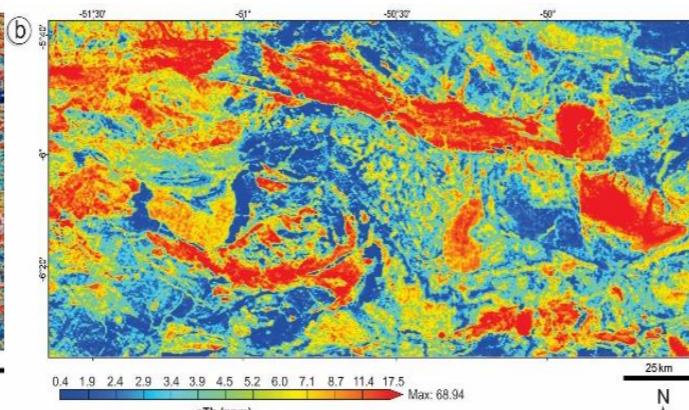


Treinando o Modelo

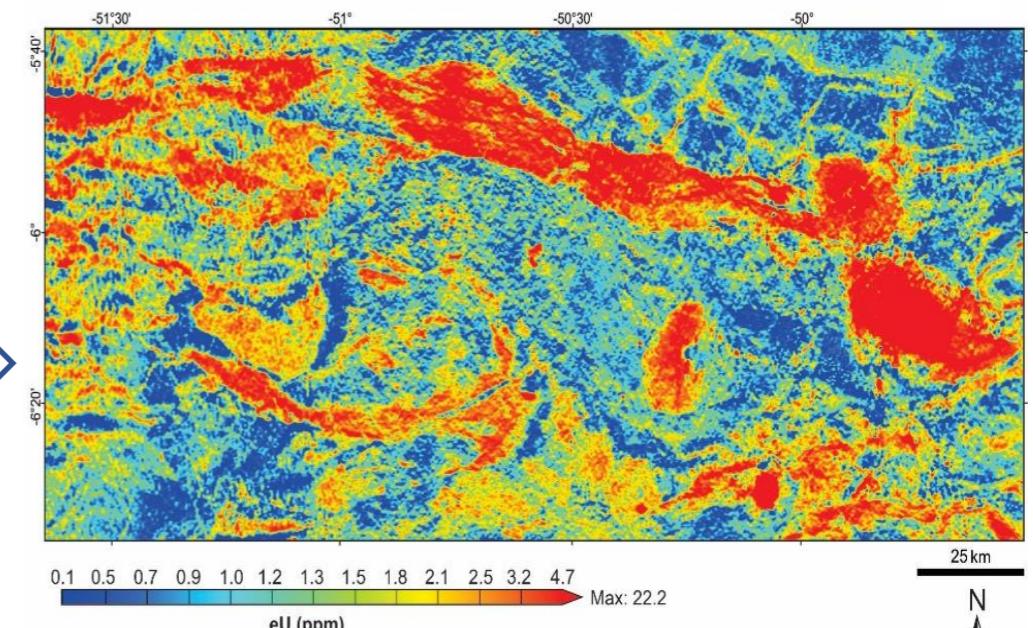
Gradiente Total



Tório



Urânio ideal



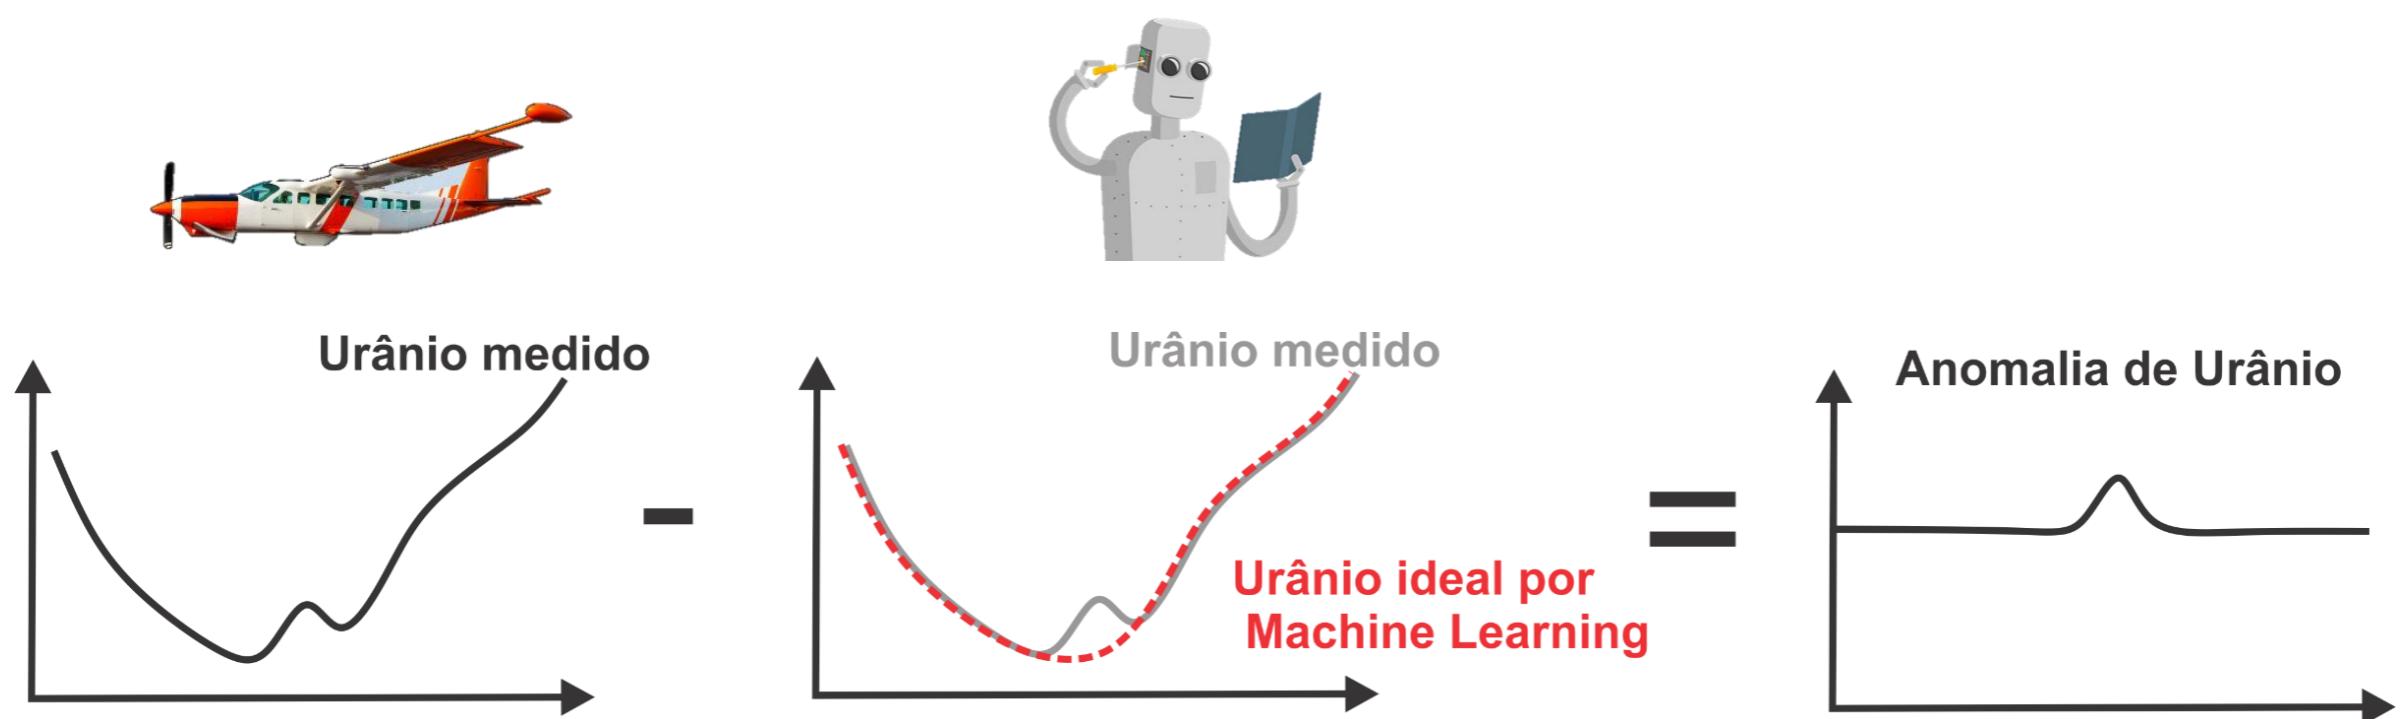
Tório/Potássio

Urânio/Potássio

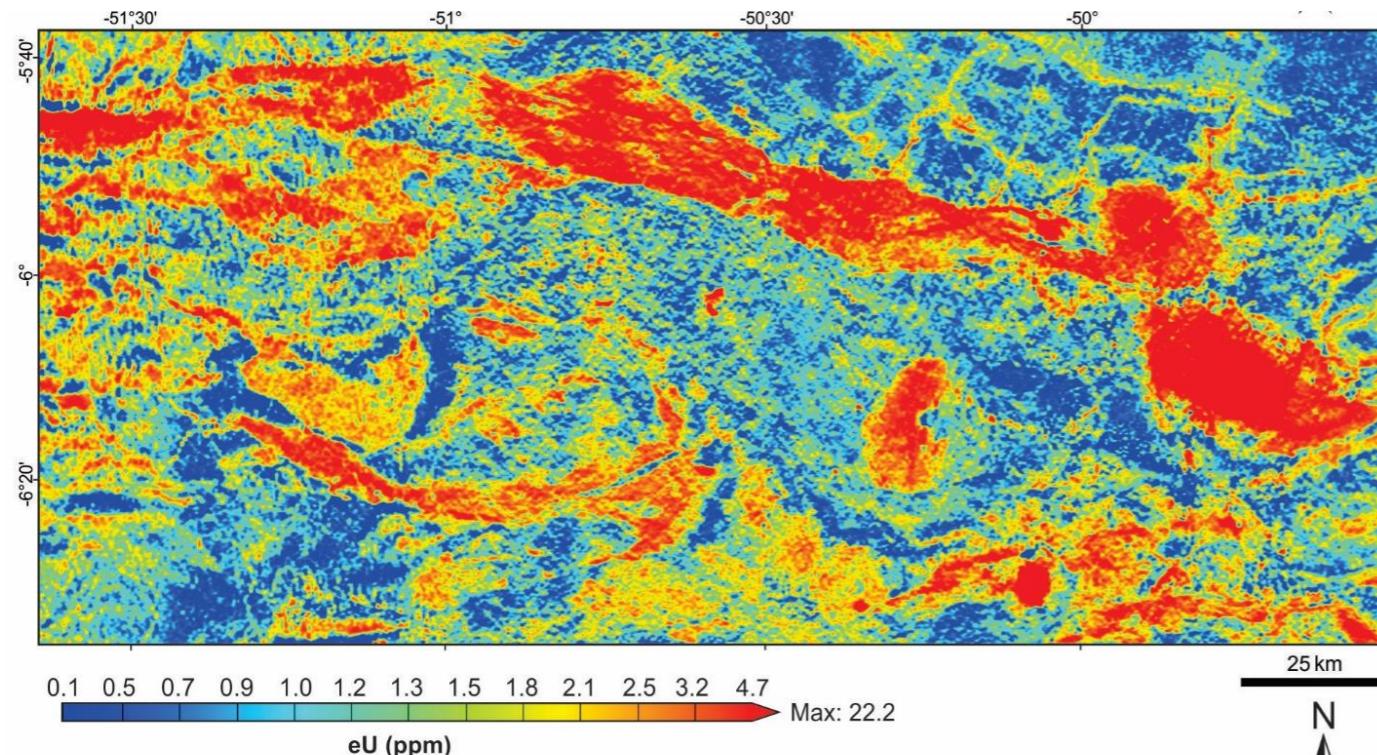
Parâmetros de background litológico

(Pires et al. 2019)

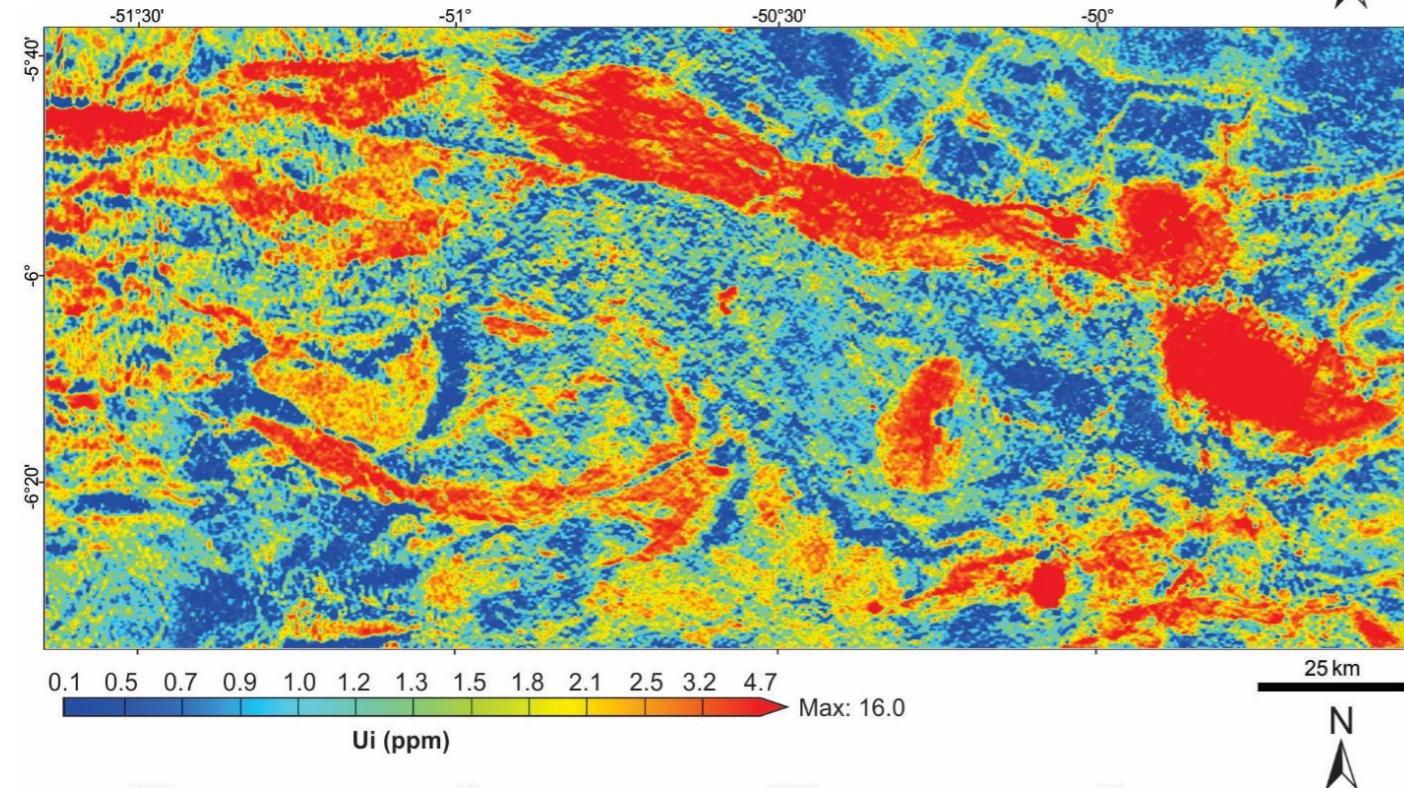
Treinando o Modelo



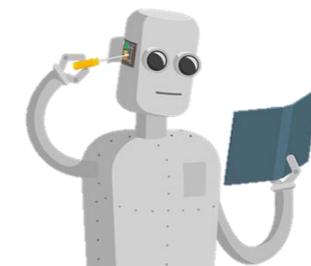
Treinando o Modelo



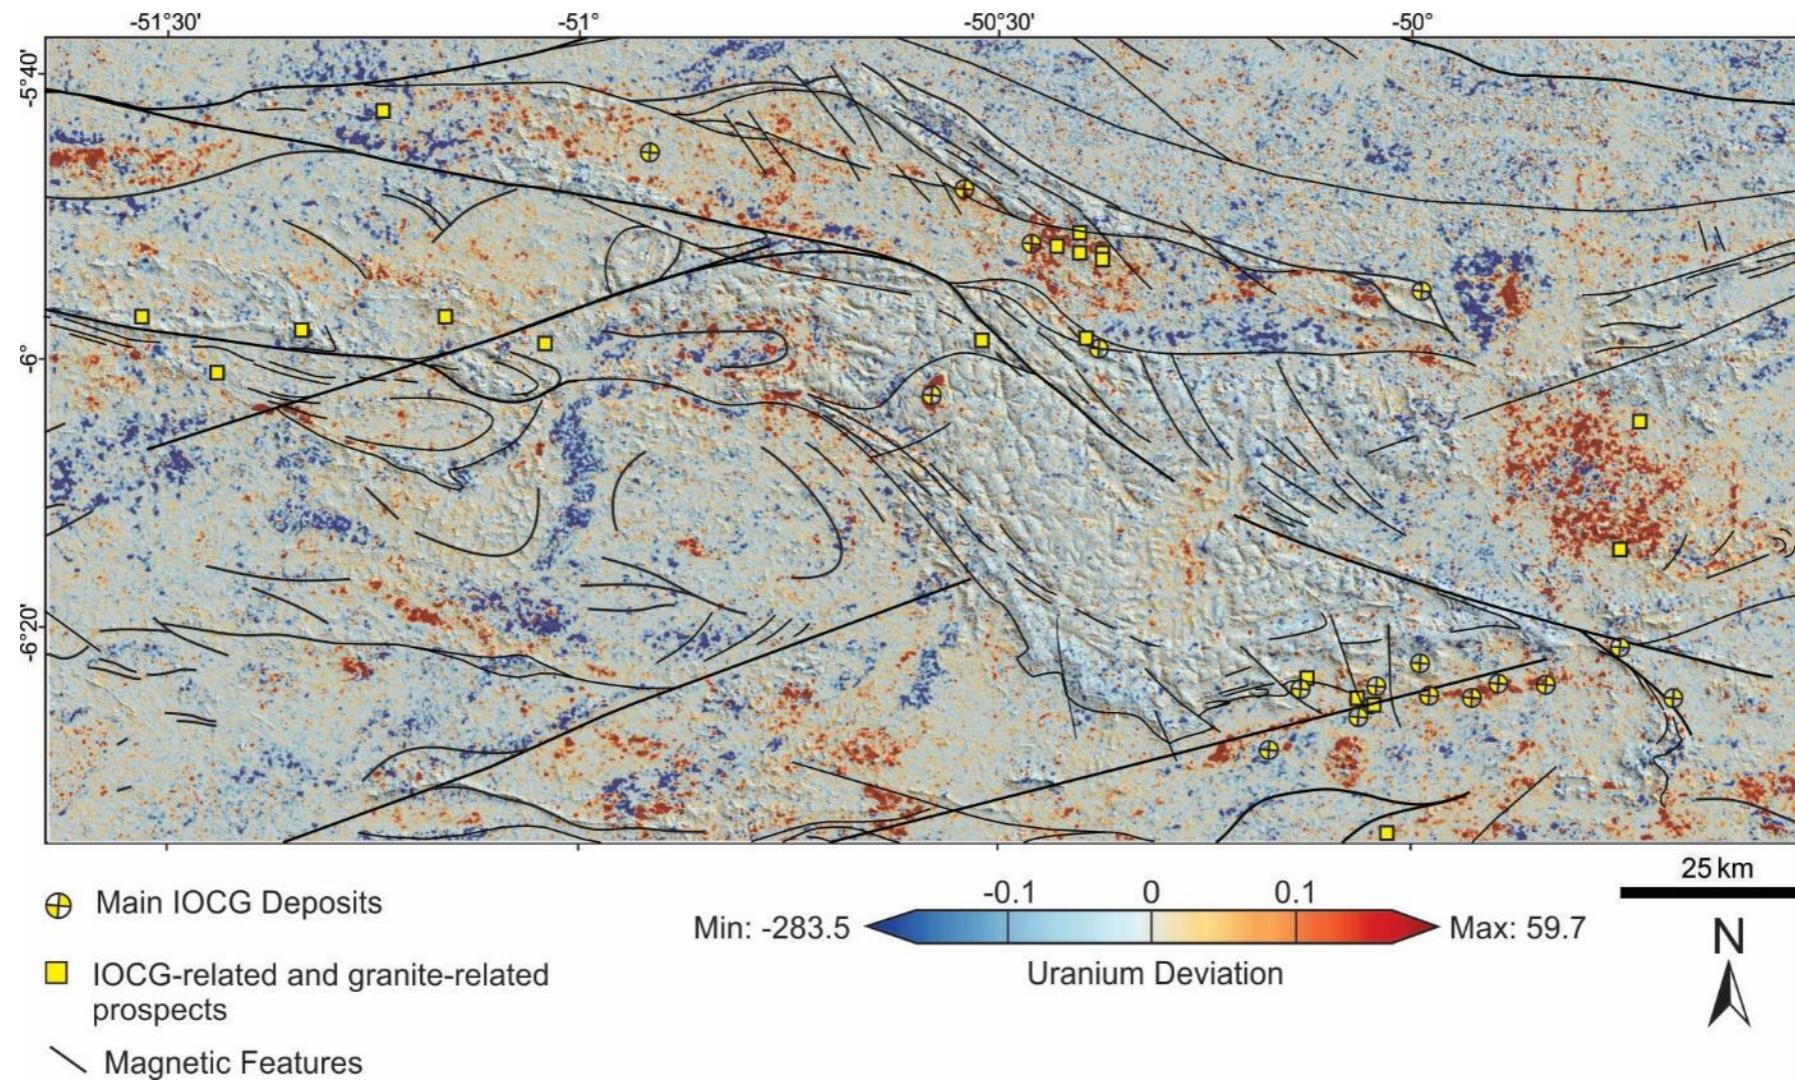
Urânio Medido

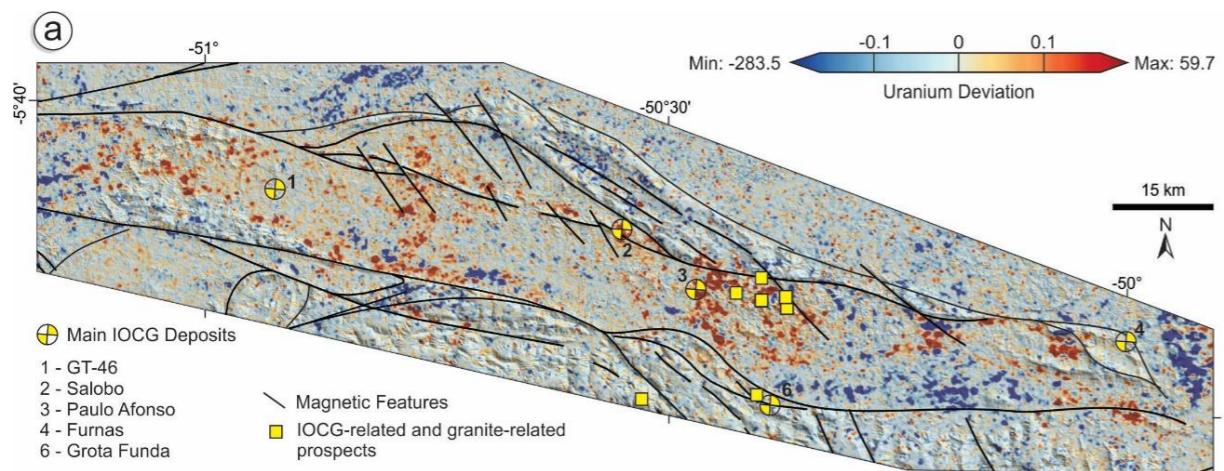


**Urânio ideal
(Machine Learning)**

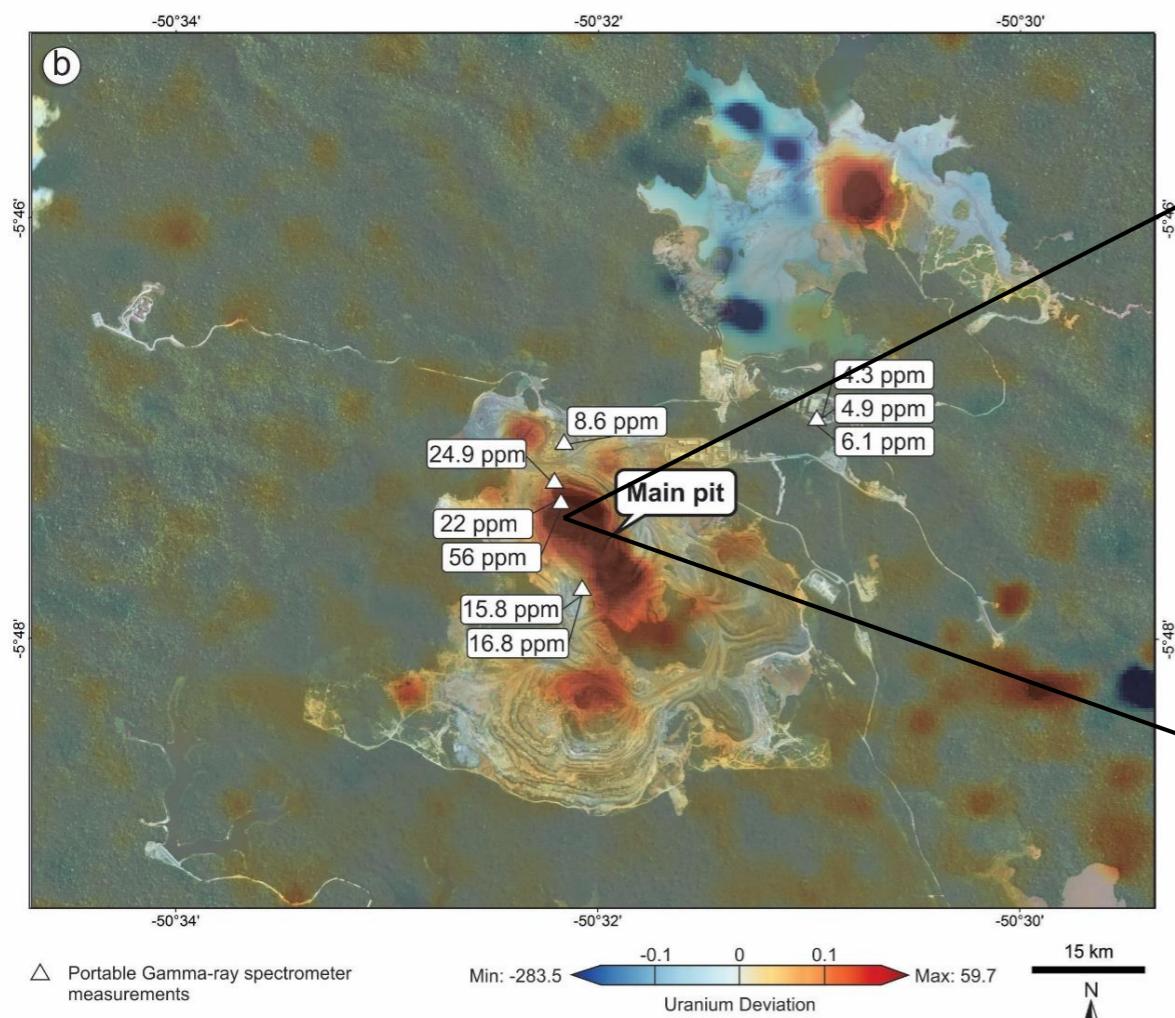


Anomalias de Urânio





Mina do Salobo



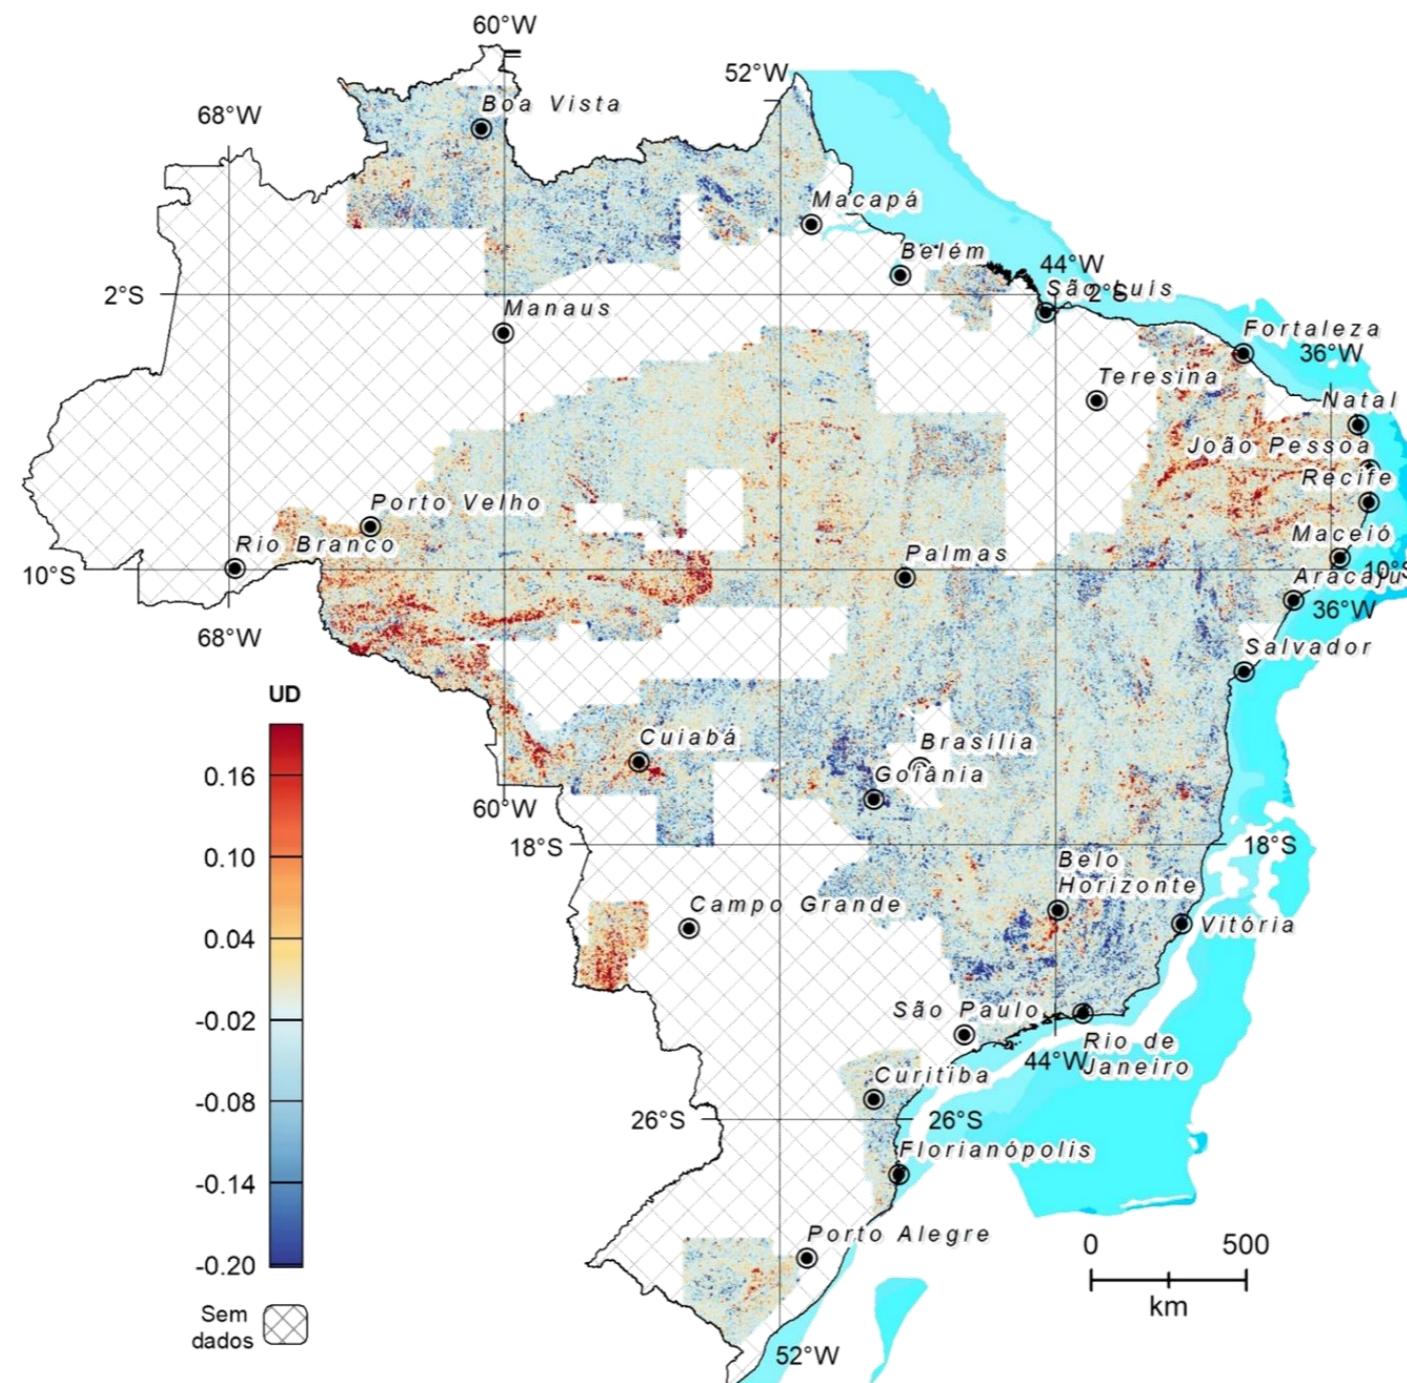
Magnetito (com Bornita, Calcopirita)

$K = 1.1 \%$
 $eTh = 5.4 \text{ ppm}$
 $eU = 19.9 \text{ ppm}$
 $\text{Susc.} = 913.8 \times 10^{-3}$

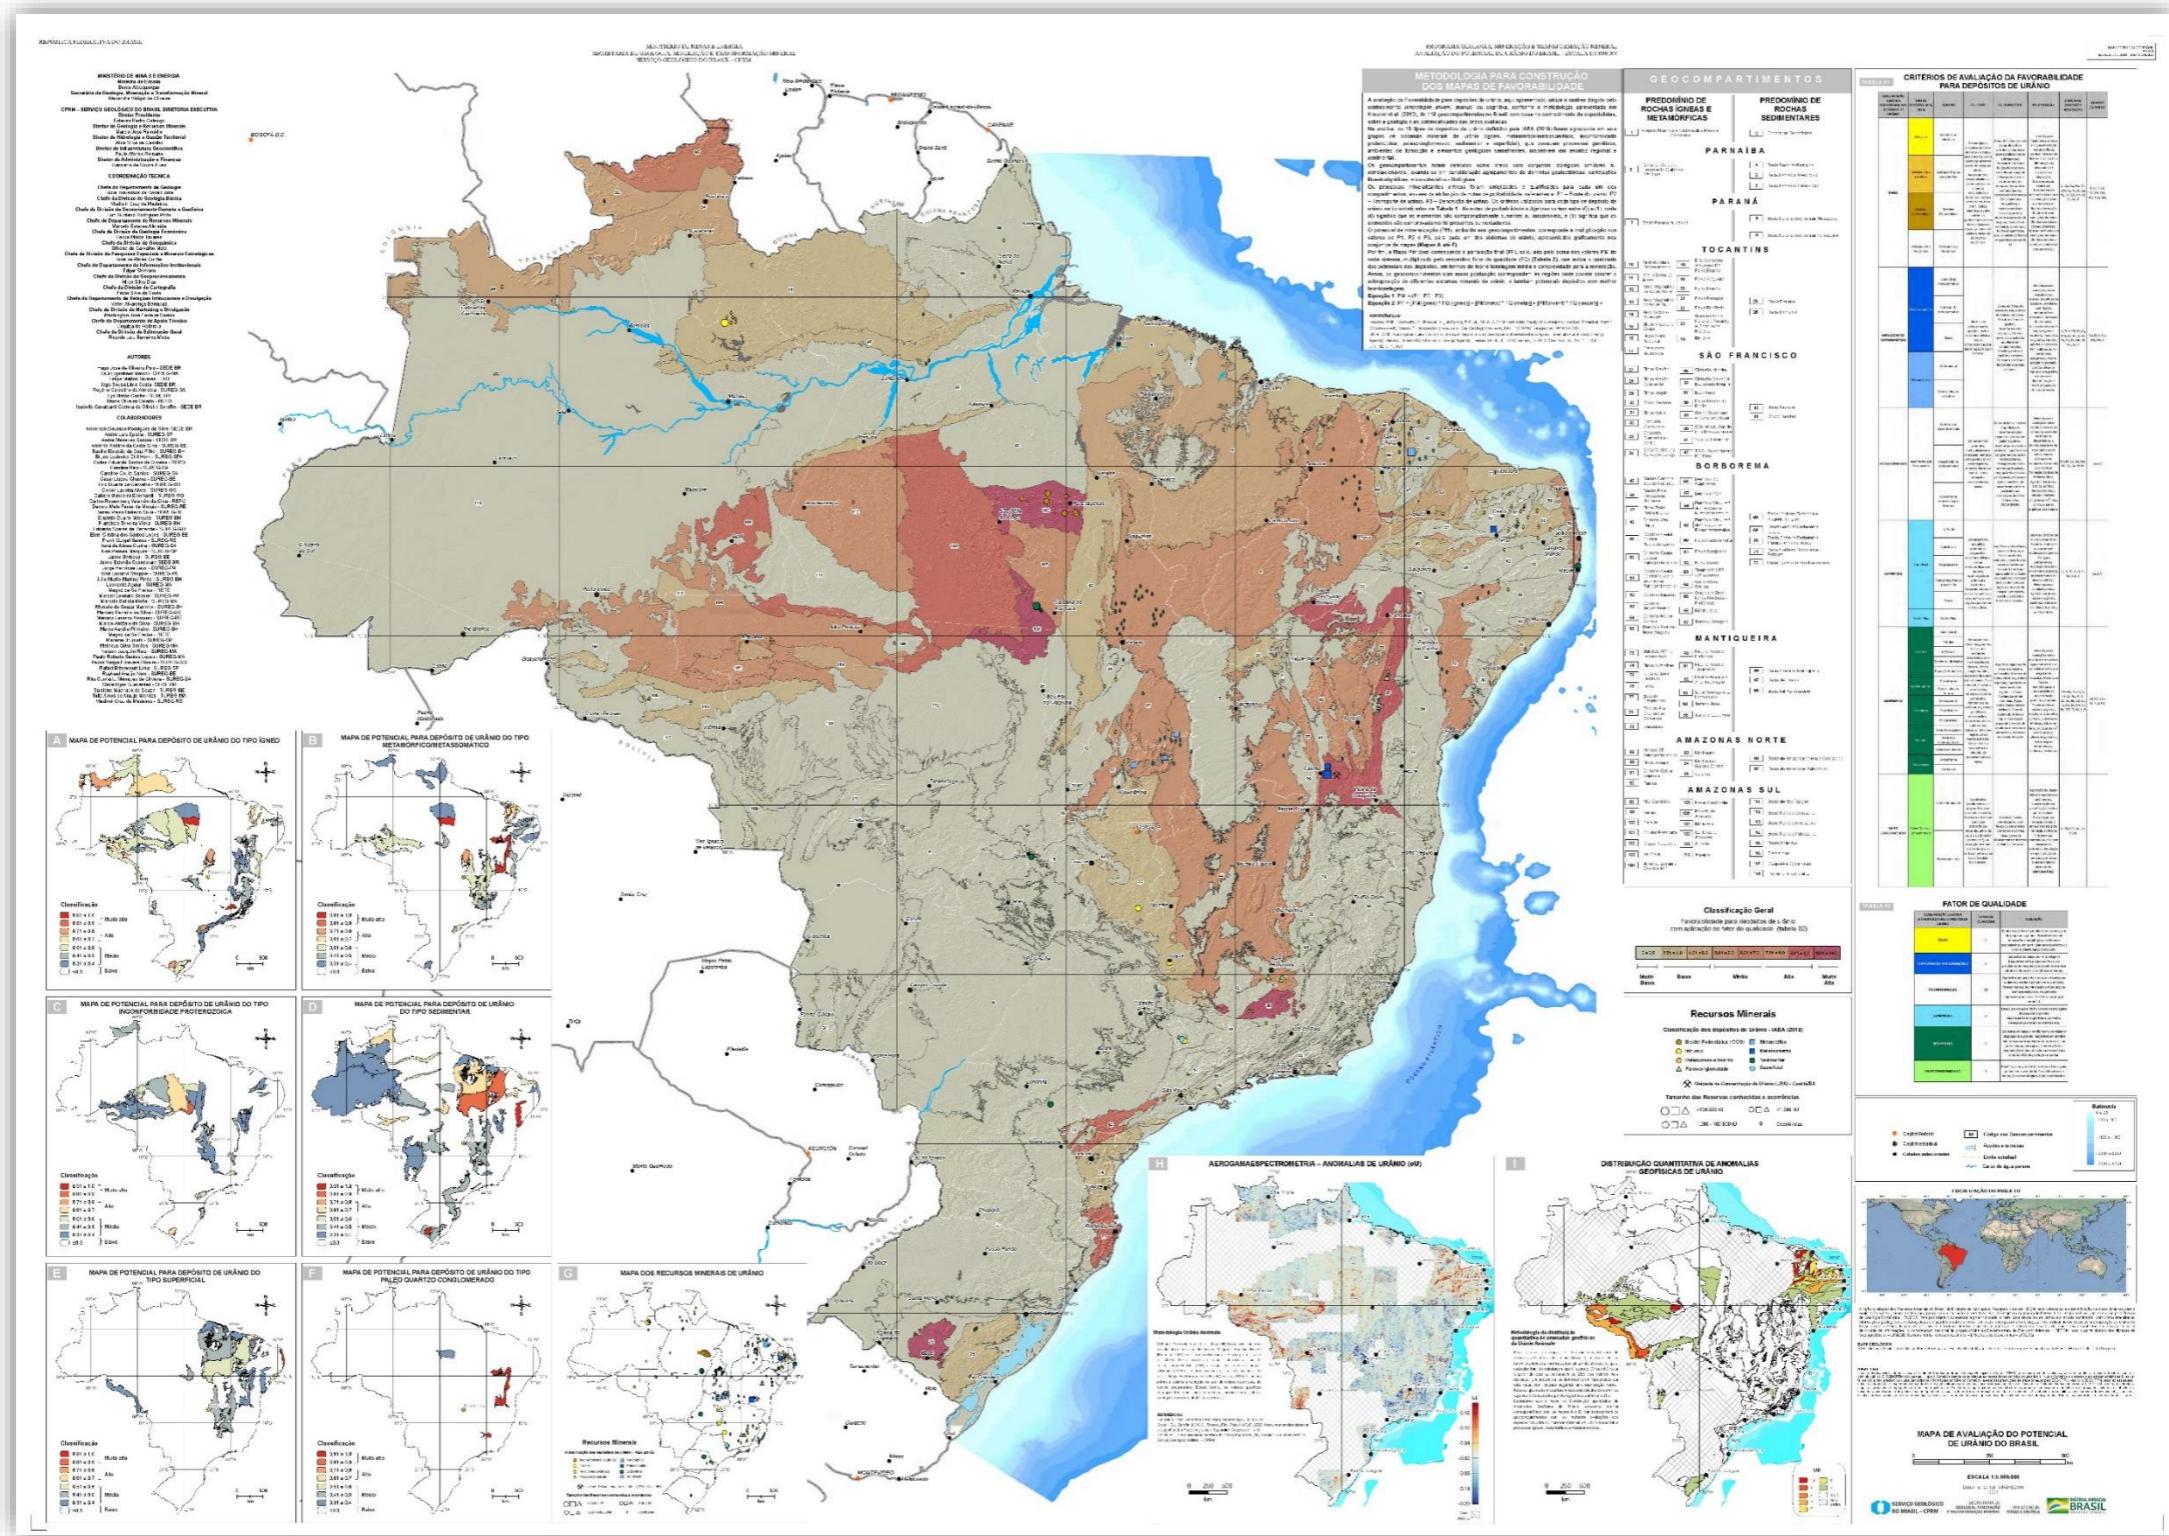
- Enriquecimento de Urânio
- Alta Susceptibilidade

Anomalias de Urânio em Escala Nacional

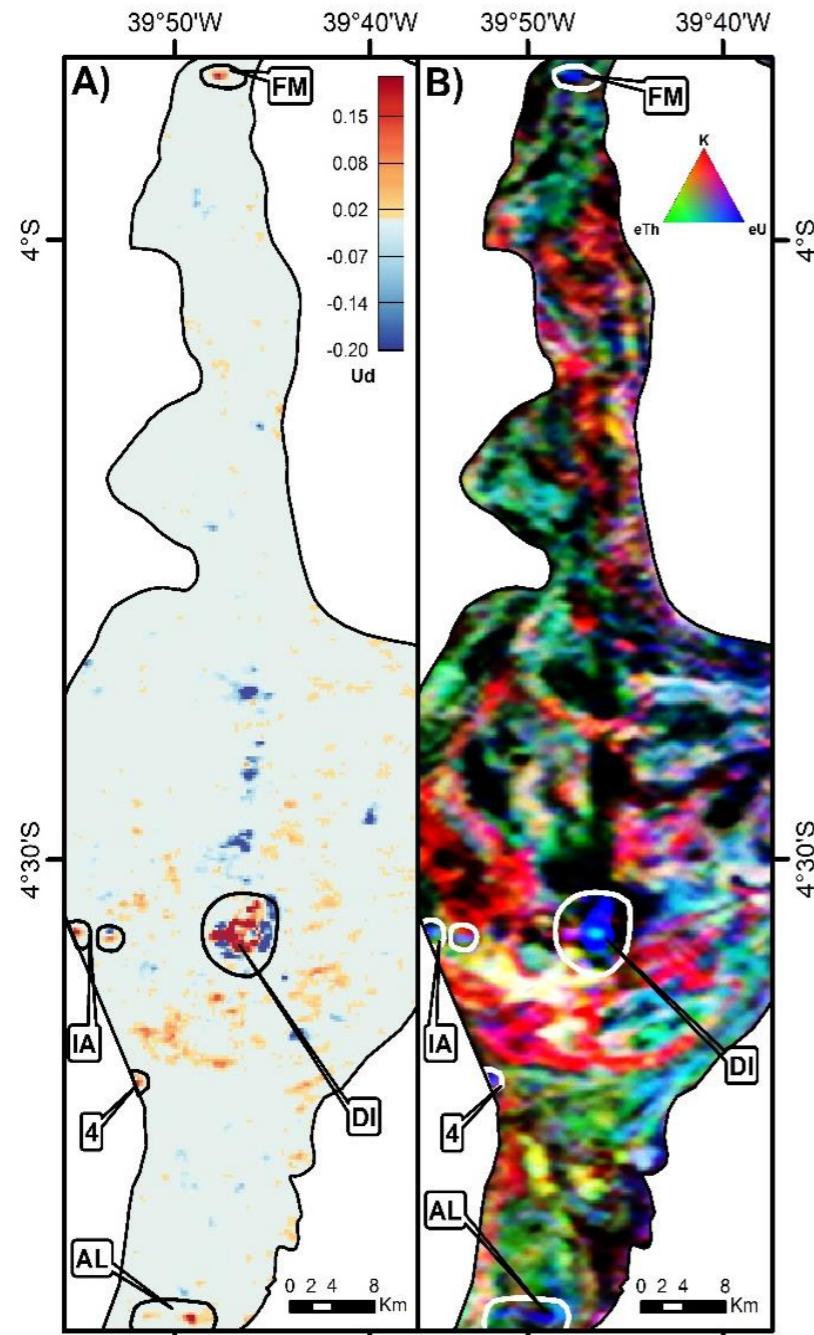
AEROGAMAESPECTROMETRIA – ANOMALIAS DE URÂNIO (eU)



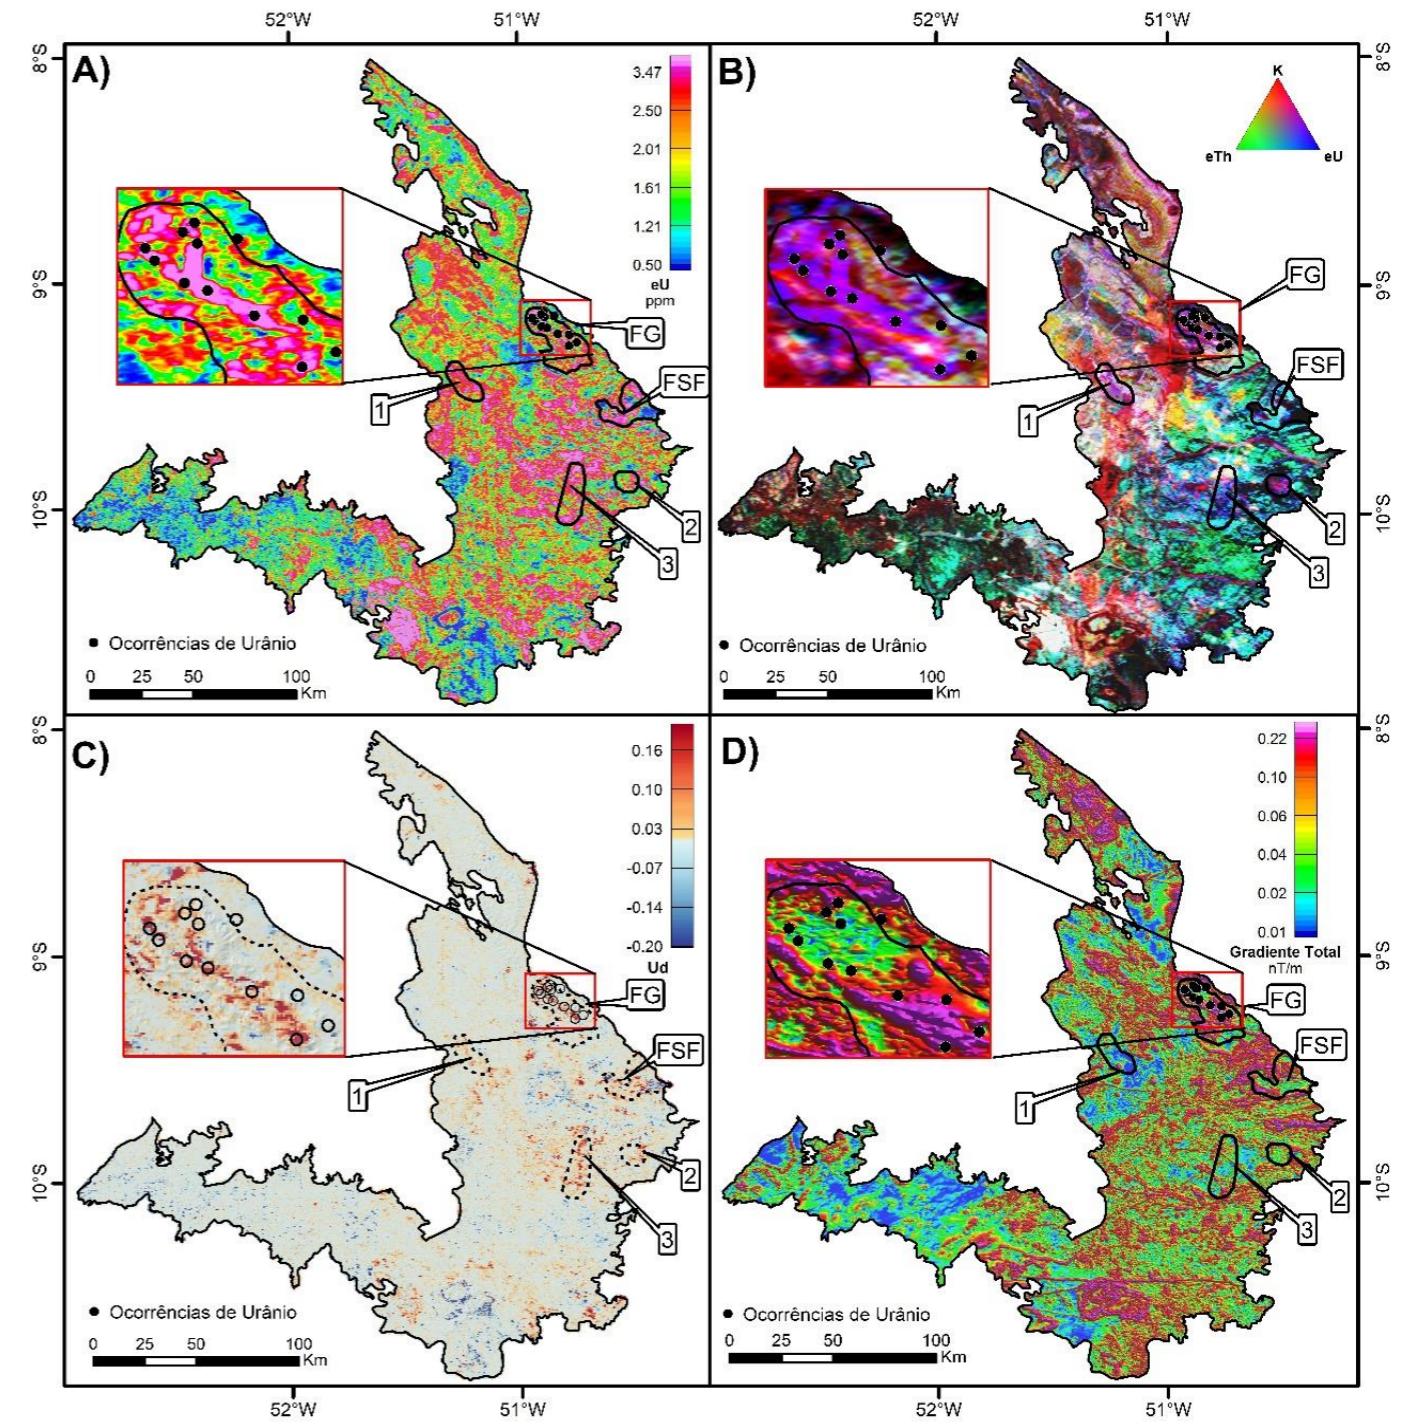
Avaliação do potencial de urânio do Brasil



Anomalias de Urânio em Escala Nacional



DI = Depósito Itataia, FM = Fazenda Madacarú, IA = indícios de albititos, AL = Albititos



FG = Formação Gorotire (FG), Fazenda Santa Fé (FSF)

Qmin – Mineral Chemistry Virtual Assistant



Contents lists available at [ScienceDirect](#)

Computers and Geosciences

journal homepage: www.elsevier.com/locate/cageo



Qmin – A machine learning-based application for processing and analysis of mineral chemistry data

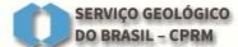
Guilherme Ferreira da Silva ^{a,*}, Marcos Vinicius Ferreira ^a, Iago Sousa Lima Costa ^a, Renato Borges Bernardes ^b, Carlos Eduardo Miranda Mota ^c, Federico Alberto Cuadros Jiménez ^b

^a Directory of Geology and Mineral Resources, Geological Survey of Brazil (SGB/CPRM), Brasilia, Brazil

^b Institute of Geosciences, University of Brasilia, Brasilia, Brazil

^c Directory of Geoscience Infrastructure, Geological Survey of Brazil (SGB/CPRM), Rio de Janeiro, Brazil



PROBLEMA	SOLUÇÃO	VALOR AGREGADO	VANTAGENS	PÚBLICO ALVO
<p><u>Que mineral é esse?</u> Análise de química mineral</p> <p>Cálculo da Fórmula Mineral</p> <p>Cálculo de Conteúdo de Voláteis (H₂O, OH)</p>	<p>Inteligência Artificial - Classificação - Regressão</p> <p>Algoritmos encadeados para otimizar o processo</p>	<p>Praticidade. Input → Output</p> <p>Erro mapeável: Classificação Regressão (Incerteza prob.) (Erro Propagado)</p> <p>Acesso ao programa via navegador (sem executável)</p> <p>CONCEITO GERAL $Qmin \approx TSG$ (focado em química mineral)</p>	<p>Banco de dados de treino extenso (+500.000 análises)</p> <p>Quanto mais uso, mais dados para ajustar o modelo*</p>	<p>Academia: Laboratórios e pesquisadores</p> <p>Indústria Mineral e órgãos forenses ('polícia científica')</p>
<p><small>* com autorização do usuário</small></p> <p>ALTERNATIVAS EXISTENTES</p> <p>Cálculo manual com uso de tabelas, livros e/ou sites (mindat.org)</p>	<p>MÉTRICAS</p> <p>Priori: Cross-fold validation</p> <p>Posteriori: Validação do resultado pelo usuário</p>		<p>DIVULGAÇÃO</p> <p>Mídia institucional & Redes sociais</p> <p>Eventos científicos & Publicações</p>	<p>Público interno: Projetos, Divisões, etc</p> <p>PRIMEIROS USUÁRIOS</p> <p>Academia & Público interno</p>
<p>ESTRUTURA DE CUSTOS</p> <p>Servidor conectado ao programa executando scripts</p> <p>Estrutura hospedada em servidor na nuvem</p> <p>ou</p>	<p>Posterior:</p> <ul style="list-style-type: none">- Curadoria- Manutenção- Atualização- FAQ	<p>RETORNO ESPERADO:</p> <p>+Agilidade</p> <p>+Inovação</p> <p>+Visibilidade</p>		 SERVIÇO GEOLÓGICO DO BRASIL - CPRM



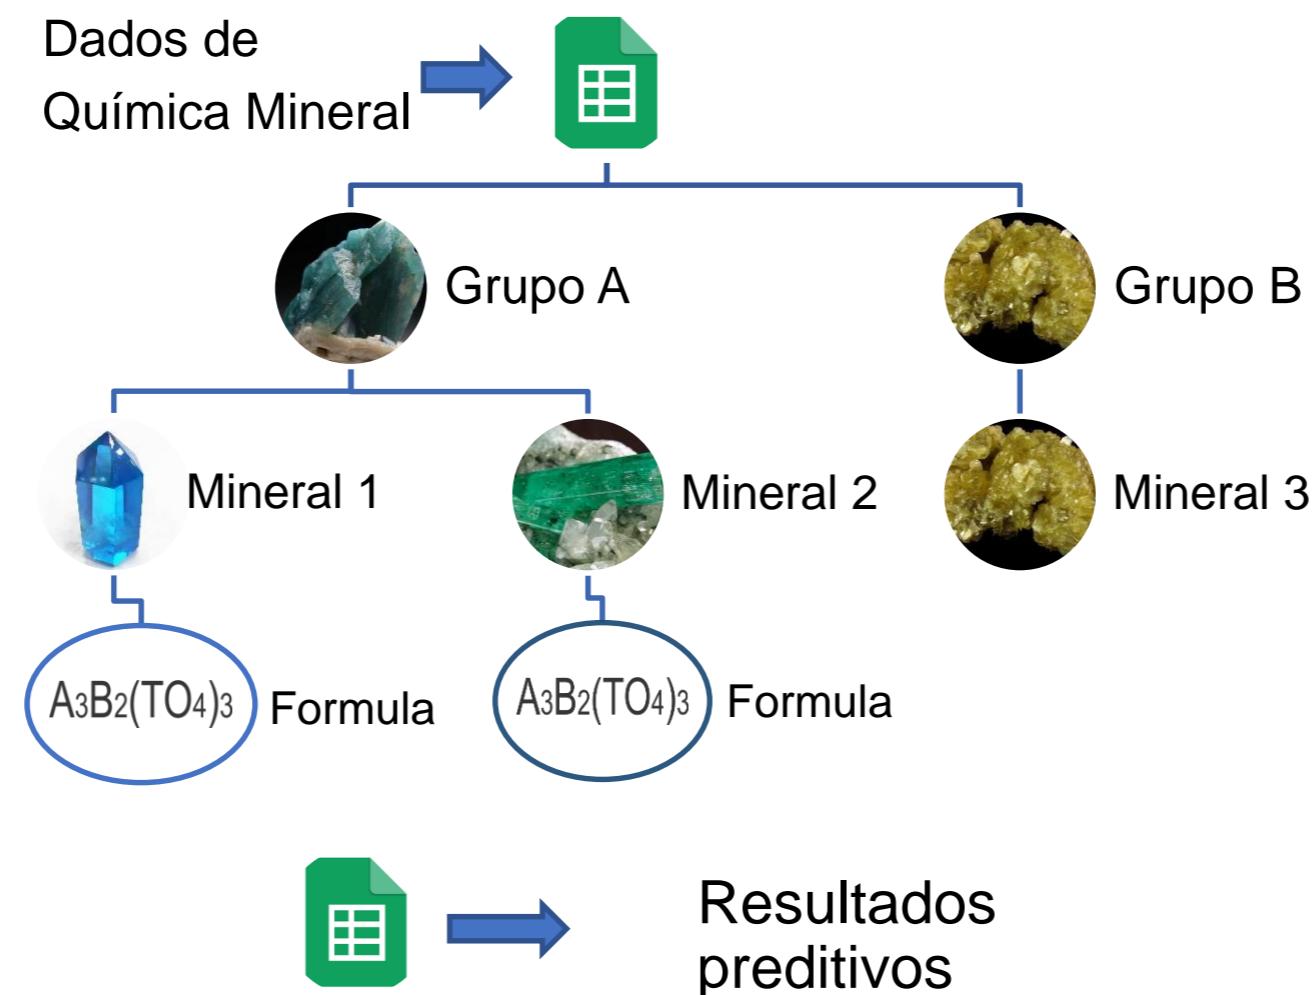
Mineral Chemistry Virtual Assistant



Importação, processamento e gerenciamento dos dados de treinamento



Modelos *Machine Learning*, SMOTE, Interface com o usuário



Validação

**Entre
grupos:
100%**

- | | | | |
|------------------|--------|---------------|-------|
| – Apatitas: | 100,0% | • Ilmenita | 100% |
| – Anfibólios: | 95,4% | • Micas: | 98,9% |
| – Argilomineras: | 88,0% | • Olivinas: | 93,3% |
| – Carbonatos: | 94,4% | • Perovskitas | 100% |
| – Espinélios: | 84,1% | • Piroxênios: | 97,0% |
| – Feldspatos: | 93,3% | • Sulfetos: | 90,5% |
| – Feldspatoides: | 95,0% | • Titanita | 100% |
| – Granadas | 90,7% | • Zircão | 100% |

Matriz de confusão de Feldspatos

Predição	ALBITA	ANDESINA	ANORTITA	ANORTHOCLASE	BYTOWNITA	LABRADORITA	MICROCLINA	OLIGOCLASE	ORTHOCLASE	SANDINA
SANIDINE	0	0	0	0.07	0	0	0.07	0	0.07	0.93
ORTHOCLASE	0	0	0	0	0	0	0.27	0	0.47	0.07
OLIGOCLASE	0	0.07	0	0.2	0	0	0	0.93	0	0
MICROCLINE	0	0	0	0	0	0	0.67	0	0.4	0
LABRADORITE	0	0	0	0.07	0	1	0	0	0	0
BYTOWNITE	0	0	0	0	1	0	0	0	0	0
ANORTHOCLASE	0	0	0	0.53	0	0	0	0	0.07	0
ANORTHITE	0	0	1	0	0	0	0	0	0	0
ANDESINE	0	0.93	0	0	0	0	0	0	0	0
ALBITA	1	0	0	0.13	0	0	0	0.07	0	0

Matriz de confusão de Piroxênios

Referências

Mineral Chemistry Virtual Assistant

Upload Files

Decimal Separator: .
Column Separator: ;
Header Skip: 0
Footer Skip: 0

Drag and Drop or [Select Files](#)

I accept to aggregate my data in the training database of Qmin

About

This is the Qmin - Mineral Chemistry Virtual Assistant. The models herein presented perform mineral classification, missing value imputation by multivariate regression and mineral formula prediction by several Random Forest classification and regression nested models. The models have been developed by researchers of the Directory of Geology and Mineral Resources, of the Geological Survey of Brazil (DGM/CPRM), with the assistance of the technical manager of the EPMA laboratory of the Institute of Geosciences/University of Brasília (IG/UnB).

Important Notes

- This model is in active development and so parameter names and behaviors, and output file formats will change without notice.
- The model is stochastic. Multiple runs with different seeds (or random state) should be undertaken to see average behavior.
- At the current state, Qmin is able to predict among 17 groups and 188 different minerals. Any other mineral not listed below will not perform as desired.

Dataset

File loaded: 31_10_12_GRANADAS_MASSA.xls

PREDICTED GROUP	GROUP QC	PREDICTED MINERAL	MINERAL QC	2nd PREDICT MINERAL	FORMULA	Row
FELOGPAP	HIGH QUALITY	OLIGOCLASE	LOW QUALITY	ANDESINE	(Ca0.2Mn0.8Fe1.7Mg0.2)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	1
GARNET	LOW QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.2Mn0.8Fe1.7Mg0.2)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	2
GARNET	LOW QUALITY	ALMANDINE	MEDIUM QUALITY	MELANITE	(Ca0.2Mn0.7Fe1.7Mg0.3)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	3
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.2Mn0.7Fe1.7Mg0.2)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	4
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.2Mn0.1Fe2.1Mg0.5)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	10
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.2Mn0.1Fe2.1Mg0.6)3.0(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	11
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.2Mn0.1Fe2.0Mg0.5)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	12
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	MELANITE	(Ca0.5Mn0.1Fe1.9Mg0.4)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	13
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.5Mn0.2Fe1.9Mg0.4)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	14
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.5Mn0.2Fe1.9Mg0.3)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	15
GARNET	LOW QUALITY	ALMANDINE	MEDIUM QUALITY	MELANITE	(Ca0.5Mn0.3Fe1.9Mg0.3)2.9(Fe0.1Al2.0)2.1(Si12.9O2.0)22.9	16
GARNET	MEDIUM QUALITY	ALMANDINE	MEDIUM QUALITY	SCHORLONITE	(Ca0.5Mn0.3Fe1.8Mg0.3)2.9(Al2.2)2.2(Si13.0O2.0)22.9	17

Graphics

downloads/5c9164ca-eeda-11ea-887e-acde48001122.xlsx

[DOWNLOAD](#)

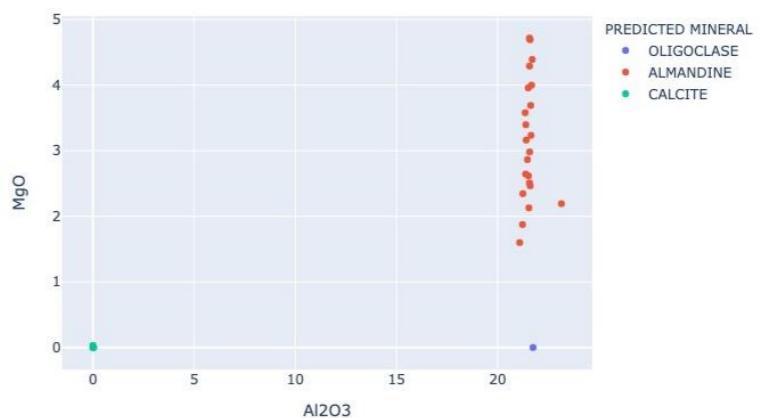
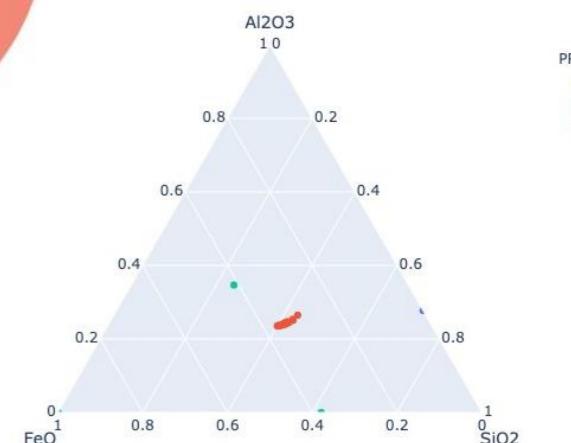
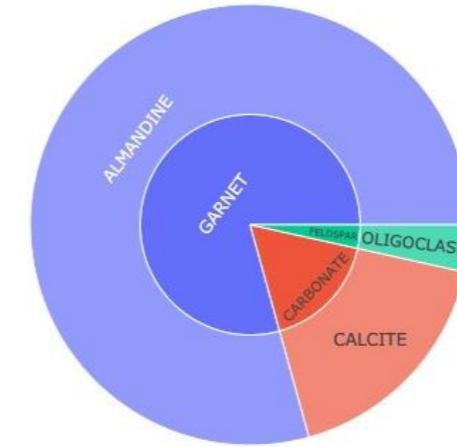
Status

This model is in active development and subject to significant code changes to:



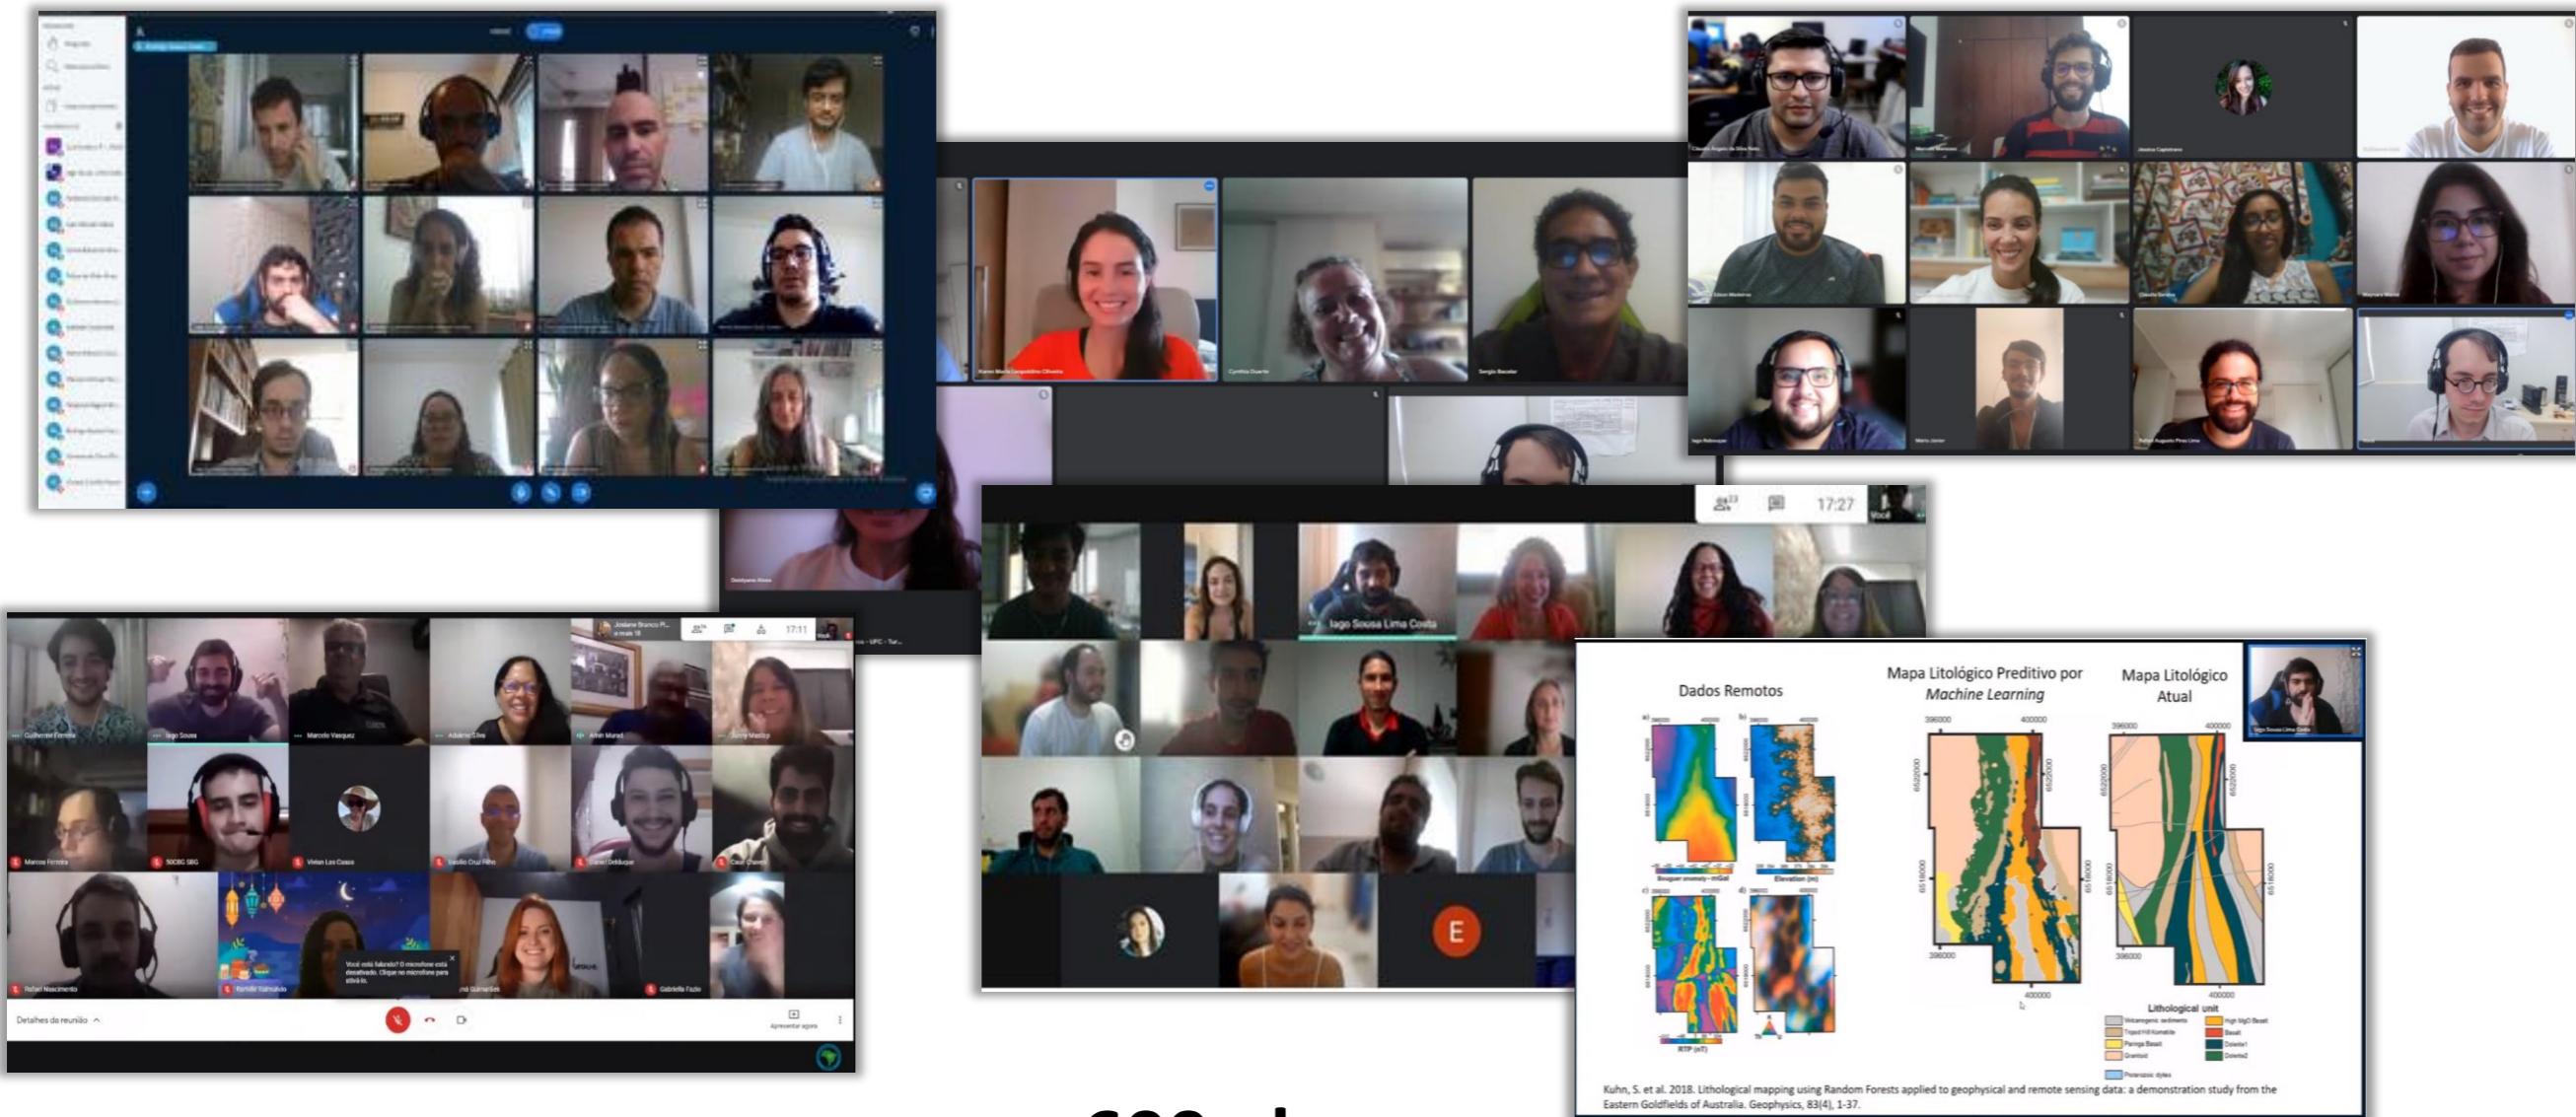
Interface Web

<https://apps.cprm.gov.br/qmin/>



Treinamentos

- Introdução a programação em Python para geocientistas
- Introdução ao Machine Learning para Novos Geocientistas
- Machine Learning para geração de mapas litológicos preditivos
- Machine Learning para geração de mapas de prospectividade mineral



Outras Publicações

Space Weather

Research Article |  Open Access | 

Forecasting Megaelectron-Volt Electrons Inside Earth's Outer Radiation Belt: PreMevE 2.0 Based on Supervised Machine Learning Algorithms

Rafael Pires de Lima , Yue Chen , Youzuo Lin

First published: 10 February 2020 | <https://doi.org/10.1029/2019SW002399>



Ore Geology Reviews

Volume 124, September 2020, 103611



Modeling of Cu-Au prospectivity in the Carajás mineral province (Brazil) through machine learning: Dealing with imbalanced training data

Elias Martins Guerra Prado ^{a, b} , Carlos Roberto de Souza Filho ^b , Emmanuel John M. Carranza ^c , João Gabriel Motta ^b 



Computers & Geosciences

Volume 142, September 2020, 104481



Petrographic microfacies classification with deep convolutional neural networks

Rafael Pires de Lima ^{a, b} , David Duarte ^a, Charles Nicholson ^c, Roger Slatt ^a, Kurt J. Marfurt ^a

Unsupervised segmentation of the Serra Dourada Granite, Goiás Tin Province, based on Airborne Geophysics.

Guilherme Ferreira da Silva¹, Marcos Vinícius Ferreira¹, Iago Sousa Lima Costa¹, Lucy Takehara Chemale¹, Luiz Gustavo Pinto¹.

¹ Geological Survey of Brazil – CPRM



Article

Convolutional Neural Network for Remote-Sensing Scene Classification: Transfer Learning Analysis

Rafael Pires de Lima ^{*}  and Kurt Marfurt

School of Geosciences, University of Oklahoma, 100 East Boyd Street, RM 710, Norman, OK 73019, USA; kmarfurt@ou.edu

* Correspondence: rlima@ou.edu

Journal of Hydrology 567 (2018) 71–85

Contents lists available at ScienceDirect



Journal of Hydrology

journal homepage: www.elsevier.com/locate/jhydrol



Research papers

Links between different classes of storm tracks and the flood trends in Spain

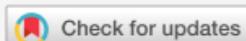
Marcus Suassuna Santos ^{a,b,c,*}, Luis Mediero ^b, Carlos Henrique Ribeiro Lima ^c, Leonardo Zandonadi Moura ^c



^a Department of Hydrology, Brazilian Geological Survey – CPRM, SBN Quadra 2, Asa Norte, 70040-904 Brasília, DF, Brazil
^b Universidad Politécnica de Madrid, Department of Civil Engineering Hydraulics, Energy and Environment, 28040 Madrid, Spain
^c University of Brasília, Department of Civil and Environmental Engineering, Darcy Ribeiro Campus, 70910-900 Brasília, DF, Brazil

 No Access | Interpretation | Volume 7, Issue 3

Convolutional neural networks as aid in core lithofacies classification



Authors:

Rafael Pires de Lima, Fnu Suriamin, Kurt J. Marfurt, and Matthew J. Pranter

The Sedimentary Record

Deep convolutional neural networks as a geological image classification tool

Rafael Pires de Lima^{1,2}, Alicia Bonar¹, David Duarte Coronado¹, Kurt Marfurt¹, Charles Nicholson¹

¹School of Geology and Geophysics, The University of Oklahoma, 100 East Boyd Street, RM 710, Norman, Oklahoma, 73019, USA

²The Geological Survey of Brazil – CPRM, 55 Rua Costa, São Paulo, São Paulo, Brazil

³School of Industrial and Systems Engineering, The University of Oklahoma, 202 West Boyd Street, RM 124, Norman, Oklahoma, 73019, USA

Identificación del origen de las tormentas que provocan las avenidas en España utilizando trayectorias de tormentas y técnicas de aprendizaje automático.

Santos, Marcus S. ^{a,b,c,1}; Mediero, Luis J. ^{c,2}; Lima, Carlos H.R. J. ^{a,2}

^a Posgrado en Tecnología Ambiental y Recursos Hídricos, Universidad de Brasília (UnB), Campus Universitario Darcy Ribeiro, Anexo SG12, Térreo, 70.910-900, Brasília, DF, Brasil.

^b Departamento de Hidrología, Servicio Geológico de Brasil (CPRM), Sede, SBN Cuadra 02, Ed. H, 70040-904, Brasilia, DF, Brasil.

^c Departamento de Ingeniería Civil: Hidráulica, Energía y Medio Ambiente, ETS de Ingenieros de Caminos, Canales y Puertos, Universidad Politécnica de Madrid, c/ Profesor Aranguren, 3. 28040. Madrid.

E-mail: ^{a,b,c}marcus.santos@cprm.gov.br, ^cluis.mediero@upm.es., ^{a,2}chrlima@unb.br

Iago Costa

Geofísico e *Coordenador Executivo da Diretoria de Geologia e Recursos Minerais*

Serviço Geológico do Brasil – CPRM

e-mail: iago.costa@sgb.gov.br

Telefone: 61-2108-8413

www.cprm.gov.br

